



ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΙΑΣ

ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ

ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

**Αξιολόγηση ενός Προεκπαιδευμένου Μοντέλου Έναντι
Στατιστικών Μεθόδων και Μεθόδων Βαθιάς Μάθησης σε
Χρονοσειρές Τιμών Μετοχών**

Διπλωματική Εργασία

Αναγνωστόπουλος Σπυρίδων

Επιβλέπουσα: Τουσίδου Ελένη

Σεπτέμβριος 2025



ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΙΑΣ

ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ

ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ


**Αξιολόγηση ενός Προεκπαιδευμένου Μοντέλου Έναντι
Στατιστικών Μεθόδων και Μεθόδων Βαθιάς Μάθησης σε
Χρονοσειρές Τιμών Μετοχών**

Διπλωματική Εργασία

Αναγνωστόπουλος Σπυρίδων

Επιβλέπουσα: Τουσίδου Ελένη

Σεπτέμβριος 2025



UNIVERSITY OF THESSALY
SCHOOL OF ENGINEERING
DEPARTMENT OF ELECTRICAL AND COMPUTER ENGINEERING

**Evaluating a Pretrained Model Against Statistical and Deep
Learning Methods on Stock Price Time Series.**

Diploma Thesis

Anagnostopoulos Spyridon

Supervisor: Tousidou Eleni

September 2025

Εγκρίνεται από την Επιτροπή Εξέτασης:

Επιβλέπουσα **Τουσίδου Ελένη**

Ε.ΔΙ.Π, Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών, Πανεπιστήμιο Θεσσαλίας

Μέλος **Βασιλακόπουλος Μιχαήλ**

Καθηγητής, Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών, Πανεπιστήμιο Θεσσαλίας

Μέλος **Δασκαλοπούλου Ασπασία**

Αναπληρώτρια Καθηγήτρια, Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών, Πανεπιστήμιο Θεσσαλίας

Ευχαριστίες

Ολοκληρώνοντας την εργασία αυτή, θα ήθελα να εκφράσω την ειλικρινή μου ευγνωμοσύνη προς την επιβλέπουσα κ. Ελένη Τουσίδου για την καθοδήγηση, την υποστήριξη και τις καίριες παρατηρήσεις της, καθώς και για την άψογη συνεργασία μας. Ευχαριστώ επίσης θερμά τα μέλη της επιτροπής, τον κ. Βασιλακόπουλο και την κ. Τσαλαπάτα, για τον χρόνο και τη συμβολή τους στη διαδικασία.

ΥΠΕΥΘΥΝΗ ΔΗΛΩΣΗ ΠΕΡΙ ΑΚΑΔΗΜΑΪΚΗΣ ΔΕΟΝΤΟΛΟΓΙΑΣ ΚΑΙ ΠΝΕΥΜΑΤΙΚΩΝ ΔΙΚΑΙΩΜΑΤΩΝ

«Με πλήρη επίγνωση των συνεπειών του νόμου περί πνευματικών δικαιωμάτων, δηλώνω ρητά ότι η παρούσα διπλωματική εργασία, καθώς και τα ηλεκτρονικά αρχεία και πηγαίοι κώδικες που αναπτύχθηκαν ή τροποποιήθηκαν στα πλαίσια αυτής της εργασίας, αποτελεί αποκλειστικά προϊόν προσωπικής μου εργασίας, δεν προσβάλλει κάθε μορφής δικαιώματα διανοητικής ιδιοκτησίας, προσωπικότητας και προσωπικών δεδομένων τρίτων, δεν περιέχει έργα/εισφορές τρίτων για τα οποία απαιτείται άδεια των δημιουργών/δικαιούχων και δεν είναι προϊόν μερικής ή ολικής αντιγραφής, οι πηγές δε που χρησιμοποιήθηκαν περιορίζονται στις βιβλιογραφικές αναφορές και μόνον και πληρούν τους κανόνες της επιστημονικής παράθεσης. Τα σημεία όπου έχω χρησιμοποιήσει ιδέες, κείμενο, αρχεία ή/και πηγές άλλων συγγραφέων, αναφέρονται ευδιάκριτα στο κείμενο με την κατάλληλη παραπομπή και η σχετική αναφορά περιλαμβάνεται στο τμήμα των βιβλιογραφικών αναφορών με πλήρη περιγραφή. Δηλώνω επίσης ότι τα αποτελέσματα της εργασίας δεν έχουν χρησιμοποιηθεί για την απόκτηση άλλου πτυχίου. Αναλαμβάνω πλήρως, ατομικά και προσωπικά, όλες τις νομικές και διοικητικές συνέπειες που δύναται να προκύψουν στην περίπτωση κατά την οποία αποδειχθεί, διαχρονικά, ότι η εργασία αυτή ή τμήμα της δεν μου ανήκει διότι είναι προϊόν λογοκλοπής».

Ο/Η Δηλών/ούσα

Αναγνωστόπουλος Σπυρίδων

Διπλωματική Εργασία

Αξιολόγηση ενός Προεκπαιδευμένου Μοντέλου Έναντι Στατιστικών

Μεθόδων και Μεθόδων Βαθιάς Μάθησης σε Χρονοσειρές Τιμών

Μετοχών

Αναγνωστόπουλος Σπυρίδων

Περίληψη

Η πρόβλεψη χρονοσειρών μετοχών αποτελεί θεμελιώδες ζήτημα στη χρηματοοικονομική, καθώς η ακριβής μοντελοποίηση και εκτίμηση της μελλοντικής πορείας των τιμών έχει καθοριστικό ρόλο στις στρατηγικές συναλλαγών, στη βελτιστοποίηση χαρτοφυλακίων και στη διαχείριση κινδύνου. Παραδοσιακά, η ανάλυση βασιζόταν σε κλασικές στατιστικές μεθόδους, οι οποίες παραμένουν έως σήμερα ευρέως δημοφιλείς. Ωστόσο, η εμφάνιση των τεχνικών βαθιάς μάθησης έχει διευρύνει σημαντικά τις δυνατότητες πρόβλεψης.

Πιο πρόσφατα, ιδιαίτερο ενδιαφέρον έχουν προσελκύσει τα θεμελιώδη μοντέλα, τα οποία αποτελούν μοντέλα γενικής χρήσης, προεκπαιδευμένα σε τεράστιους όγκους δεδομένων, και μπορούν στη συνέχεια να προσαρμοστούν σε ποικίλες εφαρμογές. Η αξιοποίησή τους στον χώρο των χρονοσειρών αποτελεί σχετικά νέα εξέλιξη, που ανοίγει νέες προοπτικές στην πρόβλεψη πολύπλοκων δυναμικών συστημάτων. Ένα χαρακτηριστικό παράδειγμα είναι το TinyTimeMixer, το οποίο, παρά τη λιτή και υπολογιστικά αποδοτική αρχιτεκτονική του, επιτυγχάνει υψηλή ακρίβεια πρόβλεψης, αποδεικνύοντας ότι η απλότητα δεν συνεπάγεται αναγκαστικά απώλεια προβλεπτικής ισχύος. Στην παρούσα εργασία εξετάζεται η εφαρμογή των TinyTimeMixers στην πρόβλεψη χρονοσειρών μετοχών και αξιολογείται η απόδοσή τους σε σύγκριση τόσο με κλασικά στατιστικά μοντέλα όσο και με σύγχρονες προσεγγίσεις βαθιάς μάθησης.

Λέξεις-κλειδιά:

Χρονοσειρές, Μετοχές, TinyTimeMixer, ARIMA, LSTM, iTransformer

Diploma Thesis

Evaluating a Pretrained Model Against Statistical and Deep Learning Methods on Stock Price Time Series.

Anagnostopoulos Spyridon

Abstract

Stock time series forecasting is a fundamental challenge in finance, as the accurate modeling and estimation of future price dynamics plays a decisive role in trading strategies, portfolio optimization, and risk management. Traditionally, analysis has relied on classical statistical methods, which remain widely popular to this day. However, the emergence of deep learning techniques has significantly expanded the predictive capabilities in this domain.

More recently, foundation models have attracted considerable attention. These are general-purpose models, pretrained on massive amounts of data, which can subsequently be adapted to a wide range of applications. Their application to time series represents a relatively new development that opens up promising opportunities for forecasting complex dynamic systems. A notable example is TinyTimeMixers, which, despite its lightweight and computationally efficient architecture, achieves high predictive accuracy, demonstrating that simplicity does not necessarily entail a loss of forecasting power. In this work, we investigate the application of TinyTimeMixers to stock time series forecasting and evaluate their performance in comparison with both classical statistical models and modern deep learning approaches.

Keywords:

Time Series, Stocks, TinyTimeMixers, ARIMA, LSTM, iTransformer

Πίνακας περιεχομένων

Ευχαριστίες	ix
Περίληψη	xii
Abstract	xiii
Πίνακας περιεχομένων	xv
Κατάλογος σχημάτων	xix
Κατάλογος πινάκων	xxiii
Συντομογραφίες	xxv
1 Εισαγωγή	1
1.1 Αντικείμενο της διπλωματικής	2
1.2 Οργάνωση του τόμου	3
2 Συναφείς εργασίες	5
2.1 Εισαγωγή	5
2.2 Στατιστικές μέθοδοι	5
2.3 Βαθιά μάθηση	6
2.4 Transformers και iTransformer	6
2.5 Θεμελιώδη μοντέλα χρονοσειρών	6
3 Θεωρητικό υπόβαθρο	9
3.1 Εισαγωγή	9
3.2 Χρηματιστήριο	9

3.3	Χρονοσειρές	10
3.4	Δεδομένα και τεχνικοί δείκτες	11
3.5	ARIMA	13
3.6	LSTM	15
3.7	iTransformer	16
3.8	TinyTimeMixers	18
3.9	Μέθοδοι αξιολόγησης αποτελεσμάτων	20
3.9.1	Μετρικές αξιολόγησης	20
3.9.2	Επενδυτική στρατηγική	21
3.9.3	Ανάλυση Συσχέτισης Μεταβλητότητας-Σφάλματος	22
4	Προεπεξεργασία και εξερεύνηση δεδομένων	23
4.1	Εισαγωγή	23
4.2	Λήψη δεδομένων και προεπεξεργασία	23
4.3	Επισκόπηση συνόλου δεδομένων	25
4.3.1	Επιλογή Δεδομένων Μετοχών	25
4.3.2	Περίοδοι σημαντικών γεγονότων	29
5	Αξιολόγηση μηδενικής προσαρμογής και βελτιστοποίηση TTM	37
5.1	Εισαγωγή	37
5.2	Υλοποίηση TTM στην python	37
5.3	Αποτελέσματα TTM μηδενικής προσαρμογής	38
5.4	Εύρεση καλύτερου ποσοστού εκπαίδευσης	42
5.4.1	Απώλειες Εκπαίδευσης - Επικύρωσης ανά ποσοστό εκπαίδευσης	42
5.4.2	Χάσμα γενίκευσης	45
5.5	Ανάλυση μεταφερσιμότητας	46
5.5.1	Συγκεντρωτικοί πίνακες αποτίμησης προβλέψεων	46
5.5.2	Εκπαίδευση στο ETF QQQ	51
5.6	Βελτιστοποίηση υπερπαραμέτρων	52
5.6.1	Πορεία σφάλματος στη μελέτη Optuna	53
5.6.2	Σχετική σημασία υπερπαραμέτρων	54
5.6.3	Διάγραμμα παράλληλων συντεταγμένων	55
5.7	Ανάλυση σημαντικότητας χαρακτηριστικών	56

5.7.1	Δείκτης SHAP	56
5.7.2	Σημαντικότητα μεταθέσεων	57
5.8	Αποτελέσματα βελτιστοποιημένου TTM	58
6	Πρόβλεψη με χρήση στατιστικών μεθόδων και μοντέλων βαθιάς μάθησης	65
6.1	Εισαγωγή	65
6.2	ARIMA	65
6.2.1	Προσδιορισμός παραμέτρων ARIMA	66
6.2.2	Αποτελέσματα προβλέψεων	70
6.3	LSTM	75
6.3.1	Δομή LSTM	75
6.3.2	Αποτελέσματα προβλέψεων	76
6.4	iTransformer	81
6.4.1	Δομή iTransformer	81
6.4.2	Αποτελέσματα προβλέψεων	82
7	Συμπεράσματα	87
7.1	Σύνοψη και συμπεράσματα	87
7.2	Μελλοντικές επεκτάσεις	94
	Βιβλιογραφία	95

Κατάλογος σχημάτων

3.1	Δομή LSTM [1]	15
3.2	Δομή Transformer και iTransformer [2]	17
3.3	Δομή του TTM από την δημοσίευση στο NeurIPS 2024 [3]	19
4.1	Τιμές κλεισίματος της AAPL στην περίοδο 2010-2025	27
4.2	Τιμές κλεισίματος της TSLA στην περίοδο 2010-2025	27
4.3	Τιμές κλεισίματος της XOM στην περίοδο 2010-2025	27
4.4	Τιμές κλεισίματος της SPY στην περίοδο 2010-2025	28
4.5	Τιμές κλεισίματος της JNJ στην περίοδο 2010-2025	28
4.6	Τιμές κλεισίματος της AMD στην περίοδο 2010-2025	28
4.7	Τιμές κλεισίματος της PG στην περίοδο 2010-2025	29
4.8	AAPL – Κατάρρευση & Ανάκαμψη (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 09/2019-06/2020	30
4.9	TSLA – Πάγωμα υψηλού βήτα (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 07/2020-07/2021	31
4.10	XOM – Κορυφή Πετρελαϊκού Κύκλου (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 11/2021-09/2022	32
4.11	SPY – Πτώση με πλάγια/αιρετική κίνηση (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 01/2022-01/2023	33
4.12	JNJ – Συνεχής ανθεκτικότητα (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 11/2018-01/2020	34
4.13	AMD – Μαζική ρευστοποίηση στον τεχνολογικό τομέα (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 05/2018-03/2019	35
4.14	PG – Ανεξαρτησία από μακροοικονομικά γεγονότα (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 01/2015-01/2016	36

5.1	Πρόβλεψη μηδενικής προσαρμογής στο σύνολο αξιολόγησης της AAPL . .	40
5.2	Πρόβλεψη μηδενικής προσαρμογής στο σύνολο αξιολόγησης της TSLA . .	40
5.3	Σχέση κυλιόμενης μεταβλητότητας/σφάλματος για την TSLA- Πρόβλεψη μηδενικής προσαρμογής	41
5.4	Απώλειες εκπαίδευσης/επικύρωσης για το ποσοστό 12%	43
5.5	Απώλειες εκπαίδευσης/επικύρωσης για το ποσοστό 24%	44
5.6	Απώλειες εκπαίδευσης/επικύρωσης για το ποσοστό 42%	44
5.7	Απώλειες εκπαίδευσης/επικύρωσης για το ποσοστό 54%	44
5.8	Χάσμα γενίκευσης	45
5.9	Συγκεντρωτικός πίνακας MAE	47
5.10	Συγκεντρωτικός πίνακας RMSE	48
5.11	Συγκεντρωτικός πίνακας MAPE	49
5.12	Πορεία σφάλματος επικύρωσης ανά δοκιμή Optuna	54
5.13	Σχετική σημασία υπερπαραμέτρων	55
5.14	Διάγραμμα παράλληλων συντεταγμένων	55
5.15	Ραβδόγραμμα δεικτών SHAP	57
5.16	Ραβδόγραμμα σημαντικότητας μεταθέσεων	58
5.17	Διάγραμμα κυλιόμενης μεταβλητότητας/σφάλματος για την TSLA - TTM- optimized [4]	61
5.18	Διάγραμμα αποδόσεων επενδυτικής στρατηγικής - TTM	63
5.19	Sharpe Ratio στρατηγικής ανά μετοχή - TTM	63
5.20	Total Return στρατηγικής ανά μετοχή - TTM	64
5.21	Max Drawdown στρατηγικής ανά μετοχή - TTM	64
6.1	Αποτελέσματα τεστ ADF	67
6.2	Διαγράμματα ACF/PACF	67
6.4	Αποτελέσματα συνάρτησης sarimax()	68
6.3	Αποτελέσματα συνάρτησης plot_diagnostics()	69
6.5	Διάγραμμα κυλιόμενης μεταβλητότητας/σφάλματος για την AMD - ARIMA [4]	72
6.6	Διάγραμμα αποδόσεων επενδυτικής στρατηγικής - ARIMA	73
6.7	Sharpe Ratio στρατηγικής ανά μετοχή - ARIMA	74
6.8	Total Return στρατηγικής ανά μετοχή - ARIMA	74

6.9	Max Drawdown στρατηγικής ανά μετοχή - ARIMA	74
6.10	Διάγραμμα κυλιόμενης μεταβλητότητας/σφάλματος για την AAPL - LSTM [4]	78
6.11	Διάγραμμα αποδόσεων επενδυτικής στρατηγικής - LSTM	79
6.12	Sharpe Ratio στρατηγικής ανά μετοχή - LSTM	80
6.13	Total Return στρατηγικής ανά μετοχή - LSTM	80
6.14	Max Drawdown στρατηγικής ανά μετοχή - LSTM	80
6.15	Διάγραμμα κυλιόμενης μεταβλητότητας/σφάλματος για την AMD - iTrans- former [4]	84
6.16	Διάγραμμα αποδόσεων επενδυτικής στρατηγικής - iTransformer	85
6.17	Sharpe Ratio στρατηγικής ανά μετοχή - iTransformer	86
6.18	Total Return στρατηγικής ανά μετοχή - iTransformer	86
6.19	Max Drawdown στρατηγικής ανά μετοχή - iTransformer	86
7.1	Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - σύνολο αξιολόγησης - TTM	91
7.2	Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - σύνολο αξιολόγησης - ARIMA	91
7.3	Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - σύνολο αξιολόγησης - LSTM	92
7.4	Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - σύνολο αξιολόγησης - iTransformer	92
7.5	Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - Πάγωμα υψηλού βήτα - TTM	92
7.6	Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - Πάγωμα υψηλού βήτα - ARIMA	93
7.7	Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - Πάγωμα υψηλού βήτα - LSTM	93
7.8	Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - Πάγωμα υψηλού βήτα - iTransformer	94

Κατάλογος πινάκων

3.1	Παράδειγμα δεδομένων από τη χρονοσειρά AAPL	12
3.2	Τεχνικοί δείκτες και περιγραφές	13
5.1	Πίνακας μετρικών στο σύνολο αξιολόγησης - TTM μηδενικής προσαρμογής	39
5.2	Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - TTM μηδενικής προσαρμογής	39
5.3	Πίνακας μετρικών στα παράθυρα γεγονότων - TTM μηδενικής προσαρμογής	40
5.4	Μετρικές μοντέλου εκπαιδευμένο στον SPY - Σύνολο αξιολόγησης	50
5.5	Μετρικές μοντέλου εκπαιδευμένο στον SPY - παράθυρα γεγονότων	50
5.6	Μετρικές μοντέλου εκπαιδευμένο στο QQQ - Σύνολο αξιολόγησης	52
5.7	Μετρικές μοντέλου εκπαιδευμένο στο QQQ - παράθυρα γεγονότων	52
5.8	Πίνακας μετρικών στο σύνολο αξιολόγησης - βελτιστοποιημένο TTM . . .	59
5.9	Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - βελτιστοποιημένο TTM	60
5.10	Πίνακας μετρικών στα παράθυρα γεγονότων - βελτιστοποιημένο TTM . . .	60
6.1	Πίνακας μετρικών στο σύνολο αξιολόγησης - ARIMA	71
6.2	Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - ARIMA	71
6.3	Πίνακας μετρικών στα παράθυρα γεγονότων - ARIMA	71
6.4	Πίνακας μετρικών στο σύνολο αξιολόγησης - LSTM	76
6.5	Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - LSTM	77
6.6	Πίνακας μετρικών στα παράθυρα γεγονότων - LSTM	77
6.7	Πίνακας μετρικών στο σύνολο αξιολόγησης - iTransformer	83
6.8	Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - iTransformer	83
6.9	Πίνακας μετρικών στα παράθυρα γεγονότων - iTransformer	83
7.1	Ενοποιημένος πίνακας μετρικών στα σύνολα αξιολόγησης για τα 4 μοντέλα	88

7.2	Ενοποιημένος πίνακας μετρικών στα παράθυρα γεγονότων για τα 4 μοντέλα	89
7.3	Ενοποιημένος πίνακας μετρικών ανά καθεστώς μεταβλητότητας για τα 5 μοντέλα	90

Συντομογραφίες

TTM	TinyTimeMixers
ARIMA	AutoRegressive Integrated Moving Average
LSTM	Long Short-Term Memory
ETF	Exchange Traded Fund
OHLCV	Open High Low Close Volume
ADF	Augmented Dickey–Fuller
ACF	Autocorrelation Function
PACF	Partial Autocorrelation Function

Κεφάλαιο 1

Εισαγωγή

Η πρόβλεψη των τιμών των μετοχών αποτελεί ένα μακροχρόνιο και κρίσιμο πρόβλημα τόσο στην ακαδημαϊκή έρευνα όσο και στην χρηματοοικονομική πρακτική. Η ικανότητα πρόβλεψης μελλοντικών κινήσεων τιμών μπορεί να προσφέρει σημαντικά πλεονεκτήματα στη διαχείριση χαρτοφυλακίου, στις αλγοριθμικές συναλλαγές και στην διαχείριση κινδύνου. Ωστόσο, οι χρηματοπιστωτικές αγορές επηρεάζονται από μια πληθώρα σύνθετων, δυναμικών και συχνά μη γραμμικών παραγόντων, καθιστώντας την πρόβλεψη των τιμών των μετοχών ένα εγγενώς δύσκολο έργο. Τα δεδομένα της αγοράς είναι συνήθως θορυβώδη, παρουσιάζουν χρονικές εξαρτήσεις και υπόκεινται σε απότομες διαρθρωτικές αλλαγές που προκαλούνται από μακροοικονομικά νέα, επενδυτικό κλίμα και απρόβλεπτα γεγονότα.

Τα δεδομένα τιμών μετοχών αποτελούν ένα κλασικό παράδειγμα χρονοσειράς, όπου οι παρατηρήσεις καταγράφονται διαδοχικά με την πάροδο του χρόνου. Η πρόβλεψη χρονοσειρών περιλαμβάνει τη μοντελοποίηση των χρονικών εξαρτήσεων εντός ιστορικών δεδομένων για την εκτίμηση μελλοντικών τιμών. Παραδοσιακά στατιστικά μοντέλα έχουν χρησιμοποιηθεί ευρέως για αυτόν τον σκοπό, ιδιαίτερα λόγω της ερμηνευσιμότητας και της απλότητας τους. Πιο πρόσφατα, οι τεχνικές μηχανικής μάθησης και βαθιάς μάθησης, έχουν δείξει πολλά υποσχόμενα αποτελέσματα στην καταγραφή πιο σύνθετων χρονικών μοτίβων.

Η ακριβής πρόβλεψη των τιμών των μετοχών παραμένει κεντρική πρόκληση στην χρηματοοικονομική ανάλυση λόγω της εγγενώς ασταθούς, μη γραμμικής και πολυμεταβλητής φύσης των χρηματοοικονομικών χρονοσειρών. Μοντέλα όπως το ARIMA, το LSTM και άλλες τεχνικές εποπτευόμενης μάθησης έχουν χρησιμοποιηθεί για την καταγραφή μοτίβων σε ιστορικά δεδομένα μετοχών. Ενώ αυτά τα μοντέλα έχουν επιδείξει ποικίλους βαθμούς επιτυχίας, συχνά απαιτούν μεγάλο αριθμό δεδομένων, σύνθετη επεξεργασία χαρακτηριστικών και

συχνή επανεκπαίδευση για να προσαρμοστούν στις μεταβαλλόμενες συνθήκες της αγοράς.

Τα τελευταία χρόνια, η εμφάνιση των θεμελιωδών μοντέλων (foundational models) έχει αποκτήσει μεγάλη δημοφιλία λόγω της επιτυχίας τους στην μοντελοποίηση φυσικής γλώσσας. Αυτή η επιτυχία οδήγησε ερευνητές και βιομηχανία στο να σχεδιάσουν τέτοιου τύπου μοντέλα και για άλλους τύπους δεδομένων. Στην περίπτωση των χρονοσειρών έχουν γίνει προσπάθειες όπως τα TimesFM [5], Chronos [6], TinyTimeMixers (IBM). Τα θεμελιώδη μοντέλα είναι προ-εκπαιδευμένα σε εκατοντάδες εκατομμύρια δείγματα χρονοσειρών από πολλούς διαφορετικούς τομείς. Τα θεμελιώδη μοντέλα είναι ελκυστικά για την μοντελοποίηση μετοχών επειδή, (i) μειώνουν την εξάρτηση από μεγάλα δείγματα για τον χρήστη, (ii) υποστηρίζουν εγγενώς πολυμεταβλητές εισόδους και εξωγενή σήματα και (iii) επιτρέπουν την ταχεία προσαρμογή σε νέες μετοχές μέσω βελτιστοποίησης λίγων δειγμάτων. Έως σήμερα δεν έχει μελετηθεί συστηματικά η απόδοσή τους σε χρηματοοικονομικές χρονοσειρές. Όμως, το χαρακτηριστικό των θεμελιωδών μοντέλων είναι πως όσο αυξάνεται ο αριθμός των παραμέτρων τους και όσο βλέπουν περισσότερα δείγματα τόσο καλύτερα γίνονται. Έτσι, δεν μπορεί να αποκλειστεί πως στο μέλλον μπορεί να υπάρξει μια παραδειγματική αλλαγή στην πρόβλεψη τέτοιων χρονοσειρών.

Μεταξύ αυτών, οι TinyTimeMixers (TTM) της IBM προσφέρουν μια ιδιαίτερα συναρπαστική προσέγγιση για την πρόβλεψη τιμών μετοχών. Το βασικό χαρακτηριστικό τους είναι πως χρειάζονται πολύ μικρή υπολογιστική δύναμη. Ένα σημαντικό πρόβλημα που αντιμετωπίζει η χρηματοοικονομική βιομηχανία είναι πως τα τωρινά μοντέλα, αν και πάρα πολύ επιτυχημένα, χρειάζονται πολλά δεδομένα και είναι πάρα πολύ απαιτητικά σε υπολογιστικούς και κατ'επέκταση ενεργειακούς πόρους. Ένα μοντέλο σαν το TTM θα μπορούσε στο μέλλον να λύσει αυτά τα προβλήματα.

1.1 Αντικείμενο της διπλωματικής

Τα θεμελιώδη μοντέλα για χρονοσειρές βρίσκονται σε πρώιμο στάδιο ανάπτυξης. Σκοπός της εργασίας αυτής είναι η εξέταση του αν ένα θεμελιώδες μοντέλο χρονοσειρών, στην προκειμένη περίπτωση το TTM, μπορεί να έχει επίδοση σε προβλέψεις τιμών μετοχών αντάξια κλασσικών μοντέλων και μοντέλων βαθιάς μάθησης, στην απλή τους μορφή. Η παραγωγή συγκρίσιμων προβλέψεων με αυτά τα μοντέλα, θα είναι ένδειξη πως τα θεμελιώδη μοντέλα χρονοσειρών μπορεί να έχουν προοπτική να υιοθετηθούν σε μεγαλύτερο εύρος εφαρμογών,

και μελλοντικές υλοποιήσεις τους ίσως να μπορέσουν να συγκριθούν με ακόμη πιο σύθετα μοντέλα της παραγωγής. Επειδή στο χρηματιστήριο υπάρχει μεγάλη ποικιλία μετοχών με διαφορετικά χαρακτηριστικά, έχει επιλεγεί ένα σύνολο δεδομένων που αντιπροσωπεύει διαφορετικά καθεστώτα μεταβλητότητας και διαφορετικές κλίμακες τιμών. Το TTM εξετάζεται σε σενάριο μηδενικής προσαρμογής και στην συνέχεια σε σενάρια εξειδικευμένης εκπαίδευσης. Για την εξειδικευμένη εκπαίδευση γίνεται μελέτη ως προς τον καλύτερο τρόπο με τον οποίο μπορεί να γίνει αυτή. Γενικώς, ο στόχος είναι να χρησιμοποιηθούν όσο το δυνατό λιγότερα δεδομένα χωρίς να θυσιάζεται η επίδοση. Τέλος, όπως ειπώθηκε, γίνεται μοντελοποίηση με το στατιστικό μοντέλο ARIMA και δύο μοντέλα βαθιάς μάθησης, το LSTM και τον iTransformer. Οι επιδόσεις του TTM συγκρίνονται με τις επιδόσεις αυτών των μοντέλων.

1.2 Οργάνωση του τόμου

Η εργασία αποτελείται από επτά κεφάλαια. Στο πρώτο γίνεται μια εισαγωγή και εξηγούνται οι στόχοι της εργασίας. Στο δεύτερο γίνεται αναφορά σε δημοσιεύσεις σχετικές με την εργασία. Το τρίτο αποτελεί το θεωρητικό υπόβαθρο, στο οποίο εξηγούνται όλες οι θεωρητικές έννοιες, η δομή των μοντέλων και άλλοι μαθηματικοί όροι που θα χρησιμοποιηθούν στην εργασία. Το τέταρτο κεφάλαιο αφορά την επιλογή, συλλογή, επεξεργασία και περιγραφή των δεδομένων. Στο πέμπτο κεφάλαιο διεξάγεται η μοντελοποίηση μηδενικής προσαρμογής του TTM και η εύρεση καλύτερου τρόπου εκπαίδευσης του. Αφού βρεθούν οι καλύτερες συνθήκες εκπαίδευσης, γίνονται μοντελοποιήσεις με την τελική, προσαρμοσμένη, μορφή του TTM. Στο έκτο κεφάλαιο γίνονται μοντελοποιήσεις με το ARIMA, το LSTM και τον iTransformer. Το έβδομο και τελευταίο κεφάλαιο περιέχει συγκεντρωτικά τα συμπεράσματα που προέκυψαν από την εργασία.

Κεφάλαιο 2

Συναφείς εργασίες

2.1 Εισαγωγή

Στο κεφάλαιο αυτό συνοψίζονται δημοσιεύσεις που εφαρμόζουν μοντέλα πρόβλεψης σε τιμές μετοχών ή/και χρηματιστηριακούς δείκτες. Παρουσιάζονται εργασίες κλασικών στατιστικών μέθοδοι ARIMA, βαθειάς μάθησης με LSTM, προσεγγίσεις με Transformers, συμπεριλαμβανομένου του iTransformer, καθώς και εργασιών θεμελιωδών μοντέλων χρονοσειρών.

2.2 Στατιστικές μέθοδοι

Το ARIMA είναι σημείο αναφοράς για βραχυπρόθεσμη πρόβλεψη χρηματιστηριακών χρονοσειρών χάρη στη διαφάνειά του και τη σχετικά απλή διαδικασία μοντελοποίησής του. Πρόσφατες εφαρμογές σε πραγματικά δεδομένα μετοχών επιβεβαιώνουν τη χρησιμότητά του. Ο Tiwary [7] εφαρμόζει το ARIMA στις μετοχές TSLA και NIO, κάνοντας βελτιστοποίηση των παραμέτρων (p, d, q) και αξιολόγηση με δείκτες όπως οι MSE και RMSE και δείχνει ότι το μοντέλο αυτό μπορεί να αποδώσει ικανοποιητικά σε βραχυπρόθεσμες προβλέψεις. Επιπλέον, η συγκριτική μελέτη των μοντέλων ARIMA και LSTM από τους Kobiela *et al.* [8], σε δεδομένα του χρηματιστηρίου NASDAQ, δείχνει ότι παρότι τα LSTM τείνουν να επιτυγχάνουν χαμηλότερα σφάλματα, το ARIMA παραμένει ανταγωνιστικό, ιδίως σε βραχυχρόνιους ορίζοντες και σε καλώς σταθμισμένα δεδομένα.

2.3 Βαθιά μάθηση

Τα LSTM έχουν χρησιμοποιηθεί εκτενώς για πρόβλεψη τιμών και τάσεων μετοχών και συχνά υπερέχουν έναντι κλασικών στατιστικών μεθόδων, ιδίως όταν υπάρχουν επαρκή ιστορικά δεδομένα. Μια καθαρά χρηματιστηριακή εφαρμογή παρουσιάζεται από τους Moghar & Hamiche (2020) [9], οι οποίοι αναπτύσσουν το μοντέλο LSTM για πρόβλεψη τιμών μετοχών και επιτυγχάνουν χαμηλά σφάλματα πρόβλεψης σε πραγματικά δεδομένα. Πιο πρόσφατα, οι Tran *et al.* (2024) [10] προβλέπουν την τάση των τιμών μετοχών του βιετναμέζικου χρηματιστηρίου (VN-Index, VN), χρησιμοποιώντας το LSTM σε συνδυασμό με τεχνικούς δείκτες (SMA, MACD, RSI) και επιτυγχάνοντας μεγάλη ακρίβεια στα περισσότερα σύνολα που εξετάζονται.

2.4 Transformers και iTransformer

Οι Transformers έχουν βρει ειδικές εφαρμογές σε χρηματιστηριακές σειρές. Το μοντέλο MASTER (Market-Guided Stock Transformer) [11] μοντελοποιεί χρονικές συσχετίσεις μεταξύ μετοχών για πρόβλεψη τιμών/τάσεων και εμφανίζει ανταγωνιστικές επιδόσεις σε χρηματιστηριακά σύνολα δεδομένων. Σχετικά με τον iTransformer, οι Liu *et al.* [2] δείχνουν ότι ο μηχανισμός «προσοχή ανά μεταβλητή» είναι πολύ αποτελεσματικός για την πρόβλεψη χρονοσειρών, ειδικά για χρονοσειρές με πολυμεταβλητή είσοδο.

2.5 Θεμελιώδη μοντέλα χρονοσειρών

Τα θεμελιώδη μοντέλα χρονοσειρών προεκπαιδούνται σε πολύ μεγάλες, ετερογενείς συλλογές χρονοσειρών και προσφέρουν δυνατότητες πρόβλεψης μηδενικής και μερικής προσαρμογής. Τα μοντέλα TimesFM και Chronos δημοσιεύτηκαν στα ICML 2024 [5] και TMLR 2024 [6] αντίστοιχα. Το TinyTimeMixer δημοσιεύθηκε στο NeurIPS 24 [3] από ομάδα της IBM research. Αν και μεγάλο μέρος της βιβλιογραφίας τους είναι γενικού σκοπού, εμφανίζονται πρώιμες εφαρμογές σε χρηματοοικονομικά δεδομένα, όπως στη μελέτη των Fu, Hirano και Imajo [12], όπου δείχνουν ότι ένα τροποποιημένο TimesFM έχει πολύ καλές επιδόσεις στους επενδυτικούς δείκτες Return, Max Drawdown και Sharpe ratio. Πρόσφατα ο Marconi [13] έκανε σύγκριση του Chronos με το TinyTimeMixer. Στη μελέτη αυτή αξιολογεί τα δύο θεμελιώδη μοντέλα χρονοσειρών σε τρεις χρηματοοικονομικές εργασίες πρόβλεψης: μετα-

βολές της απόδοσης του 10ετούς ομολόγου του αμερικανικού Δημοσίου, μεταβλητότητα του ζεύγους EUR/USD και πρόβλεψη spreads μετοχών.

Κεφάλαιο 3

Θεωρητικό υπόβαθρο

3.1 Εισαγωγή

Σε αυτό το κεφάλαιο ορίζονται οι βασικές θεωρητικές έννοιες της εργασίας. Περιγράφονται βασικές έννοιες του χρηματιστηρίου και των χρονοσειρών. Στη συνέχεια, παρουσιάζονται τα μοντέλα που θα χρησιμοποιηθούν για προβλέψεις. Τέλος, εξηγούνται οι μέθοδοι που θα χρησιμοποιηθούν για αποτίμηση των αποτελεσμάτων των μοντέλων αυτών.

3.2 Χρηματιστήριο

Η χρηματιστηριακή αγορά είναι μια αγορά όπου επενδυτές αγοράζουν και πωλούν μικρά μερίδια ιδιοκτησίας εταιριών, γνωστά ως μετοχές. Οι εταιρείες εισάγουν τις μετοχές τους σε οργανωμένα χρηματιστήρια, όπως το χρηματιστήριο της Νέας Υόρκης ή το Nasdaq, για να αντλήσουν κεφάλαια για ανάπτυξη. Φέρνοντας κοντά αγοραστές και πωλητές με διαφανείς διαδικασίες, η χρηματιστηριακή αγορά παρέχει ρευστότητα, η οποία επιτρέπει στους επενδυτές να μετατρέπουν τις μετοχές σε μετρητά με περιορισμένη καθυστέρηση, ασφάλεια και μικρό κόστος συναλλαγής.

Η εμπορική δραστηριότητα λαμβάνει χώρα σε δύο ευρείς τομείς. Η πρωτογενής αγορά είναι η αγορά στην οποία οι εταιρείες αντλούν νέα κεφάλαια πουλώντας μετοχές σε επενδυτές. Η δευτερογενής αγορά είναι η αγορά στην οποία οι υπάρχουσες μετοχές αλλάζουν χέρια μεταξύ των επενδυτών, με τις τιμές να προσαρμόζονται στις νέες πληροφορίες και στην ισορροπία προσφοράς και ζήτησης. Οι περισσότεροι άνθρωποι όταν χρησιμοποιούν τη λέξη χρηματιστήριο εννοούν την δευτερογενή αγορά.

Οι χρηματιστές και οι ειδικοί διαπραγματευτές διασφαλίζουν την ομαλή λειτουργία της αγοράς παρέχοντας συνεχείς τιμές και απορροφώντας τις πρόσκαιρες ανισορροπίες. Μετά την ολοκλήρωση μιας συναλλαγής, τα συστήματα εκκαθάρισης και διακανονισμού είναι υπεύθυνα για την ορθή μεταβίβαση των χρημάτων και της κυριότητας.

Όπως ειπώθηκε, μια μετοχή είναι μια ιδιόκτητη συμμετοχή στα περιουσιακά στοιχεία μιας εταιρείας, αλλά εκτός από την αγοραπωλησία μετοχών οι επενδυτές μπορούν να συμμετέχουν και με άλλους τρόπους στο χρηματιστήριο. Οι δείκτες της αγοράς, όπως ο S&P 500, είναι συγκεντρωτικοί δείκτες που συνοψίζουν την απόδοση ομάδων μετοχών. Οι επενδυτές μπορούν να συμμετέχουν στην αγορά αγοράζοντας χρηματιστηριακά αμοιβαία κεφαλαία (Exchange Traded Fund - ETF) που μετράνε την απόδοση δεικτών όπως ο S&P 500.

Οι τιμές αλλάζουν συνεχώς ανάλογα με την προσφορά και τη ζήτηση. Νέες πληροφορίες όπως αναφορές κερδών, οικονομικά δεδομένα, κινήσεις επιτοκίων ή εταιρικά νέα, μετατοπίζουν τις προσδοκίες των επενδυτών και, ως εκ τούτου, την τιμή που είναι διατεθειμένοι να πληρώσουν. Ενώ οι μετοχές έχουν ιστορικά προσφέρει ελκυστικές μακροπρόθεσμες αποδόσεις, είναι ασταθείς και μπορούν να παρουσιάζουν μεγάλες διακυμάνσεις, επομένως οι επενδυτές μπορεί να κερδίσουν ή να χάσουν χρήματα.

Η μεταβλητότητα είναι ένας δείκτης που μετρά πόσο έντονα αλλάζουν οι αποδόσεις μιας μετοχής ή ενός ETF. Ουσιαστικά, μας δείχνει το εύρος των διακυμάνσεων. Ως μέτρο χρησιμοποιείται συνήθως η τυπική απόκλιση των αποδόσεων, η οποία στη συνέχεια ετησιοποιείται (π.χ., πολλαπλασιάζοντας την ημερήσια τυπική απόκλιση με την τετραγωνική ρίζα του αριθμού των ημερών διαπραγμάτευσης). Υψηλότερη μεταβλητότητα σημαίνει ότι οι αποδόσεις είναι πιο ασταθείς, αλλά δεν μας λέει τίποτα για το αν η τιμή κινείται προς τα πάνω ή προς τα κάτω. Ο δείκτης Βήτα (Beta) δείχνει πόσο ευαίσθητη είναι η τιμή στις κινήσεις της αγοράς. Βοηθά τους επενδυτές να κατανοήσουν τον συστημικό κίνδυνο, δηλαδή τον κίνδυνο που επηρεάζει όλη την αγορά και δεν μπορεί να εξαιρεθεί με τακτικές όπως π.χ. διαφοροποίηση χαρτοφυλακίου.

3.3 Χρονοσειρές

Μια χρονοσειρά είναι μια ακολουθία παρατηρήσεων που ταξινομούνται με βάση τον χρόνο. Η σειρά με την οποία εμφανίζονται αυτές οι τιμές είναι πολύ σημαντική, γιατί η τιμή σε κάθε χρονική στιγμή επηρεάζεται από τιμές σε προηγούμενες χρονικές στιγμές. Για πα-

ράδειγμα, η σημερινή τιμή μιας μετοχής είναι πιθανό να επηρεαστεί από τη χθεσινή ή την προχθεσινή. Αυτή η εξάρτηση από το παρελθόν είναι το βασικό χαρακτηριστικό κάθε χρονοσειράς. Αντίθετα, σε άλλα είδη δεδομένων, όπως για παράδειγμα τα αποτελέσματα μιας δημοσκόπησης, κάθε παρατήρηση θεωρείται συνήθως ανεξάρτητη από τις άλλες.

Οι χρονοσειρές περιγράφονται από τέσσερα στοιχεία, την τάση, την εποχικότητα, τους κύκλους και τον θόρυβο. Η τάση είναι μια μακροπρόθεσμη, επίμονη ανοδική ή καθοδική κίνηση που εκδηλώνεται πιο αργά από τις καθημερινές διακυμάνσεις. Η εποχικότητα αναφέρεται σε συστηματικά μοτίβα που επαναλαμβάνονται με σταθερή συχνότητα. Οι κύκλοι είναι επαναλαμβανόμενες κινήσεις πάνω-κάτω που δεν συνδέονται με ένα σταθερό χρονικό διάστημα και επομένως ποικίλλουν σε μήκος και εύρος. Ο θόρυβος είναι η ακανόνιστη, απρόβλεπτη συνιστώσα που απομένει μετά την αφαίρεση των υπόλοιπων στοιχείων.

Στις χρηματιστηριακές χρονοσειρές υπάρχουν πολλές οικονομικές μεταβλητές που επηρεάζουν τις αποδόσεις, συμπεριλαμβανομένων των βραχυπρόθεσμων επιτοκίων, του πληθωρισμού, των μετρήσεων των οικονομικών συνθηκών κ.α. Επειδή αυτοί οι παράγοντες εξελίσσονται με την πάροδο του χρόνου, οι στατιστικές ιδιότητες των τιμών και των αποδόσεων είναι συχνά μη στάσιμες, γεγονός που έχει άμεσες επιπτώσεις στον σχεδιασμό και την αξιολόγηση μοντέλων. Στασιμότητα σημαίνει ότι η στατιστική συμπεριφορά μιας χρονοσειράς δεν αλλάζει με την πάροδο του χρόνου, δηλαδή ο μέσος όρος, η διακύμανση και η συσχέτιση των δεδομένων παραμένουν σταθερά, ανεξάρτητα από το πότε τα παρατηρούμε. Αυτή η ιδιότητα είναι ιδιαίτερα σημαντική, καθώς πολλά μοντέλα πρόβλεψης λειτουργούν βέλτιστα όταν τα δεδομένα είναι στάσιμα.

3.4 Δεδομένα και τεχνικοί δείκτες

Τα προϊόντα των χρηματιστηρίων αναγνωρίζονται από έναν σύντομο κωδικό (ticker) π.χ. AAPL για την Apple, MSFT για τη Microsoft, SPY για ένα ETF του S&P 500. Τα δεδομένα είναι στη μορφή Open, High, Low, Close, Volume (OHLCV). Το άνοιγμα (Open) είναι η τιμή της πρώτης συναλλαγής που γίνεται μετά το άνοιγμα του χρηματιστηρίου. Η υψηλότερη τιμή (High) είναι η υψηλότερη τιμή στην οποία πωλήθηκε μία μετοχή μέσα στην ημέρα και η χαμηλότερη τιμή (Low) είναι η χαμηλότερη τιμή στην οποία πωλήθηκε. Το κλείσιμο (Close) είναι η τιμή της τελευταίας συναλλαγής πριν από το κλείσιμο του χρηματιστηρίου. Τέλος, ο όγκος (Volume) είναι ο συνολικός αριθμός των μετοχών που συναλλάχθηκαν κατά τη διάρ-

κεια μίας ημέρας. Σε αυτήν την εργασία, όπως και στις περισσότερες μοντελοποιήσεις, η πρόβλεψη γίνεται στην τιμή κλεισίματος. Αυτή η επιλογή γίνεται γιατί η τιμή κλεισίματος λειτουργεί σαν μια περίληψη όλης της ημέρας. Στον Πίνακα 3.1 φαίνεται ένα στιγμιότυπο δεδομένων για την μετοχή της Apple Inc. (AAPL).

Ημερομηνία	Open	High	Low	Close	Volume
2010-01-04	6.42	6.46	6.39	6.44	493,729,600
2010-01-05	6.46	6.49	6.42	6.45	601,904,800
2010-01-06	6.45	6.48	6.34	6.35	552,160,000
2010-01-07	6.37	6.38	6.29	6.34	477,131,200
2010-01-08	6.33	6.38	6.29	6.38	447,610,800
2010-01-11	6.40	6.41	6.27	6.32	462,229,600

Πίνακας 3.1: Παράδειγμα δεδομένων από τη χρονοσειρά AAPL

Στην εργασία, εκτός από τα κλασσικά αυτά χαρακτηριστικά θα χρησιμοποιηθούν και τεχνικοί δείκτες. Οι τεχνικοί δείκτες είναι μαθηματικοί μετασχηματισμοί των τιμών και του όγκου που έχουν σχεδιαστεί για να συνοψίζουν μοτίβα και να βοηθούν στη λήψη αποφάσεων. Υπάρχουν πολλές κατηγορίες τεχνικών δεικτών. Οι δείκτες τάσης βοηθούν στον προσδιορισμό της κατεύθυνσης της αγοράς. Οι δείκτες ορμής μετρούν την ταχύτητα και την ισχύ των κινήσεων των τιμών. Οι δείκτες μεταβλητότητας μετρούν το πόσο γρήγορα και πόσο έντονα αλλάζουν οι τιμές. Οι δείκτες όγκου επικεντρώνονται στον όγκο συναλλαγών για να επιβεβαιώσουν την ισχύ μιας κίνησης τιμών. Στον Πίνακα 3.2 καταγράφονται οι δείκτες που θα χρησιμοποιηθούν:

Δείκτης	Κατηγορία	Περιγραφή
sma_20	τάσης	ο μέσος όρος των τελευταίων 20 κλεισιμάτων.
ema_20	τάσης	όπως ο SMA αλλά με μεγαλύτερο βάρος στις πιο πρόσφατες τιμές.
wma_20	τάσης	γραμμικές σταθμίσεις (η πιο πρόσφατη τιμή έχει το υψηλότερο βάρος).

Δείκτης	Κατηγορία	Περιγραφή
tema_20	τάσης	συνδυάζει EMA, διπλό EMA και τριπλό EMA για μείωση χρονοκαθυστερήσεων.
rsi_14	ορμής	ταλαντωτής ορμής (0–100)· >70 «υπεραγορασμένο», <30 «υπερπωλημένο».
stoch_k	ορμής	θέση του κλεισίματος μέσα στο πρόσφατο εύρος υψηλού–χαμηλού· >80 υψηλή ζώνη, <20 χαμηλή ζώνη.
cci_14	ορμής	απόκλιση της «τυπικής τιμής» από τον μέσο της· επίπεδα +100/–100 σηματοδοτούν ισχύ/αδυναμία.
bb_upper/bb_lower	μεταβλητότητας	Ζώνες Bollinger: περιβλήματα γύρω από έναν κινητό μέσο στις $\pm k$ τυπικές αποκλίσεις (συνήθως $k=2$).
atr_14	μεταβλητότητας	μέτρο μεταβλητότητας του τυπικού ημερήσιου εύρους.
obv	όγκου	αθροιστικός όγκος που προστίθεται στις ανοδικές ημέρες και αφαιρείται στις πτωτικές.
cmf_20	όγκου	σταθμισμένη (ως προς τον όγκο) πίεση αγορών έναντι πωλήσεων σε 20 περιόδους.

Πίνακας 3.2: Τεχνικοί δείκτες και περιγραφές

3.5 ARIMA

Το ARIMA είναι ένα από τα πιο γνωστά στατιστικά μοντέλα για πρόβλεψη χρονοσειρών. Η λέξη ARIMA είναι ακρωνύμιο που σημαίνει:

AR — AutoRegressive (Αυτοπαλίνδρομο): Το μοντέλο προβλέπει την τρέχουσα τιμή με βάση προηγούμενες τιμές της ίδιας χρονοσειράς, π.χ. αν η τιμή σήμερα μοιάζει με μέσο όρο των τιμών των τελευταίων 3 ημερών, τότε έχουμε AR(3).

I — Integrated (Ολοκληρωμένο): Αν η χρονοσειρά έχει τάση ή δεν είναι στάσιμη, παίρ-

νουμε διαφορές χρονικών τιμών. π.χ. κάθε μέρα οι τιμές αυξάνονται κατά 1, παίρνοντας τη διαφορά (σήμερα – χθες) παίρνουμε στάσιμη σειρά.

MA — Moving Average (Κινητός Μέσος): Το μοντέλο χρησιμοποιεί τα λάθη πρόβλεψης από προηγούμενες μέρες για να βελτιώσει την πρόβλεψη. π.χ. αν χθες κάναμε πρόβλεψη και πέσαμε έξω κατά +2, ίσως σήμερα πρέπει να διορθώσουμε προς τα κάτω.

Το μοντέλο γράφεται και ως $ARIMA(p, d, q)$, όπου, p ο αριθμός καθυστερήσεων στο AR μέρος (πόσες προηγούμενες τιμές λαμβάνουμε υπόψη), d ο αριθμός διαφορών (για να κάνουμε τη σειρά στάσιμη) και q ο αριθμός καθυστερήσεων στο MA μέρος (πόσα προηγούμενα σφάλματα λαμβάνουμε υπόψη).


Για τον έλεγχο στασιμότητας χρησιμοποιείται το ADF test (Augmented Dickey–Fuller test). Το τεστ αυτό βασίζεται στη λογική των στατιστικών υποθέσεων. Αν η σειρά δεν είναι στάσιμη, εφαρμόζεται διαφορική μετατροπή. Κάθε τιμή αντικαθίσταται με τη διαφορά της από την προηγούμενη τιμή. Στόχος είναι να βρεθεί το μικρότερο d που κάνει τη σειρά στάσιμη.

Η μελέτη για εύρεση παραμέτρων p (AR) και q (MA) γίνεται με τις συνάρτησεις ACF και PACF, οι οποίες μετράνε την ομοιότητα της σημερινής τιμής με παρελθοντικές τιμές. Η διαφορά τους είναι πως η ACF για να μετρήσει την ομοιότητα της σημερινής με μια παρελθοντική τιμή λαμβάνει υπόψη της την επίδραση όλων των ενδιάμεσων τιμών. Η PACF μετράει καθαρή συσχέτιση αγνοώντας τις ενδιάμεσες τιμές. Αν η τιμή της ACF είναι μεγάλη για τις πρώτες μέρες χρειάζονται όροι MA, και αντίστοιχα για την PACF χρειάζονται όροι AR.

Για να γίνει μελέτη των σφαλμάτων παράγονται οι στατιστικές (i) Ljung–Box: Έλεγχος αν τα υπόλοιπα έχουν αυτο συσχέτιση. (ii) Jarque–Bera: Έλεγχος αν η κατανομή των υπολοίπων είναι κανονική. (iii) Heteroskedasticity: Έλεγχος αν η διακύμανση των υπολοίπων είναι σταθερή στον χρόνο. (iv) Δείκτες προσαρμογής (AIC, BIC).

Επίσης, αν το μοντέλο είναι σωστά προσαρμοσμένο, τα υπόλοιπα πρέπει να μοιάζουν με λευκό θόρυβο. Για να εξεταστεί αυτό κατασκευάζονται τα διαγράμματα (i) Standardized residuals over time: Γραφική παράσταση των υπολοίπων στον χρόνο, (ii) Histogram & KDE plot: Ιστόγραμμα των υπολοίπων, με υπερτιθέμενη εκτίμηση πυκνότητας (KDE) και την καμπύλη κανονικής κατανομής $N(0, 1)$, (iii) Normal Q–Q plot: Σύγκριση της κατανομής των υπολοίπων με την ιδανική κανονική κατανομή και (iv) Autocorrelation (ACF των υπολοίπων): Αυτοσυσχετίσεις των υπολοίπων για διάφορες χρονοκαθυστερήσεις.

3.6 LSTM



Σχήμα 3.1: Δομή LSTM [1]

Τα δίκτυα Long Short-Term Memory (LSTM) είναι μια κατηγορία αναδρομικών νευρωνικών δικτύων σχεδιασμένη για τη μοντελοποίηση ακολουθιακών δεδομένων. Με την εισαγωγή μιας επίμονης κατάστασης κελιού (cell state) και πολλαπλασιαστικών πυλών (gates), τα LSTM επιτρέπουν την εκμάθηση εξαρτήσεων σε μεγάλους χρονικούς ορίζοντες, καθιστώντας τα κατάλληλα για πρόβλεψη χρονοσειρών, μοντελοποίηση γλώσσας, επεξεργασία ομιλίας και άλλες εργασίες σε ακολουθίες. Το LSTM μπορεί να έχει πολλαπλά επίπεδα για σύλληψη ιεραρχικών χρονικών χαρακτηριστικών. Το Σχήμα 3.1 δείχνει τη δομή του LSTM.

Στη χρονική στιγμή t , με είσοδο x_t , προηγούμενη κρυφή κατάσταση h_{t-1} και προηγούμενη κατάσταση κελιού c_{t-1} , το LSTM υπολογίζει:

$$\begin{aligned}
 f_t &= \sigma(W_f[x_t, h_{t-1}] + b_f) && \text{(forget gate),} \\
 i_t &= \sigma(W_i[x_t, h_{t-1}] + b_i) && \text{(input gate),} \\
 \tilde{c}_t &= \tanh(W_c[x_t, h_{t-1}] + b_c) && \text{(candidate state),} \\
 c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t && \text{(cell update),} \\
 o_t &= \sigma(W_o[x_t, h_{t-1}] + b_o) && \text{(output gate),} \\
 h_t &= o_t \odot \tanh(c_t) && \text{(hidden state).}
 \end{aligned}$$

Εδώ, σ είναι η λογιστική σιγμοειδής συνάρτηση και $\odot$ δηλώνει στοιχείο-κατά-στοιχείο πολλαπλασιασμό. Ο μηχανισμός των πυλών ρυθμίζει τη διατήρηση μνήμης, την εισροή πληροφορίας και την έκθεση της πληροφορίας, αντίστοιχα.

Για την πρόβλεψη χρονοσειρών η εκπαίδευση και οι προβλέψεις πρέπει να γίνουν σε ως ένα βαθμό στάσιμη χρονοσειρά. Το μοντέλο προβλέπει τον επόμενης ημέρας λογαριθμικό ημερήσιο δείκτη απόδοσης (log-return) της τιμής κλεισίματος:

$$r_t = \log(P_t) - \log(P_{t-1})$$

Η πρόβλεψη γίνεται σε επίπεδο return (όχι τιμής), και αργότερα μετατρέπεται σε τιμή. Με αυτόν τον τρόπο εξασφαλίζουμε κάποιο βαθμό στασιμότητας. Τα LSTM μπορεί να είναι απαιτητικά σε δεδομένα, υπολογιστικά βαριά και ευαίσθητα στις υπερπαραμέτρους, αλλά συλλαμβάνουν πολύ αποτελεσματικά μη γραμμικά χρονικά πρότυπα.

3.7 iTransformer

Ο Transformer είναι μια αρχιτεκτονική νευρωνικών δικτύων που βασίζεται στον μηχανισμό της αυτο/προσοχής (self-attention), ο οποίος επιτρέπει τον παραλληλισμένο υπολογισμό συμφραζομένων αναπαραστάσεων για όλα τα στοιχεία μιας ακολουθίας. Ο παραλληλισμός επιταχύνει την εκπαίδευση και τον καθιστά ιδιαίτερα αποτελεσματικό για τη μοντελοποίηση εξαρτήσεων. Η είσοδος αποτελείται από μια ακολουθία ενσωματώσεων διανυσμάτων (tokens) και κωδικοποιήσεων θέσης (positional embeddings). Οι διανυσματικές ενσωματώσεις είναι απλώς η ακολουθία που αναπαρίσταται σε μια αριθμητική μορφή που μπορεί να επεξεργαστεί το νευρωνικό δίκτυο. Οι κωδικοποιήσεις θέσης είναι διανυσματικές αναπαραστάσεις που περιέχουν πληροφορίες σχετικά με τη θέση κάθε σημείου στην ακολουθία εισαγωγής, σε σχέση με τα άλλα σημεία. Τα tokens συνδυάζονται με τα positional embeddings και περνάνε από τον μηχανισμό προσοχής.


Τα εμπλουτισμένα tokens κοιτάνε το ένα το άλλο για να αποφασιστεί που πρέπει να δοθεί προσοχή. Αυτό γίνεται μετασχηματίζοντας κάθε token σε queries Q , keys K και values V . Ο μηχανισμός προσοχής υπολογίζει σκορ ομοιότητας, τα περνάει από τη συνάρτηση softmax και υπολογίζει την προσοχή πολ/ζοντας με τα V

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V,$$

όπου d_k η διάσταση των keys. Πολλαπλές κεφαλές αυτής της διαδικασίας (MHSA, Multi-Head Self-Attention) επιτρέπουν στο μοντέλο να εστιάζει ταυτόχρονα σε διαφορετικούς τύπους σχέσεων.

Μετά την προσοχή, κάθε θέση περνά από ένα ίδιο για όλες τις θέσεις διστρωματικό πολυεπίπεδο πρόσθιο δίκτυο (position-wise FFN) που εφαρμόζει μη γραμμικό μετασχηματισμό. Κάθε υποστρώμα (attention ή FFN) πλαισιώνεται από συνδέσεις υπολοίπου και LayerNorm, κάτι που σταθεροποιεί και επιταχύνει την εκπαίδευση. Όταν απαιτείται αυστηρή αιτιότητα, εφαρμόζεται μάσκα (causal mask) ώστε οι υπολογισμοί να μην χρησιμοποιούν μελλοντικές θέσεις. Ανάλογα με το πρόβλημα, χρησιμοποιείται μόνο encoder (π.χ. για αναπαράσταση), μόνο decoder (αυτοπαλινδρομική πρόβλεψη) ή σχήμα encoder-decoder για ακολουθία-σε-ακολουθία. Οι αποκωδικοποιητές μπορούν να παράγουν είτε κατανομές πιθανότητας (για γλώσσα/ταξινόμηση) είτε συνεχείς τιμές μέσω κατάλληλου γραμμικού προβολέα (για παλινδρόμηση/χρονοσειρές).

Στις χρονοσειρές ο Transformer θεωρεί κάθε χρονικό βήμα ως token. Η αυτο-προσοχή υπολογίζεται κατά μήκος του χρόνου για να συλληφθούν χρονικές εξαρτήσεις. Για μήκος ακολουθίας T , η κλασική προσοχή έχει πολυπλοκότητα $O(T^2)$ σε χρόνο και μνήμη. Για προγνωστικά μοντέλα, οι αιτιοκρατικές μάσκες επιβάλλουν χρονική σειρά, ενώ οι κωδικοποιήσεις θέσης μπορούν να εκφράσουν εποχικότητα ή άλλα χρονικώς εξαρτώμενα σχήματα.



Σχήμα 3.2: Δομή Transformer και iTransformer [2]

Ο iTransformer (inverted Transformer) αντιστρέφει τους συνηθισμένους ρόλους του χρόνου και των μεταβλητών. Αντιμετωπίζει κάθε μεταβλητή/σειρά ως token και εφαρμόζει μηχανισμό self-attention μεταξύ μεταβλητών. Σε αντίθεση με έναν τυπικό Transformers, όπου


τα tokens είναι τα χρονικά βήματα και η προσοχή λειτουργεί κατά μήκος του χρόνου, εδώ η προσοχή συλλαμβάνει απευθείας τις δια-σειριακές αλληλεπιδράσεις και το χρονικό μοντέλο εφαρμόζεται χωριστά πάνω στον άξονα του χρόνου για καθεμία.

Επειδή αποφεύγεται η χρονική προσοχή με πολυπλοκότητα $O(T^2)$, η κλιμάκωση γίνεται κυρίως με τον αριθμό μεταβλητών, που συχνά είναι σημαντικά μικρότερος από το T . Στην πράξη, ο iTransformer ταιριάζει καλύτερα σε πολυμεταβλητές χρονοσειρές με μέτρια και μεγάλα χρονικά παράθυρα, ενώ είναι λιγότερο κατάλληλο για σειρές μιας μεταβλητής όπου δεν υπάρχει δια-σειριακή δομή προς αξιοποίηση. Στο σχήμα 3.2 φαίνονται οι αρχιτεκτονικές των Transformer και iTransformer.

3.8 TinyTimeMixers

Το TinyTimeMixer (TTM) είναι μια οικογένεια εξαιρετικά λιτών, προεκπαιδευμένων μοντέλων (pre-trained models) για πολυμεταβλητή πρόβλεψη χρονοσειρών, που αναπτύχθηκε από την IBM Research [3]. Μια σύνοψη της αρχιτεκτονικής του φαίνεται στο σχήμα 3.3. Το TTM στοχεύουν σε σενάρια μηδενικού δείγματος (zero-shot) και λίγων δειγμάτων (few-shot) όπου η ταχεία προσαρμογή και το χαμηλό υπολογιστικό κόστος είναι κρίσιμα. Σε αντίθεση με πολλές βασικές γραμμές δισεκατομμυρίων παραμέτρων, τα TTM επιτυγχάνουν ανταγωνιστική ακρίβεια με μοντέλα περίπου $\leq 1M$ παραμέτρων, επιτρέποντας εκτέλεση και λεπτο-προσαρμογή (fine-tuning) ακόμη και σε συστήματα μόνο με CPU. Τα βάρη και ο κώδικας χρήσης διατίθενται ανοικτά με άδεια Apache-2.0 στο Hugging Face.

Σε αρχιτεκτονικό επίπεδο, το TTM βασίζεται στο ελαφρύ πρότυπο TSMixer/MLP αντί των Transformers και εισάγει μηχανισμούς που βελτιώνουν τη μεταφορά γνώσης μεταξύ ετερογενών συνόλων δεδομένων όπως προσαρμοστικό επιμερισμό (adaptive patching), δειγματοληψία πολλαπλών αναλύσεων (diverse-resolution sampling) και προθεματική ρύθμιση ανάλυσης (resolution prefix-tuning). Η στρατηγική πολυεπίπεδης μοντελοποίησης υποστηρίζει τόσο προεκπαίδευση ανεξάρτητη ανά κανάλι (channel-independent pretraining) όσο και ανάμιξη καναλιών (channel-mixing) κατά τη λεπτο-προσαρμογή (fine-tuning), γεγονός που βοηθά στη σύλληψη συσχετίσεων μεταξύ μεταβλητών και στην ενσωμάτωση εξωγενών σημάτων. Οι σχεδιαστικές αυτές επιλογές αναφέρονται ότι προσφέρουν βελτιώσεις 4–40% σε σενάρια μηδενικού/λίγων δειγμάτων (zero/few-shot), ενώ μειώνουν σημαντικά τη μνήμη και τον χρόνο εκτέλεσης.



Σχήμα 3.3: Δομή του TTM από την δημοσίευση στο NeurIPS 2024 [3]

Από την πλευρά των εκδόσεων, το TTM ακολουθεί προσέγγιση εστιασμένης προεκπαίδευσης (focused pre-training), δηλαδή αντί για ένα γιγαντιαίο μοντέλο, προεκπαιδεύονται πολλαπλά μικροσκοπικά μοντέλα για συγκεκριμένα καθεστώτα πλαισίου–ορίζοντα (context–horizon regimes), π.χ. μήκη πλαισίου (context lengths) 512, 1024 και 1536 βημάτων. Η έκδοση r1 είναι εκπαιδευμένη σε 250M δείγματα ενώ η r2 επεκτάθηκε σε 700M δείγματα ($\approx 15\%+$ μέση βελτίωση έναντι της r1 σε τυπικά benchmarks), και η r2.1 κλιμακώθηκε σε 1B δείγματα επεκτείνοντας την υποστήριξη από λεπτομερές/ωριαίο ρυθμό δειγματοληψίας σε ημερήσιες/εβδομαδιαίες κλίμακες. Τα μοντέλα έχουν περίπου 805k παραμέτρους.

Στην πράξη, τα TTM χρησιμοποιούνται κυρίως για σημειακή πρόβλεψη, με εργαλειοθήκη που υποστηρίζει επίσης συναφείς εργασίες όπως ανίχνευση ανωμαλιών ή ταξινόμηση στο οικοσύστημα Granite Time Series. Οι προτεινόμενες πρακτικές περιλαμβάνουν άμεση εφαρμογή μηδενικού δείγματος (zero-shot) για γρήγορες γραμμές βάσης και ελαφριά λεπτοπροσαρμογή για βελτίωση ακρίβειας.

Τα TTM είναι άμεσα προσβάσιμα μέσω του πακέτου Python `granite-tsfm` (`granite-tsfm`) υπό τη μορφή του `TinyTimeMixerForecaster` (`TinyTimeMixerForecaster`), το οποίο διαθέτει

στρατηγικές εκμάθησης μηδενικού δείγματος, ελάχιστης και πλήρους προσαρμογής.

3.9 Μέθοδοι αξιολόγησης αποτελεσμάτων

3.9.1 Μετρικές αξιολόγησης

Για την μελέτη των επιδόσεων των μοντέλων υπολογίζονται τρεις μετρικές που μετράνε απόδοση ως προς τα σφάλματα και τέσσερις που μετράνε απόδοση ως προς την κατεύθυνση.

Μέσο Απόλυτο Σφάλμα (MAE)

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |\hat{y}_t - y_t|$$

Το MAE μετρά τον μέσο όρο της απόλυτης απόκλισης μεταξύ της προβλεπόμενης και της πραγματικής τιμής κλεισίματος. Παρέχει μια άμεση εκτίμηση της ακρίβειας σε επίπεδο δο-
λαρίου και αντικατοπτρίζει το τυπικό σφάλμα ανά πρόβλεψη.

Ρίζα Μέσου Τετραγωνικού Σφάλματος (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (\hat{y}_t - y_t)^2}$$

Το RMSE δίνει μεγαλύτερη βαρύτητα σε μεγάλα σφάλματα. Ενώ σχετίζεται με το MAE, ανα-
δεικνύει τις καταστροφικές αστοχίες του μοντέλου σε περιόδους έντονης μεταβλητότητας ή
αλλαγών τάσης.

Μέσο Απόλυτο Ποσοστιαίο Σφάλμα (MAPE)

$$\text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{\hat{y}_t - y_t}{y_t} \right|$$

Το MAPE εκφράζει το σφάλμα ως ποσοστό επί της πραγματικής τιμής, διευκολύνοντας τη
σύγκριση μεταξύ μετοχών διαφορετικής κλίμακας τιμών. Ένα σφάλμα 2% είναι αναλογικά
ισοδύναμο, ανεξαρτήτως απόλυτης τιμής της μετοχής.

Κατευθυντική Ακρίβεια (Hit Rate)

$$\text{Hit Rate} = \frac{1}{n} \sum_{t=1}^n \{\text{sign}(\hat{y}_t - y_{t-1}) = \text{sign}(y_t - y_{t-1})\}$$

Η κατευθυντική ακρίβεια μετρά εάν το μοντέλο προβλέπει σωστά την κατεύθυνση της μεταβολής τιμής (άνοδος ή πτώση). Πρόκειται για σημαντική μετρική σε χρηματοοικονομικές εφαρμογές, όπου η ορθότητα της κατεύθυνσης είναι συχνά σημαντικότερη από το ακριβές μέγεθος. Στην πράξη, ακρίβεια 55–60% είναι πολύ ισχυρή για την ημερήσια κατεύθυνση. Οτιδήποτε υψηλότερο για παρατεταμένη περίοδο είναι σπάνιο και συχνά υποδηλώνει υπερπροσαρμογή.

Precision, Recall και F1 Score Ορίζουμε ως θετική κλάση την ανοδική μεταβολή της τιμής (δηλαδή όταν $y_t > y_{t-1}$). Τότε:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Οι μετρικές αυτές περιγράφουν την ικανότητα του μοντέλου να ανιχνεύει ανοδικές τάσεις, όπου τιμές μεταξύ 0,55–0,60 θεωρούνται πολύ καλό σκορ. Τιμές πάνω από 0,65 είναι σπάνιο στις πραγματικές αγορές ειδικά για ερευνητικά μοντέλα:

- Υψηλό **Precision (ακρίβεια)** υποδηλώνει ότι το μοντέλο αποφεύγει ψευδή σήματα αγοράς.
- Υψηλό **Recall (πληρότητα)** σημαίνει ότι το μοντέλο εντοπίζει τις περισσότερες πραγματικές ανοδικές κινήσεις.
- Υψηλό **F1** αποτυπώνει ισορροπία μεταξύ ακρίβειας και πληρότητας.

Συλλογικά, το σύνολο των μετρικών επιτρέπει μια σφαιρική ερμηνεία της συμπεριφοράς του μοντέλου σε κάθε εκδοχή του, τόσο σε ομαλά όσο και σε ταραχώδη περιβάλλοντα.

3.9.2 Επενδυτική στρατηγική

Για να αξιολογηθεί αν οι προβλέψεις ενός μοντέλου για τη μεταβολή της τιμής μιας μετοχής έχουν πρακτική αξία, ορίζεται μια απλή επενδυτική στρατηγική συναλλαγών που μετατρέπει τις προβλέψεις σε αποδόσεις. Κάθε ημέρα το μοντέλο δίνει μια πρόβλεψη για το πρόσημο της μεταβολής της τιμής την επόμενη ημέρα. Αν η προβλεπόμενη μεταβολή είναι θετική, επιλέγεται θέση long (+1). Αν είναι αρνητική, επιλέγεται θέση short (−1).

Για παράδειγμα, αν σήμερα το μοντέλο προβλέπει άνοδο για αύριο επιλέγεται θέση +1. Αν αύριο η πραγματική μεταβολή είναι +1%, υπάρχει κέρδος +1%. Αν είχε προβλέψει πτώση

(−1%) και η αγορά ανέβαινε +1%, θα υπήρχε ζημιά −1%. Ακολουθώντας αυτή τη λογική για ένα μεγάλο χρονικό διάστημα κατασκευάζεται μια σωρευτική καμπύλη, η οποία ανεβαίνει όταν τα σήματα πέφτουν μέσα σε περιόδους με μεγάλες κινήσεις και βουτά όταν οι προβλέψεις είναι συστηματικά λάθος.

Για την κατανόηση των αποδόσεων της στρατηγικής σε κάποια μακρά χρονική περίοδο κατασκευάζονται διαγράμματα της σωρευτικής καμπύλης και υπολογίζονται τρεις μετρικές:

1. Sharpe ratio: μέση ημερήσια απόδοση της στρατηγικής διαιρεμένη με την τυπική απόκλιση των ημερήσιων αποδόσεων..
2. Συνολική απόδοση (Total/Cumulative Return): Εκφράζει πόσο κέρδος/ζημιά προέκυψε στο σύνολο της περιόδου.
3. Μέγιστο drawdown (MDD): η μεγαλύτερη ποσοστιαία πτώση της καμπύλης κεφαλαίου από ένα τοπικό υψηλό έως το επόμενο χαμηλό πριν επιτευχθεί νέο υψηλό. Μετρά το «χειρότερο λάκκο» που θα βίωνε ο επενδυτής.

3.9.3 Ανάλυση Συσχέτισης Μεταβλητότητας-Σφάλματος

Τέλος, εξετάζεται η στατιστική σχέση μεταξύ της μεταβλητότητας της αγοράς και του απόλυτου σφάλματος πρόβλεψης ανά μετοχή. Η διερεύνηση αυτή γίνεται μέσω διαγραμμάτων διασποράς όπου στον άξονα x απεικονίζεται η 5-ημερη κυλιόμενη μεταβλητότητα (ως τυπική απόκλιση των λογαριθμικών αποδόσεων) και στον άξονα y η απόλυτη τιμή του σφάλματος πρόβλεψης. Η μεταβλητότητα υπολογίζεται ως:

$$\sigma_t^{(5)} = \text{std} \left(\log \left(\frac{P_t}{P_{t-1}} \right) \right)_{t-4}^t$$

Το σφάλμα υπολογίζεται ως η απόλυτη απόκλιση μεταξύ της προβλεπόμενης τιμής κλεισίματος του μοντέλου και της πραγματικής τιμής.

$$\epsilon = |\hat{y}_t - y_t|$$

Κεφάλαιο 4

Προεπεξεργασία και εξερεύνηση δεδομένων

4.1 Εισαγωγή

Σε αυτό το κεφάλαιο περιγράφεται το πρόγραμμα λήψης δεδομένων και η διαδικασία προεπεξεργασίας, που αναλαμβάνουν αντίστοιχα τη μαζική λήψη ιστορικών τιμών μετοχών και το στήσιμο ενός καθαρού, ομογενοποιημένου συνόλου δεδομένων. Ακόμη, αιτιολογείται η επιλογή των μετοχών, που θα χρησιμοποιηθούν για εκπαίδευση και αξιολόγηση, με σκοπό να καλυφθούν διαφορετικά φαινόμενα της αγοράς. Τέλος, διεξάγεται μια απλή διερευνητική ανάλυση για να αναδειχθούν βασικά χαρακτηριστικά των δεδομένων.

4.2 Λήψη δεδομένων και προεπεξεργασία

Το πρόγραμμα λήψης δεδομένων είναι ένα μικρό πρόγραμμα Python σχεδιασμένο να απλοποιεί την απόκτηση ιστορικών χρονοσειρών τιμών μετοχών από την υπηρεσία Yahoo. Οι χρήστες παρέχουν μια περιγραφή των δεδομένων σε μορφή `.json` που καθορίζει τους κωδικούς των μετοχών και τα χρονικά διαστήματα που θέλει ο χρήστης. Στη συνέχεια, το πρόγραμμα ανακτά τα πεδία τιμών. Τα δεδομένα συλλέγονται σε `dataframes`, ένα για κάθε κωδικό.

Μόλις ληφθούν τα ακατέργαστα δεδομένα, το πρόγραμμα εναρμονίζει ασυνεπείς ονοματολογικές συμβάσεις και δομές σε μια ενιαία διάταξη έξι στηλών. Αυτό το σταθερό σχήμα διασφαλίζει ότι τα εργαλεία προεπεξεργασίας μπορούν να λειτουργήσουν χωρίς προβλή-

ματα. Κάθε χρονοσειρά γράφεται στον δίσκο ως ένα αρχείο .csv. Δημιουργούνται φάκελοι κατ' εντολή του χρήστη, οι αριθμητικές τιμές αποδίδονται με σταθερή ακρίβεια, και οι ημερομηνίες ακολουθούν το πρότυπο ISO.

Αφού ολοκληρωθούν όλες οι λήψεις, τα ακατέργαστα δεδομένα προωθούνται στον προεπεξεργαστή για να μετατραπούν στην τελική τους μορφή, η οποία θα χρησιμοποιηθεί στα πειράματα. Ο προεπεξεργαστής εκτελεί τέσσερις διαδικασίες:

1. Φόρτωση δεδομένων & βασική τακτοποίηση.
2. Προσαρμογή τιμών.
3. Δημιουργία ομοιόμορφου ημερολογίου.
4. Υπολογισμός λογαριθμικών αποδόσεων 1 ημέρας.

Πρώτα, διαβάζει τα αρχεία και μετατρέπει τη στήλη date σε τύπο datetime64 (YYYY-MM-DD), διότι οι συναρτήσεις ταξινόμησης, ταξινομούν από τα αριστερά προς τα δεξιά. Έπειτα την ορίζει ως δείκτη (dataFrame index), για να αξιοποιήσει τις δυνατότητες που παρέχουν οι δείκτες της βιβλιοθήκης pandas. Παρότι η Yahoo παρέχει υψηλής ποιότητας δεδομένα, πρέπει να είμαστε βέβαιοι ότι ο δείκτης έχει αυστηρή μονοτονία (συνεχώς αυξανόμενος χωρίς διπλότυπα). Για να εξασφαλιστεί η μονοτονία αυτή, εκτελείται ταξινόμηση βάσει του δείκτη και διαγράφονται τυχόν διπλές καταχωρήσεις.

Οι δημόσια καταχωρημένες εταιρείες, ιδίως οι μεγάλες που μελετώνται εδώ, συχνά πραγματοποιούν διασπάσεις μετοχών (πρωτογενής αγορά). Αυτό σημαίνει ότι αυξάνουν τον απόλυτο αριθμό των μετοχών τους χωρίς να αλλάζει η συνολική αξία της εταιρείας. Τέτοιες διασπάσεις δημιουργούν τεχνητά άλματα τιμών που παραπλανούν τα μοντέλα αλλά και τα μετρικά σφάλματος. Για παράδειγμα, μια διάσπαση 1-σε-4 οδηγεί σε πτώση 75% στην ακατέργαστη χρονοσειρά. Ένα προβλεπτικό μοντέλο μπορεί να το ερμηνεύσει ως κραχ στην αγορά με αποτέλεσμα τα μετρικά σφάλματος να αυξηθούν απότομα και το μοντέλο να μην γενικεύσει σωστά. Για να το αντιμετωπίσει αυτό, ο προεπεξεργαστής χρησιμοποιεί την προσαρμοσμένη τιμή κλεισίματος AdjClose που παρέχει η Yahoo, και υπολογίζει έναν παράγοντα με τον οποίο πολλαπλασιάζονται όλες οι στήλες:

$$\text{factor} = \frac{\text{AdjClose}}{\text{Close}},$$

$$\text{AdjOpen} = \text{factor} \times \text{Open}$$

$$\text{AdjHigh} = \text{factor} \times \text{High}$$

$$\text{AdjLow} = \text{factor} \times \text{Low}$$

Τα ακατέργαστα δεδομένα μπορεί να περιέχουν κενά για ορισμένες ημερομηνίες, τα οποία θα προκαλέσουν ασυμφωνίες κατά την εκπαίδευση μοντέλων. Για να το λύσει αυτό, ο προεπεξεργαστής δημιουργεί ένα ομοιόμορφο ημερολόγιο συναλλαγών από 2010-01-01 έως 2024-12-31. Έπειτα επαναδεικτοδοτεί (re-index) το dataframe στο νέο δείκτη, ώστε όλα τα σύνολα δεδομένων να έχουν ακριβώς τις ίδιες ημερομηνίες. Οι γραμμές για τις οποίες δεν υπήρχαν τιμές μετατρέπονται σε NaN. Επειδή μεγάλα τμήματα συνεχόμενων κενών είναι σπάνια, αρκεί να εφαρμοστεί ένα forward fill (όταν βρεις NaN, πάρε την τελευταία μη-NaN τιμή και αντέγραψε την) και στη συνέχεια backward fill (αν το σύνολο ξεκινάει με NaN, το forward fill δεν καλύπτει τις αρχικές απύσες τιμές), χωρίς φόβο να αλλάξει η κατανομή των τιμών. Τέλος, δημιουργεί μια καινούρια στήλη στην οποία υπολογίζει λογαριθμικές αποδόσεις κάθε ημέρας. Αυτή η στήλη χρησιμοποιείται για τον υπολογισμό τεχνικών δεικτών και για εκπαίδευση στα μοντέλα βαθειάς μάθησης.

4.3 Επισκόπηση συνόλου δεδομένων

4.3.1 Επιλογή Δεδομένων Μετοχών

Το σύνολο δεδομένων της μελέτης περιλαμβάνει επτά χρονοσειρές ημερήσιων τιμών μετοχών για την περίοδο 2010–2024. Οι κωδικοί που επιλέχθηκαν είναι: AAPL, TSLA, XOM, SPY, JNJ, AMD και PG. Κάθε χρονοσειρά περιλαμβάνει τις στήλες: date, open, high, low, close, adj_close και volume.


Η επιλογή των μετοχών σε αυτή τη μελέτη σχεδιάστηκε ώστε να διασφαλίζει μια ολοκληρωμένη αναπαράσταση του τοπίου της χρηματοοικονομικής αγοράς. Επιδιώκει να ισορροπήσει την ποικιλία κλάδων, τα καθεστώτα μεταβλητότητας και τους ρόλους τους στη δομή της αγοράς, παράγοντες που επηρεάζουν σημαντικά τη συμπεριφορά των χρονοσειρών και, κατ' επέκταση, την απόδοση των μοντέλων. Οι επιλεγμένες μετοχές καλύπτουν ένα ευρύ φάσμα οικονομικών ρόλων, επιτρέποντας πιο γενικεύσιμα και ερμηνεύσιμα συμπεράσματα μοντελοποίησης.

Οι AAPL (Apple Inc.) και TSLA (Tesla Inc.) επιλέχθηκαν για να εκπροσωπήσουν το τμήμα τεχνολογίας υψηλής ανάπτυξης, αλλά καταλαμβάνουν διαφορετικές θέσεις εντός αυτού. Η AAPL είναι μια ώριμη, με παγκόσμια επιρροή εταιρεία, με σταθερά κέρδη, ευρύ οικοσύστημα προϊόντων και μακροχρόνια παρουσία στον δείκτη S&P 500. Η συμπεριφορά της χαρακτηρίζεται από μέτρια μεταβλητότητα και συνεχή ανάπτυξη. Αντιθέτως, η TSLA είναι ένα χαρακτηριστικό παράδειγμα μετοχής υψηλού βήτα. Εμφανίζει διακυμάνσεις μεγαλύτερες από την αγορά ως απάντηση σε οικονομικά νέα ή μεταβολές στη διάθεση των επενδυτών. Αυτό οφείλεται στην υποθετική της αξία, την ταχεία επέκταση και την ευαισθησία σε καινοτομία των ανταγωνιστών.

Οι XOM (Exxon Mobil), JNJ (Johnson & Johnson) και PG (Procter & Gamble) επιλέχθηκαν για να καλύψουν κυκλικές και αμυντικές μετοχές. Η XOM δραστηριοποιείται στον ενεργειακό τομέα, όπου τα έσοδα και οι τιμές συνδέονται στενά με τις διεθνείς αγορές εμπορευμάτων και γεωπολιτικές εξελίξεις. Είναι κυκλική μετοχή, δηλαδή στενά συνδεδεμένη με την μακροοικονομική πορεία της οικονομίας, που αποδίδει καλά σε περιόδους οικονομικής ανάπτυξης και συρρικνώνεται σε υφέσεις. Αντίθετα, οι JNJ και PG θεωρούνται αμυντικές μετοχές, δηλαδή παρέχουν βασικά αγαθά και υπηρεσίες με σταθερά έσοδα ανεξάρτητα από τις ευρύτερες συνθήκες.

Ο SPY είναι ένα ETF που παρακολουθεί την απόδοση του S&P 500, ενός δείκτη που μετράει την απόδοση 500 μεγάλων εταιρειών των ΗΠΑ. Χρησιμοποιείται ευρέως στην ακαδημαϊκή χρηματοοικονομική και στην πρακτική διαχείριση κεφαλαίου, διότι αντικατοπτρίζει τη συνολική κίνηση της αγοράς. Η επιλογή της επιτρέπει να αξιολογηθεί η απόδοση των μοντέλων στο σύνολο της αγοράς.


Τέλος, η AMD επιλέχθηκε για να εκπροσωπήσει τον κλάδο των ημιαγωγών, γνωστός για την κυκλικότητα και την υψηλή μεταβλητότητά του. Η τιμή της μετοχής της διακυμαίνεται σημαντικά λόγω της γρήγορης εξέλιξης της τεχνολογίας των ημιαγωγών, προβλημάτων στην εφοδιαστική αλυσίδα και έντονου ανταγωνισμού. Αυτά τα χαρακτηριστικά την καθιστούν ιδανική για έλεγχο αντοχής των προβλεπτικών μοντέλων. Με την προσθήκη της AMD, αξιολογείται η ικανότητα ενός μοντέλου να προσαρμόζεται σε αιχμηρές μεταβολές και σύνθετες συμπεριφορές τιμών, που σπάνια συναντώνται σε άλλους κλάδους. Στα διαγράμματα 4.1 - 4.7 παρουσιάζεται η εξέλιξη της τιμής κλεισίματος των επτά χρονοσειρών.




Σχήμα 4.1: Τιμές κλεισίματος της AAPL στην περίοδο 2010-2025



Σχήμα 4.2: Τιμές κλεισίματος της TSLA στην περίοδο 2010-2025




Σχήμα 4.3: Τιμές κλεισίματος της XOM στην περίοδο 2010-2025




Σχήμα 4.4: Τιμές κλεισίματος της SPY στην περίοδο 2010-2025



Σχήμα 4.5: Τιμές κλεισίματος της JNJ στην περίοδο 2010-2025



Σχήμα 4.6: Τιμές κλεισίματος της AMD στην περίοδο 2010-2025




Σχήμα 4.7: Τιμές κλεισίματος της PG στην περίοδο 2010-2025

Συνολικά, ο συνδυασμός αυτός διασφαλίζει ότι τα πειράματά θα καλύψουν ένα ευρύ και ρεαλιστικό φάσμα χρηματοοικονομικών συνθηκών, επιτρέποντάς την διερεύνηση δυνατών και αδύναμων σημείων των μοντέλων σε πλαίσια (i) σταθερότητας VS μεταβλητότητας, (ii) κυκλικότητας VS αμυντικότητας και (iii) επιπέδου εταιρίας VS επιπέδου αγοράς.


4.3.2 Περίοδοι σημαντικών γεγονότων

Από κάθε σύνολο δεδομένων επιλέγεται ένα υποσύνολο, το οποίο αναδεικνύει ενδιαφέρουσες περιπτώσεις που δοκιμάζουν διαφορετικές πτυχές της γενίκευσης των μοντέλων. Ακολουθεί η περιγραφή κάθε γεγονότος, η χρηματοοικονομική του σημασία και ο τρόπος με τον οποίο δοκιμάζει τα προβλεπτικά συστήματα.

AAPL – Κατάρρευση & Ανάκαμψη (2020-03-10): (Σχήμα 4.8) Αυτό το παράθυρο αποτυπώνει την βίαιη αντίδραση της αγοράς στην εμφάνιση της πανδημίας COVID-19. Η AAPL γνώρισε απότομη πτώση στις αρχές Μαρτίου 2020 λόγω του παγκόσμιου πανικού και του lockdown. Ακολούθησε ταχεία ανάκαμψη λόγω στροφής των επενδυτών στην τεχνολογία. Αυτό το σχήμα-V δοκιμάζει την ικανότητα ενός μοντέλου να ανταποκρίνεται σε ταχείες αλλαγές μεταβλητότητας.




(α) ορίζοντας 2010-2025




(β) ορίζοντας 09/2019-06/2020

Σχήμα 4.8: AAPL – Κατάρρευση & Ανάκαμψη (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 09/2019-06/2020

TSLA – Πάγωμα υψηλού βήτα (2021-01-15): (Σχήμα 4.9) Μετά από παραβολική άνοδο το 2020, η TSLA εισήλθε στις αρχές του 2021 σε φάση υψηλής αλλά μη κατευθυνόμενης μεταβλητότητας. Η τιμή διακυμαινόταν σε μεγάλο εύρος. Αυτό το φαινόμενο δείχνει τι συμβαίνει όταν μια μετοχή υψηλού βήτα χάνει ορμή και οι επενδυτές απομακρύνονται από τα κερδοσκοπικά ονόματα.




(α) ορίζοντας 2010-2025




(β) ορίζοντας 07/2020-07/2021

Σχήμα 4.9: TSLA – Πάγωμα υψηλού βήτα (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 07/2020-07/2021

XOM – Κορυφή Πετρελαϊκού Κύκλου (2022-06-01): (Σχήμα 4.10) Αναπαριστά την κορύφωση του ράλλυ πετρελαίου μετά την πανδημία, όταν οι τιμές εκτοξεύτηκαν λόγω γεωπολιτικών εντάσεων (π.χ. πόλεμος στην Ουκρανία) και στη συνέχεια κανονικοποιήθηκαν. Η μετοχή της XOM ακολούθησε αυτό το μοτίβο. Οι μοντελοποιήσεις δυσκολεύονται από εξαρτήσεις σε εξωγενείς παράγοντες και από απότομες μεταβάσεις, για αυτό το υποσύνολο είναι ιδανικό τεστ ανίχνευσης αλλαγής κατάστασης στην αγορά.




(α) ορίζοντας 2010-2025




(β) ορίζοντας 11/2021-09/2022

Σχήμα 4.10: XOM – Κορυφή Πετρελαϊκού Κύκλου (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 11/2021-09/2022

SPY – Πτώση με πλάγια/αιρετική κίνηση (2022-09-15): (Σχήμα 4.11) Μέσα στο 2022, ο S&P 500 μπήκε σε παρατεταμένη φάση πτώσης χωρίς σαφή κατεύθυνση. Σε αντίθεση με ξαφνικά κραχ ή ράλλυ, εδώ επικρατούσε χαμηλή ορμή και μακροοικονομική αβεβαιότητα (π.χ. πληθωριστικές πιέσεις, αυξήσεις επιτοκίων), δημιουργώντας θορυβώδη κίνηση με ημερήσιες αναστροφές. Τέτοιες περιόδους είναι δύσκολο να προβλεφθούν, καθώς ο λόγος σήματος-θορύβου είναι εξαιρετικά χαμηλός.




(α) ορίζοντας 2010-2025




(β) ορίζοντας 01/2022-01/2023

Σχήμα 4.11: SPY – Πτώση με πλάγια/αιρετική κίνηση (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 01/2022-01/2023

JNJ – Συνεχής ανθεκτικότητα (2019-08-01): (Σχήμα 4.12) Αυτή η φάση δείχνει τη JNJ να κινείται σε στενό εύρος τιμών, με ελάχιστη μεταβλητότητα για μεγάλο διάστημα. Οι αμυντικές μετοχές, όπως η JNJ, παραμένουν σταθερές σε περιόδους αβεβαιότητας χάρη στον ρόλο τους στην υγεία και τη χαμηλή ζήτηση. Το φαινόμενο αυτό δοκιμάζει τα μοντέλα όχι με πολυπλοκότητα αλλά με στασιμότητα — πώς αποφεύγουν να «φανταστούν» σήματα εκεί όπου δεν υπάρχουν.




(α) ορίζοντας 2010-2025




(β) ορίζοντας 11/2018-01/2020

Σχήμα 4.12: JNJ – Συνεχής ανθεκτικότητα (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 11/2018-01/2020

AMD – Μαζική ρευστοποίηση στον τεχνολογικό τομέα (2018-10-10): (Σχήμα 4.13) Περίοδος ευρείας υποτίμησης των τεχνολογικών μετοχών υπό την πίεση ανησυχιών για αυξήσεις επιτοκίων και γενικό κλίμα κινδύνου. Η τιμή της AMD κατέρρευσε απότομα, απεικονίζοντας συνδεδεμένη πώληση σε high-beta τεχνολογία. Η φάση αυτή δοκιμάζει την ικανότητα ανίχνευσης τομεακών σοκ και γρήγορων μεταβάσεων συσχετίσεων.




(α) ορίζοντας 2010-2025




(β) ορίζοντας 05/2018-03/2019

Σχήμα 4.13: AMD – Μαζική ρευστοποίηση στον τεχνολογικό τομέα (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 05/2018-03/2019

PG – Ανεξαρτησία από μακροοικονομικά γεγονότα (2015-06-15): (Σχήμα 4.14) Παρουσιάζει τη συμπεριφορά μιας μετοχής καταναλωτικών αγαθών σε περίοδο εξαιρετικά χαμηλής μεταβλητότητας και θορύβου. Η PG κινήθηκε σε στενό εύρος για εβδομάδες ολόκληρες χωρίς να ανταποκριθεί σε ευρύτερα γεγονότα. Τέτοια παράθυρα είναι κρίσιμα για την αξιολόγηση της συντηρητικότητας του μοντέλου.



(α) ορίζοντας 2010-2025



(β) ορίζοντας 01/2015-01/2016

Σχήμα 4.14: PG – Ανεξαρτησία από μακροοικονομικά γεγονότα (α) στον ορίζοντα 2010-2025 (β) στον ορίζοντα 01/2015-01/2016

Κεφάλαιο 5

Αξιολόγηση μηδενικής προσαρμογής και βελτιστοποίηση TTM

5.1 Εισαγωγή

Σε αυτό το κεφάλαιο αξιολογείται το TTM σε σενάριο μηδενικής προσαρμογής (zero-shot), εξετάζονται οι βέλτιστες συνθήκες εκπαίδευσης (finetune) και αποτιμάται η απόδοση του βελτιστοποιημένου μοντέλου. Παρουσιάζονται πίνακες και διαγράμματα για το TTM μηδενικής προσαρμογής, διερευνάται το ιδανικό ποσοστό εκπαίδευσης και εξετάζεται το κατά πόσο η γνώση που αποκτάται από την εκπαίδευση σε μία μετοχή μπορεί να μεταφερθεί στην πρόβλεψη άλλων μετοχών. Στη συνέχεια, γίνεται ανάλυση ως προς την βελτιστοποίηση των υπερπαραμέτρων και αξιολογείται η σημαντικότητα των χαρακτηριστικών. Από τα αποτελέσματα αυτών των πειραμάτων παράγεται ένα βελτιστοποιημένο, ως προς την πρόβλεψη μετοχών, μοντέλο TTM, το οποίο αποτιμάται στην τελευταία ενότητα του κεφαλαίου.

5.2 Υλοποίηση TTM στην python

Η υλοποίηση του TTM μπορεί να βρεθεί στην βιβλιοθήκη `granite-tsfm`. Στην εργασία χρησιμοποιείται η 2η έκδοση του TTM, `ibm-granite/granite-timeseries-ttm-r2`. Η διαδικασία εκπαίδευσης και αξιολόγησης έχει ως εξής. Κατ' αρχάς ορίζονται οι στήλες χρονοσήμανσης (`date`), στόχου (`close`) και τα χαρακτηριστικά εισόδου, OHLV και τεχνικοί δείκτες. Στη συνέχεια, τα δεδομένα διοχετεύονται στον προεπεξεργαστή (`Time SeriesPreprocessor`), ο οποίος εφαρμόζει κανονικοποίηση, ορίζει παράθυρο ιστορι-

κού 512 ημερών και θέτει τον ορίζοντα πρόβλεψης σε 1 ημέρα.

Με την συνάρτηση `.from_pretrained()` φορτώνεται το προεκπαιδευμένο μοντέλο TTM. Τα δεδομένα διαχωρίζονται σε σύνολα εκπαίδευσης και αξιολόγησης με την συνάρτηση `.get_datasets()`. Από εδώ και πέρα, στην περίπτωση μηδενικής προσαρμογής, παράγονται απευθείας αποτελέσματα.

Για εξειδικευμένη εκπαίδευση, ορίζονται ο ρυθμός μάθησης, ο αριθμός των εποχών και το μέγεθος παρτίδας. Στη συνέχεια, δημιουργείται ένα αντικείμενο `TrainingArguments` που συγκεντρώνει όλες τις υπερπαραμέτρους. Ως βελτιστοποιητής χρησιμοποιείται ο Adam. Το προεκπαιδευμένο μοντέλο, τα `TrainingArguments`, ο βελτιστοποιητής και το σύνολο εκπαίδευσης δίνονται ως είσοδοι στον `Trainer`. Η συνάρτηση `.train()` εκτελεί τη διαδικασία εκπαίδευσης.

Ο προεκπαιδευμένος κορμός (backbone) του TTM διατηρείται παγωμένος και η εκπαίδευση γίνεται μόνο στην κεφαλή πρόβλεψης (head). Έτσι, μειώνεται ο αριθμός εκπαιδευσιμων παραμέτρων, ο κίνδυνος υπερπροσαρμογής και ο χρόνος σύγκλισης. Σε όλα τα πειράματα παρατηρήθηκε πως μετά από 5 εποχές δεν γίνονται σημαντικές αλλαγές στο αποτέλεσμα.

Σε όλα τα πειράματα που θα ακολουθήσουν, ως σύνολο αξιολόγησης επιλέγεται το τελευταίο 40% του κάθε συνόλου δεδομένων, δηλαδή η περίοδος 03/2019 - 12/2024.

5.3 Αποτελέσματα TTM μηδενικής προσαρμογής

Ο Πίνακας 5.1 συνοψίζει την επίδοση του μοντέλου ανά μετοχή στο σύνολο αξιολόγησης. Η TSLA είναι σαφής ακραία περίπτωση, με πολύ υψηλά σφάλματα (MAE 119,10, RMSE 139,26, MAPE 60,99), ένδειξη ότι το μοντέλο δεν αποτυπώνει την έντονη μεταβλητότητά της. Αντίθετα, οι JNJ και PG εμφανίζουν χαμηλά σφάλματα. Το SPY έχει σχετικά υψηλά MAE/RMSE (34,58/39,03), αλλά πολύ χαμηλό MAPE (2,61%), άρα καλή ποσοστιαία επίδοση λόγω υψηλότερης κλίμακας τιμών. Στις κατευθυντικές μετρικές οι επιδόσεις είναι γενικά μέτριες. Ξεχωρίζουν το SPY ($F1=0,547$) και η JNJ (Hit Rate=0,501).

Για μια συνολικότερη εικόνα της επίδοσης ανά καθεστώς μεταβλητότητας, τα αποτελέσματα ομαδοποιούνται και παρουσιάζονται στον Πίνακα 5.2. Στο καθεστώς Υψηλής Μεταβλητότητας (TSLA, AMD) καταγράφονται τα μεγαλύτερα σφάλματα. Παρότι οι κατευθυντικές μετρικές καταγράφονται σε επίπεδα συγκρίσιμα με τα υπόλοιπα καθεστώτα (Hit Rate

0,4787, F1 0,5121), το μέγεθος των σφαλμάτων δεν αντισταθμίζεται. Στο καθεστώς Χαμηλής Μεταβλητότητας (JNJ, PG) επιτυγχάνεται αισθητά καλύτερη επίδοση (MAE 8,47, MAPE 6,05%). Μετά από Αντιστροφή Τάσης (AAPL, XOM) τα σφάλματα παρατηρούνται σε ενδιάμεσα επίπεδα (MAE 21,54, MAPE 17,45%). Τέλος, στο καθεστώς Πλάγιας/Ακατάστατης Κίνησης (SPY) καταγράφονται σχετικά υψηλά MAE/RMSE (47,75/52,59), ενώ επιτυγχάνεται το υψηλότερο συνολικό F1 (0,5365).

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	19,34	21,23	14,69	0,466	0,505	0,546	0,524
TSLA	119,10	139,26	60,99	0,485	0,511	0,512	0,511
XOM	6,96	7,81	10,86	0,483	0,490	0,505	0,497
SPY	34,58	39,03	2,61	0,484	0,528	0,555	0,547
JNJ	4,42	4,90	3,10	0,501	0,518	0,517	0,517
AMD	14,31	16,74	16,42	0,479	0,478	0,511	0,493
PG	7,24	8,01	5,77	0,473	0,518	0,527	0,518

Πίνακας 5.1: Πίνακας μετρικών στο σύνολο αξιολόγησης - TTM μηδενικής προσαρμογής

Regime Type	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
High-Volatility	81,29	96,16	52,20	0,4787	0,4912	0,5361	0,5121
Low-Volatility	8,47	9,15	6,05	0,4828	0,5083	0,5237	0,5202
Post-Trend Reversal	21,54	23,84	17,45	0,4776	0,5086	0,5511	0,5077
Sideways/Chop	47,75	52,59	12,07	0,4766	0,5214	0,5525	0,5365

Πίνακας 5.2: Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - TTM μηδενικής προσαρμογής

Στον Πίνακα 5.3 παρουσιάζονται τα αποτελέσματα των μετρικών στα παράθυρα γεγονότων. Η TSLA εξακολουθεί να ξεχωρίζει με πολύ υψηλό MAPE (70,23%). Το SPY εμφανίζει σημαντική αύξηση στο σφάλμα (RMSE 41,47). Οι JNJ, PG και XOM διατηρούν σχετικά χαμηλά σφάλματα. Οι κατευθυντικές μετρικές παραμένουν κοντά στις τιμές του συνόλου αξιολόγησης, με το υψηλότερο F1 να καταγράφεται στην XOM (0,557).

Στα παρακάτω διαγράμματα φαίνεται μια ενδεικτική οπτικοποίηση των αποτελεσμάτων με προβλέψεις της τιμής κλεισίματος των AAPL (Σχήμα 5.1) και TSLA (Σχήμα 5.2).

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	8,45	9,08	12,73	0,436	0,487	0,557	0,520
TSLA	137,13	148,67	70,23	0,431	0,461	0,437	0,449
XOM	7,83	8,25	10,76	0,497	0,543	0,570	0,557
SPY	36,71	41,47	9,12	0,479	0,414	0,444	0,429
JNJ	4,36	4,98	3,36	0,475	0,511	0,497	0,504
AMD	8,26	8,86	13,39	0,488	0,536	0,576	0,555
PG	8,09	8,67	6,68	0,492	0,529	0,537	0,559

Πίνακας 5.3: Πίνακας μετρικών στα παράθυρα γεγονότων - TTM μηδενικής προσαρμογής




Σχήμα 5.1: Πρόβλεψη μηδενικής προσαρμογής στο σύνολο αξιολόγησης της AAPL



Σχήμα 5.2: Πρόβλεψη μηδενικής προσαρμογής στο σύνολο αξιολόγησης της TSLA

Τέλος υπολογίζεται η σχέση μεταξύ βραχυπρόθεσμης μεταβλητότητας και απόλυτου σφάλματος πρόβλεψης αποτυπώνεται ενδεικτικά στα παρακάτω διαγράμματα. Στον άξονα x παρουσιάζεται η 5-ήμερη κυλιόμενη μεταβλητότητα και στον άξονα y απεικονίζεται το απόλυτο σφάλμα· κάθε σημείο αντιστοιχίζεται σε μία χρονική στιγμή πρόβλεψης. Για την TSLA (Σχήμα 5.3) καταγράφονται πολύ μεγάλα σφάλματα ακόμη και σε χαμηλές τιμές μεταβλητότητας. Στις AAPL, SPY και AMD τα σφάλματα παρατηρούνται περίπου στο 1/3 των αντίστοιχων της TSLA για συγκρίσιμα επίπεδα. Στις JNJ, PG και XOM διαπιστώνεται ευνοϊκή σχέση μεταβλητότητας–σφάλματος, με χαμηλά σφάλματα σε όλο το εύρος.



Σχήμα 5.3: Σχέση κυλιόμενης μεταβλητότητας/σφάλματος για την TSLA- Πρόβλεψη μηδενικής προσαρμογής

Τα παραπάνω αποτελέσματα αναδεικνύουν πως το απλό προεκπαιδευμένο μοντέλο TTM, όταν αυτό εφαρμόζεται για την πρόβλεψη χρονοσειρών μετοχών, έχει πολύ χαμηλές επιδόσεις. Η ανάγκη για εξειδικευμένη προσαρμογή σε δεδομένα μετοχών είναι εμφανής. Αλλά για την προσαρμογή αυτή υπάρχουν πολλές παράμετροι οι οποίες πρέπει να επιλεγθούν κατάλληλα. Στις ενότητες που θα ακολουθήσουν γίνεται ανάλυση για την σωστή επιλογή των παραμέτρων αυτών.

5.4 Εύρεση καλύτερου ποσοστού εκπαίδευσης

Όπως έδειξε η προηγούμενη ενότητα, το TTM μηδενικής προσαρμογής εμφανίζει πολύ μεγάλα σφάλματα, ειδικά σε καθεστώτα υψηλής μεταβλητότητας. Στα πειράματα που θα ακολουθήσουν σε αυτό το κεφάλαιο θα βρεθούν οι κατάλληλες συνθήκες για την προσαρμογή αυτή. Όπως ειπώθηκε σε προηγούμενα κεφάλαια, η κύρια δυνατότητα που δίνουν τα θεμελιώδη μοντέλα είναι η δυνατότητα προβλέψεων με καθόλου ή με ελάχιστα δεδομένα. Για να αξιοποιηθεί η δυνατότητα αυτή, ως στόχος των επόμενων πειραμάτων τίθεται η παραγωγή ενός ειδικά εκπαιδευμένου μοντέλου TTM, το οποίο έχει όσο το δυνατό μεγαλύτερη ικανότητα γενίκευσης με όσο το δυνατό λιγότερα δεδομένα μετοχών.


Στο παρόν πείραμα διερευνάται πώς επηρεάζεται το μοντέλο όσο αυξάνεται το ποσοστό του συνόλου δεδομένων που διατίθεται για εκπαίδευση. Η διαδικασία που ακολουθείται έχει ως εξής: (i) Διαβάζεται το σύνολο δεδομένων μιας μετοχής (π.χ. της AAPL). Αυτό το σύνολο δεδομένων περιέχει τιμές μετοχών από το 2010 μέχρι το 2025. Όπως ειπώθηκε στο Κεφάλαιο 2, όλα τα σύνολα δεδομένων ακολουθούν ομοιόμορφο ημερολόγιο, οπότε έχουν τον ίδιο αριθμό εγγραφών, οι οποίες είναι 3893. (ii) Επιλέγεται το μέγεθος του συνόλου εκπαίδευσης παίρνοντας ένα ποσοστό του συνόλου δεδομένων. Το σύνολο εκπαίδευσης ξεκινάει πάντα από την αρχή του συνόλου δεδομένων, δηλαδή από την πρώτη μέρα του 2010. Για παράδειγμα, αν επιλεγεί ποσοστό εκπαίδευσης 10%, το σύνολο εκπαίδευσης είναι από 01/01/2010 συν 389 ημέρες στο μέλλον. Επίσης, η υλοποίηση του TTM παράγει κατά τη διάρκεια της εκπαίδευσης από μόνη της ένα σύνολο επικύρωσης (validation set). Η εκπαίδευση τρέχει για 5 εποχές και σε κάθε εποχή μετράται το σφάλμα εκπαίδευσης και το σφάλμα επικύρωσης. (iii) Το δεύτερο βήμα επαναλαμβάνεται για τα ποσοστά 6%, 12%, 18%, 24%, 30%, 36%, 42%, 48% και 54%. Τέλος, και τα τρία βήματα επαναλαμβάνονται και για τις επτά μετοχές.

5.4.1 Απώλειες Εκπαίδευσης - Επικύρωσης ανά ποσοστό εκπαίδευσης

Αφού ολοκληρώθηκε η εκπαίδευση για όλες τις μετοχές και για όλα τα ποσοστά παράχθηκαν διαγράμματα με την εξέλιξη του σφάλματος εκπαίδευσης και του σφάλματος επικύρωσης. Παρακάτω ερμηνεύονται τα αποτελέσματα όλων των διαγραμμάτων και δίνονται ενδεικτικά 4 σχήματα 5.4 - 5.7. Κάθε σχήμα αφορά ένα ποσοστό εκπαίδευσης και περιέχει δύο διαγράμματα, ένα για το σφάλμα εκπαίδευσης και ένα για το σφάλμα επικύρωσης, τα

οποία περιέχουν 7 γραμμές, μία για κάθε μετοχή. Ο άξονας των x είναι ο αριθμός της εποχής και ο άξονας των y η τιμή του σφάλματος.


Στα χαμηλά ποσοστά εκπαίδευσης 6% έως και 18% (Σχήμα 5.4) παρατηρείται υψηλό σφάλμα επικύρωσης για πιο απαιτητικές μετοχές (π.χ. TSLA, AMD), παρότι το σφάλμα εκπαίδευσης μειώνεται σταθερά και καθίσταται πολύ μικρό. Η απόκλιση αυτή αποτελεί ισχυρή ένδειξη υπερπροσαρμογής. Αντίθετα, μετοχές χαμηλής μεταβλητότητας (PG, JNJ, XOM) παρουσιάζουν ήδη χαμηλό και σταθερό σφάλμα επικύρωσης ακόμη και με περιορισμένα δεδομένα.




Σχήμα 5.4: Απώλειες εκπαίδευσης/επικύρωσης για το ποσοστό 12%

Ένα σημείο καμπής παρατηρείται μετά το ποσοστό του 18% (Σχήμα 5.5). Η TSLA, που αρχικά είχε ασταθή απόδοση και υψηλό σφάλμα επικύρωσης, παρουσιάζει σημαντική βελτίωση. Το σφάλμα επικύρωσης μειώνεται απότομα και σταθεροποιείται. Αυτή η αλλαγή δείχνει ότι το μοντέλο αρχίζει να συλλαμβάνει τη δυναμική δομή της TSLA μόλις εκπαιδευτεί σε επαρκή αριθμό παραδειγμάτων.


Στα μεσαία ποσοστά (24%,30%,36%), οι περισσότερες μετοχές παρουσιάζουν ισορροπία μεταξύ μείωσης του σφάλματος εκπαίδευσης και βελτίωσης του σφάλματος επικύρωσης. Η τιμές των σφαλμάτων δείχνουν πως οι προβλέψεις αρχίζουν να είναι επιτυχημένες. Οι TSLA, PG και SPY αποδίδουν σταθερά καλά σε αυτό το εύρος. Η AMD φαίνεται ότι σταθεροποιείται σε αυτό το στάδιο.



Σχήμα 5.5: Απώλειες εκπαίδευσης/επικύρωσης για το ποσοστό 24%



Σχήμα 5.6: Απώλειες εκπαίδευσης/επικύρωσης για το ποσοστό 42%



Σχήμα 5.7: Απώλειες εκπαίδευσης/επικύρωσης για το ποσοστό 54%


Στα υψηλότερα ποσοστά 42% (Σχήμα 5.6), 48% και 54% (Σχήμα 5.7), το μοντέλο επιτυγχάνει τη σταθερότερη και πιο γενικεύσιμη απόδοσή του. Το σφάλμα επικύρωσης παραμένει

σταθερά χαμηλό τόσο για σταθερές όσο και για ευμετάβλητες μετοχές, ενώ το σφάλμα εκπαίδευσης συγκλίνει ομαλά με ελάχιστη διακύμανση. Ωστόσο, στα ποσοστά 48% και 54% το σφάλμα επικύρωσης της AMD αποκτά ανοδική πορεία σε σχέση με το σφάλμα εκπαίδευσης. Αυτό είναι ένδειξη πως ξαναεμφανίζεται υπερπροσαρμογή.

5.4.2 Χάσμα γενίκευσης

Για την ολοκλήρωση της ανάλυσης του ποσοστού εκπαίδευσης, υπολογίζεται το χάσμα γενίκευσης (generalization gap) για κάθε ποσοστό. Το χάσμα γενίκευσης ορίζεται ως η διαφορά μεταξύ του σφάλματος εκπαίδευσης και του σφάλματος επικύρωσης μόνο στην τελευταία εποχή, με σκοπό να μετρηθεί η ικανότητα γενίκευσης όταν πλέον η εκπαίδευση έχει τελειώσει.

Μικρό χάσμα υποδηλώνει καλύτερη γενίκευση, ενώ μεγάλο αρνητικό χάσμα φανερώνει υπερπροσαρμογή. Σε αυτό το βήμα, υπολογίζεται ο μέσος όρος του χάσματος γενίκευσης όλων των μετοχών, αντί της καθεμίας ξεχωριστά. Η εξέλιξη του χάσματος απεικονίζεται στο διάγραμμα του Σχήματος 5.8. Επίσης στο διάγραμμα αποτυπώνεται και η τυπική απόκλιση που αναδεικνύει σε τι διάστημα κυμαίνεται το χάσμα.



Σχήμα 5.8: Χάσμα γενίκευσης

Το γράφημα δείχνει ότι σε χαμηλά ποσοστά (6%, 12%), το μοντέλο παρουσιάζει μεγάλα

αρνητικά χάσματα γενίκευσης, επιβεβαιώνοντας ότι σε αυτά τα ποσοστά γίνεται υπερπροσαρμογή. Καθώς το ποσοστό αυξάνεται πέρα από το 18%, το χάσμα μειώνεται σταθερά και τελικά πλησιάζει το μηδέν. Σταθεροποιείται κοντά στο μηδέν για ποσοστά 42%-54%. Επιπλέον, η τυπική απόκλιση είναι μεγάλη όχι μόνο στα χαμηλότερα ποσοστά αλλά και στο εύρος 24-36%. Από τις δύο αναλύσεις φαίνεται πως το ποσοστό 42% είναι η ασφαλής επιλογή για τα πειράματα που θα ακολουθήσουν, εξασφαλίζοντας καλά σφάλματα επικύρωσης με σχετικά μικρό αριθμό δεδομένων.

5.5 Ανάλυση μεταφερσιμότητας

Σε αυτό το πείραμα εξετάζεται ο καλύτερος τρόπος εκπαίδευσης του TTM ως προς την επιλογή του σε ποιο σύνολο δεδομένων θα γίνει η εκπαίδευση. Για την υλοποίηση του πειράματος παράγονται επτά προσαρμοσμένα μοντέλα TTM, καθένα απ' τα οποία είναι εκπαιδευμένο σε μία από τις επτά μετοχές. Το ποσοστό εκπαίδευσης που χρησιμοποιείται είναι το ποσοστό που βρέθηκε στην προηγούμενη ενότητα, δηλαδή 42%. Κάθε ένα από τα επτά προσαρμοσμένα μοντέλα κάνει προβλέψεις σε σύνολα αξιολόγησης και των επτά μετοχών και υπολογίζονται όλες οι μετρικές για την πρόβλεψη αυτή. Με αυτόν τον τρόπο ελέγχεται το κατά πόσο μοτίβα που μαθεύτηκαν από την εκπαίδευση σε μία μετοχή, κάνουν το TTM να μπορεί να μεταφέρει αυτή τη γνώση και για προβλέψεις άλλων μετοχών, εξού και ο όρος μεταφερσιμότητα. Το ερώτημα που τίθεται σε αυτό το πείραμα είναι αν τα καλύτερα αποτελέσματα παράγονται, όταν για την πρόβλεψη μιας μετοχής γίνεται εκπαίδευση στην ίδια τη μετοχή, ή αν υπάρχουν κάποιες μετοχές που κάνουν το TTM να αποκτήσει ισχυρότερη ικανότητα γενίκευσης, ακόμη και για προβλέψεις σε μετοχές στις οποίες δεν έχει εκπαιδευτεί.

5.5.1 Συγκεντρωτικοί πίνακες αποτίμησης προβλέψεων


Στους συγκεντρωτικούς πίνακες αποτελεσμάτων των προβλέψεων για τα RMSE (Σχήμα 5.9), MAE (Σχήμα 5.10) και MAPE (Σχήμα 5.11) που ακολουθούν, κάθε γραμμή αντιστοιχεί στη μετοχή πάνω στην οποία εκπαιδεύεται το μοντέλο και κάθε στήλη στη μετοχή στην οποία γίνεται η πρόβλεψη. Η κύρια διαγώνιος απεικονίζει την απόδοση όταν το μοντέλο εκπαιδεύεται και προβλέπει στην ίδια μετοχή. Όσο πιο σκούρα είναι η απόχρωση ενός κελιού, τόσο καλύτερη είναι η τιμή της μετρικής. Επιπλέον, η βέλτιστη τιμή της μετρικής για κάθε μετοχή-στόχο επισημαίνεται με ένα λευκό περίγραμμα.

Στις περισσότερες μετοχές (π.χ. XOM, SPY, JNJ, PG) για τις μετρικές σφάλματος, οι διαγώνιες τιμές είναι μεν από τις χαμηλότερες ανά στήλη, αλλά όχι συστηματικά οι καλύτερες, άρα η εκπαίδευση του μοντέλου πάνω στη μετοχή-στόχο δεν συνεπάγεται την καλύτερη επίδοση πρόβλεψης. Τα χειρότερα αποτελέσματα ανά στήλη εμφανίζονται όταν το μοντέλο εκπαιδεύεται σε τεχνολογικές μετοχές (AAPL, TSLA, AMD), πιθανόν επειδή ο αυξημένος θόρυβος και η αστάθεια των τιμών τους ενσωματώνεται στα βάρη του TTM με αποτέλεσμα να μειώνεται η ικανότητα γενίκευσης.

Οι XOM, JNJ και PG προβλέπουν ιδιαίτερα καλά η μία την άλλη. Όταν όμως χρησιμοποιούνται για να προβλεφθεί ο SPY, παρατηρείται χαμηλό MAPE αλλά υψηλά RMSE και MAE. Επειδή ο SPY, ως ETF του S&P 500, το οποίο ενσωματώνει την επίδοση των 500 μεγαλύτερων εταιριών των Η.Π.Α, έχει σημαντικά μεγαλύτερη κλίμακα τιμής, μικρές ποσοστιαίες αποκλίσεις μεταφράζονται σε μεγάλες απόλυτες αποκλίσεις. Το αντίστροφο μοτίβο εμφανίζεται με την XOM. Λόγω χαμηλότερης κλίμακας τιμών, ακόμη και μέτρια απόλυτα σφάλματα διογκώνονται ποσοστιαία, οδηγώντας σε υψηλότερο MAPE.



Σχήμα 5.9: Συγκεντρωτικός πίνακας MAE



Σχήμα 5.10: Συγκεντρωτικός πίνακας RMSE



Σχήμα 5.11: Συγκεντρωτικός πίνακας MAPE

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	4,49	5,91	3,65	0,47	0,51	0,55	0,53
TSLA	18,23	24,57	10,37	0,49	0,51	0,55	0,53
XOM	2,64	3,33	4,65	0,48	0,49	0,52	0,50
SPY	2,93	3,86	2,31	0,47	0,51	0,54	0,52
JNJ	2,41	3,10	1,71	0,50	0,51	0,53	0,52
AMD	6,40	8,75	7,01	0,47	0,47	0,51	0,49
PG	2,43	3,09	1,95	0,46	0,50	0,52	0,51

Πίνακας 5.4: Μετρικές μοντέλου εκπαιδευμένο στον SPY - Σύνολο αξιολόγησης

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	4,15	5,46	6,21	0,44	0,49	0,55	0,52
TSLA	38,14	41,11	20,01	0,46	0,49	0,58	0,53
XOM	5,49	6,45	7,27	0,53	0,51	0,53	0,52
SPY	71,03	78,04	18,68	0,456	0,38	0,44	0,41
JNJ	6,33	8,06	5,66	0,45	0,51	0,51	0,51
AMD	2,75	3,57	16,05	0,44	0,48	0,50	0,49
PG	6,07	7,08	10,38	0,50	0,47	0,52	0,49

Πίνακας 5.5: Μετρικές μοντέλου εκπαιδευμένο στον SPY - παράθυρα γεγονότων

Για τις κατευθυντικές μετρικές δεν δίνονται οι πίνακες διότι τα αποτελέσματα είναι παρόμοια παντού. Θα χρειαστεί βελτιστοποίηση σε άλλους παράγοντες για να επιτευχθεί καλύτερη απόδοση στις μετρικές αυτές. Ακολουθούν μερικά σχόλια για τις τιμές τους. Το Hit Rate κινείται σε στενό εύρος (0,47–0,50). Στις προβλέψεις στην AAPL οι τιμές παραμένουν ουσιαστικά σταθερές ανεξάρτητα από το μοντέλο, ενώ παρόμοιο μοτίβο εμφανίζει και η PG. Για τις μετρικές Precision/Recall/F1, τα μοντέλα που εκπαιδεύτηκαν σε AMD και TSLA υστερούν.

Το μοντέλο που εκπαιδεύεται στο SPY παρουσιάζει ισχυρή γενίκευση, έχοντας τις καλύτερες προβλέψεις για όλες τις μετρικές σε όλες τις μετοχές. Ως δείκτης ενσωματώνει μια ισορροπημένη σύνοψη της αγοράς, επιτρέποντας στο μοντέλο να μεταφέρει αποτελεσματικά τα μαθημένα μοτίβα σε άλλες μετοχές. Στους Πίνακες 5.4 και 5.5 φαίνονται οι μετρικές των

προβλέψεων του στα σύνολα αξιολόγησης και στα παράθυρα γεγονότων αντίστοιχα.

5.5.2 Εκπαίδευση στο ETF QQQ

Για να επιβεβαιωθεί πως η εκπαίδευση σε δείκτες, όπως ο S&P 500, δίνει στο TTM ικανότητα να προβλέπει αποτελεσματικά μετοχές οποιασδήποτε μεταβλητότητας και κλίμακας, γίνεται εκπαίδευση με ένα ακόμα ETF, το QQQ. Επειδή δεν παρουσιάστηκε στο Κεφάλαιο 2 ακολουθεί μια σύντομη περιγραφή του.

Το QQQ, που εκδίδεται από την εταιρία Invesco, είναι ένα από τα πιο δημοφιλή ETF στον κόσμο. Αντικατοπτρίζει την απόδοση του δείκτη Nasdaq-100, ο οποίος εμπεριέχει τις αποδόσεις των 100 μεγαλύτερων εταιριών στο χρηματιστήριο Nasdaq. Το Nasdaq είναι ένα ηλεκτρονικό χρηματιστήριο, στο οποίο γίνονται αγοραπωλησίες μετοχών κυρίως του τεχνολογικού τομέα (π.χ. Amazon, Microsoft, NVIDIA).

Όπως και με τις υπόλοιπες μετοχές τα δεδομένα για το QQQ λήφθηκαν από το πρόγραμμα λήψης δεδομένων (από 01/01/2010 έως 31/12/2024), τροποποιήθηκαν από τον προεπεξεργαστή και χρησιμοποιήθηκε το 42% τους ως σύνολο εκπαίδευσης. Έγιναν προβλέψεις στα σύνολα δεδομένων και στα παράθυρα αξιολόγησης όλων των μετοχών.

Οι Πίνακες 5.6 και 5.7 δείχνουν τις μετρικές αξιολόγησης για την πρόβλεψη στα σύνολα αξιολόγησης και στα παράθυρα γεγονότων για το μοντέλο που εκπαιδεύτηκε στο QQQ. Παρατηρείται η ίδια συμπεριφορά όπως και με το μοντέλο που εκπαιδεύτηκε στο SPY. Το μοντέλο κάνει καλύτερες προβλέψεις από την ξεχωριστή εκπαίδευση σε κάθε μετοχή στόχο. Σε σύγκρισή με το μοντέλο που εκπαιδεύτηκε στο SPY, όσον αφορά τις μετρικές πλάτους για τις μετοχές TSLA, AAPL και AMD έχει καλύτερα αποτελέσματα και στο σύνολο αξιολόγησης και στα παράθυρα γεγονότων. Για τις JNJ, XOM και PG έχει χειρότερα. Αυτό τονίζει την εξειδίκευση του ETF αυτού σε τεχνολογικές μετοχές. Στις μετρικές κατεύθυνσης τα δύο μοντέλα έχουν παρόμοια αποτελέσματα. Ανεξαρτήτως των συγκρίσεων μεταξύ των δύο μοντέλων, επιβεβαιώθηκε πως η εκπαίδευση σε χρηματιστηριακούς δείκτες είναι καλύτερη επιλογή.

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	2,78	3,75	2,22	0,468	0,505	0,545	0,524
TSLA	13,02	17,49	7,65	0,499	0,522	0,552	0,536
XOM	3,08	3,74	5,02	0,493	0,505	0,524	0,512
JNJ	2,93	3,50	2,36	0,498	0,513	0,530	0,521
AMD	4,35	6,13	4,88	0,480	0,479	0,515	0,497
PG	3,16	3,40	2,27	0,473	0,509	0,534	0,521

Πίνακας 5.6: Μετρικές μοντέλου εκπαιδευμένο στο QQQ - Σύνολο αξιολόγησης

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	4,61	5,31	6,44	0,446	0,500	0,566	0,531
TSLA	11,32	13,96	6,20	0,469	0,497	0,563	0,528
XOM	5,75	6,18	7,37	0,523	0,568	0,592	0,579
JNJ	1,99	6,45	1,27	0,451	0,507	0,509	0,508
AMD	1,14	1,56	5,65	0,436	0,471	0,505	0,486
PG	6,23	7,52	10,06	0,482	0,455	0,469	0,462

Πίνακας 5.7: Μετρικές μοντέλου εκπαιδευμένο στο QQQ - παράθυρα γεγονότων

5.6 Βελτιστοποίηση υπερπαραμέτρων

Σε αντίθεση με τις παραμέτρους του μοντέλου (βάρη), που μαθαίνονται κατά την εκπαίδευση, οι υπερπαραμέτροι καθορίζονται πριν από την εκπαίδευση. Οι υπερπαραμέτροι ενός μοντέλου συνήθως έχουν σημαντικό ρόλο στην επίδοση του. Μέχρι τώρα, ο ρυθμός μάθησης και το μέγεθος παρτίδας επιλέγονταν στην τύχη. Σε αυτήν την ενότητα θα βρεθεί τι ρόλο παίζει ο ρυθμός μάθησης και το μέγεθος παρτίδας στην επίδοση του μοντέλου. Αν έχουν σημαντικό ρόλο θα βρεθεί η ιδανική τιμή τους. Η παρακάτω μελέτη είναι για μοντέλο εκπαιδευμένο στο 42% του SPY. Για πιο μικρά ποσοστά οι βελτιστοποιήσεις στην απόδοση ήταν ανάλογες, αλλά όχι αντίστοιχες. Για πιο μεγάλα ποσοστά δεν έγινε έλεγχος καθώς, όπως ειπώθηκε παραπάνω, στόχος είναι η χρήση του μικρότερου δυνατού ποσοστού.

Για την βελτιστοποίηση θα χρησιμοποιηθεί το εργαλείο Optuna. Το Optuna είναι ένα εργαλείο βελτιστοποίησης υπερπαραμέτρων ανοιχτού κώδικα το οποίο διακρίνεται για την


ταχύτητα και την αποτελεσματικότητά του, καθώς χρησιμοποιεί έξυπνη δειγματοληψία και περικοπή μη υποσχόμενων δοκιμών για εξοικονόμηση χρόνου. Αντί να δοκιμάζει όλους τους συνδυασμούς, το Optuna ορίζει έναν χώρο αναζήτησης, προτείνει πολλά υποσχόμενες υπερπαραμέτρους, τις αξιολογεί και μαθαίνει από προηγούμενες δοκιμές για να βελτιώσει τις μελλοντικές προτάσεις. Είναι ιδιαίτερα χρήσιμο για σύνθετα μοντέλα ή μεγάλα σύνολα δεδομένων, όπου η εξαντλητική βελτιστοποίηση δεν είναι εφικτή.

Για τη χρήση του Optuna πρώτα πρέπει να οριστεί μια συνάρτηση στόχος. Αυτή η συνάρτηση: 1) λαμβάνει τις προτάσεις δοκιμών από το Optuna, 2) διαμορφώνει το μοντέλο χρησιμοποιώντας τις προτεινόμενες υπερπαραμέτρους, 3) το εκπαιδεύει και το αξιολογεί, 4) επιστρέφει ένα αριθμητικό σκορ προς ελαχιστοποίηση (σε αυτήν την περίπτωση, η απώλεια επικύρωσης).

Στη συνέχεια, δημιουργείται μια μελέτη Optuna: 1) Πραγματοποιείται μια μελέτη 10 ξεχωριστών δοκιμών. Σε κάθε δοκιμή, το Optuna επιλέγει έναν διαφορετικό συνδυασμό υπερπαραμέτρων. 2) το μοντέλο εκπαιδεύεται και αξιολογείται, και το αποτέλεσμα καταγράφεται σε ένα αρχείο. 3) μετά από όλες τις δοκιμές, το Optuna εντοπίζει το καλύτερο σύνολο υπερπαραμέτρων που οδήγησε στη χαμηλότερη απώλεια επικύρωσης.

5.6.1 Πορεία σφάλματος στη μελέτη Optuna

Το διάγραμμα του Σχήματος 5.12 οπτικοποιεί τον τρόπο με τον οποίο αλλάζει το σφάλμα επικύρωσης κατά τη διάρκεια κάθε δοκιμής στη μελέτη του Optuna. Κάθε μπλε τελεία αντιπροσωπεύει μια δοκιμή με έναν συγκεκριμένο συνδυασμό υπερπαραμέτρων, και η κόκκινη γραμμή παρακολουθεί την καλύτερη απώλεια επικύρωσης που επιτεύχθηκε μέχρι στιγμής.




Σχήμα 5.12: Πορεία σφάλματος επικύρωσης ανά δοκιμή Optuna

Η χαμηλότερη απώλεια επικύρωσης που επιτεύχθηκε ήταν περίπου 0,447, ορατή στην τελική δοκιμή. Η βελτιστοποίηση βελτιώνεται με την πάροδο του χρόνου, με την κόκκινη γραμμή να κατεβαίνει, ιδιαίτερα μεταξύ των δοκιμών 2 και 3. Οι πρώτες δοκιμές είχαν υψηλότερη απώλεια, δείχνοντας ότι το μοντέλο εξερεύνησε χειρότερες διαμορφώσεις πριν συγκλίνει σε καλύτερες. Αυτό υποδεικνύει ότι το Optuna εξερεύνησε με επιτυχία τον χώρο παραμέτρων και βελτίωσε την απόδοση του μοντέλου με την πάροδο του χρόνου επιλέγοντας καλύτερες υπερπαραμέτρους. Στην τελική δοκιμή οι υπερπαραμέτροι ήταν `learning_rate=0,0022490307997647717`, `batch_size = 64`.

5.6.2 Σχετική σημασία υπερπαραμέτρων

Το ραβδόγραμμα του Σχήματος 5.13 δείχνει τη σχετική σημασία κάθε υπερπαραμέτρου στην ελαχιστοποίηση της συνάρτησης στόχου. Αυτή υπολογίζεται χρησιμοποιώντας μια προσέγγιση σημαντικότητας χαρακτηριστικών βασισμένη σε κάποιο μοντέλο (π.χ. δάση τυχαίων αποφάσεων).


Ο ρυθμός μάθησης συμβάλλει στο 89% της διαφοράς στην απόδοση. Το μέγεθος παρτίδας συμβάλλει πολύ λιγότερο (11%). Η ρύθμιση του ρυθμού μάθησης είχε σημαντικά μεγαλύτερο αντίκτυπο στην απόδοση του μοντέλου απ' ό,τι η ρύθμιση του μεγέθους παρτίδας. Το μοντέλο είναι εξαιρετικά ευαίσθητο στον ρυθμό μάθησης, ίσως οι χαμηλές τιμές σε μετρικές κατεύθυνσης να ευθύνονταν στην επιλογή αυτής της υπερπαραμέτρου.



Σχήμα 5.13: Σχετική σημασία υπερπαραμέτρων

5.6.3 Διάγραμμα παράλληλων συντεταγμένων

Το διάγραμμα του Σχήματος 5.14 παράλληλων συντεταγμένων εμφανίζει τις σχέσεις μεταξύ των υπερπαραμέτρων και των προκυπτουσών τιμών στόχου σε όλες τις δοκιμές. Κάθε γραμμή αντιπροσωπεύει μια δοκιμή. Στον αριστερό άξονα είναι η τιμή στόχος (σφάλμα επικύρωσης), στον μεσαίο το μέγεθος παρτίδας και στον δεξιό ο ρυθμός μάθησης. Οι γραμμές χρωματίζονται ανάλογα με την απόδοση, με τις πιο σκούρες γραμμές να αντιπροσωπεύουν χαμηλότερη απώλεια.



Σχήμα 5.14: Διάγραμμα παράλληλων συντεταγμένων

Οι χαμηλότερες απώλειες επιτυγχάνονται όταν ο ρυθμός μάθησης είναι περίπου 0,0022. Πολύ χαμηλοί ρυθμοί μάθησης (π.χ. 0,0001) ή πολύ υψηλοί (π.χ. 0,0025+) υποβαθμίζουν την απόδοση. Δεν υπάρχει σαφής τάση στο μέγεθος παρτίδας, καθώς καλή απόδοση παρατηρείται σε όλες τις τιμές. Με βάση όλα τα παραπάνω ο ρυθμός μάθησης που επιλέγεται είναι 0,0022. Ως μέγεθος παρτίδας επιλέγεται το 64.


5.7 Ανάλυση σημαντικότητας χαρακτηριστικών

Μέχρι τώρα το μοντέλο εκπαιδευόταν μόνο στην τιμή κλεισίματος. Σε αυτή την ενότητα γίνεται ανάλυση σημαντικότητας των χαρακτηριστικών OHLV και τεχνικών δεικτών. Για την ανάλυση σημαντικότητας χαρακτηριστικών χρησιμοποιούνται δύο τρόποι: (i) με τον δείκτη SHAP, ο οποίος ποσοτικοποιεί την συνεισφορά κάθε μεταβλητής σε μεμονωμένες προβλέψεις. Είναι βασισμένος στη θεωρία παιγνίων και είναι ανεξάρτητος του μοντέλου που χρησιμοποιείται. (ii) Η σημαντικότητα μεταθέσεων, η οποία ανακατεύει με τυχαίο τρόπο μεταβλητές εισόδου και μετράει την επίδοση του μοντέλου. Μεγάλη πτώση στην απόδοση δείχνει πως η μεταβλητή που ανακατεύτηκε ήταν σημαντική.

5.7.1 Δείκτης SHAP

Το ραβδόγραμμα του Σχήματος 5.15 απεικονίζει τις μέσες τιμές σημαντικότητας χαρακτηριστικών SHAP που συγκεντρώθηκαν από προβλέψεις σε όλες τις μετοχές. Οι τιμές SHAP παρέχουν πληροφορίες σχετικά με το πόσο συμβάλλει κάθε χαρακτηριστικό στις προβλέψεις του μοντέλου, με υψηλότερες τιμές να υποδηλώνουν μεγαλύτερη επιρροή. Τα χαρακτηριστικά των ακατέργαστων τιμών κυριαρχούν σε σημασία. Η χαμηλότερη ημερήσια τιμή low είναι το πιο επιδραστικό χαρακτηριστικό συνολικά, με μέση τιμή SHAP 30,25. Η υψηλότερη ημερήσια τιμή high και η τιμή ανοίγματος open ακολουθούν στενά, υποδηλώνοντας ότι τα βασικά επίπεδα τιμών φέρουν το ισχυρότερο προγνωστικό σήμα στο μοντέλο.

Οι τεχνικοί δείκτες παρουσιάζουν ποικίλους βαθμούς επιρροής. Μεταξύ των κινητών μέσων όρων, ο σταθμισμένος κινητός μέσος όρος 20 ημερών wma_20 και ο εκθετικός κινητός μέσος όρος ema_20 συμβάλλουν σημαντικά στις προβλέψεις του μοντέλου. Ο τριπλός εκθετικός κινητός μέσος όρος tema_20 έχει επίσης αξιοσημείωτο, αν και χαμηλότερο, μέσο αντίκτυπο. Αντίθετα, ο απλός κινητός μέσος όρος sma_20 και η άνω ζώνη Bollinger bb_upper παρουσιάζουν μικρή αλλά όχι μηδενική επιρροή.




Σχήμα 5.15: Ραβδόγραμμα δεικτών SHAP

5.7.2 Σημαντικότητα μεταθέσεων

Η σημαντικότητα μεταθέσεων είναι μια τεχνική που χρησιμοποιείται για να μετρηθεί πόσο σημαντικό είναι κάθε χαρακτηριστικό για ένα εκπαιδευμένο μοντέλο. Ένα χαρακτηριστικό ανακατεύεται τυχαία σε ολόκληρο το σύνολο δεδομένων. Η απόδοση του μοντέλου επαναξιολογείται. Αν η απόδοση μειωθεί σημαντικά, αυτό σημαίνει ότι το συγκεκριμένο χαρακτηριστικό ήταν σημαντικό. Αν η απόδοση δεν αλλάξει ιδιαίτερα, το χαρακτηριστικό πιθανότατα δεν ήταν σημαντικό.

Η σημαντικότητα μεταθέσεων υπολογίζεται για την πρόβλεψη κάθε μετοχής και μετά υπολογίζεται ο μέσος όρος όλων, για κάθε χαρακτηριστικό. Στον κάθετο άξονα είναι τα ονόματα των χαρακτηριστικών και στον οριζόντιο άξονα η μείωση στην απόδοση του μοντέλου. Στο διάγραμμα του Σχήματος 5.16 ο σταθμισμένος κινητός μέσος όρος (20 ημερών) wma_20 κυριαρχεί. Η ανακατάταξή του βλέπει σοβαρά την πρόβλεψη. Ο τριπλός εκθετικός κινητός μέσος όρος tema_20 και ο κλασικός εκθετικός κινητός μέσος επιβεβαιώνουν την εξάρτηση του μοντέλου από στρατηγικές παρακολούθησης τάσεων.

Η ημερήσια υψηλή τιμή βοηθά στις προβλέψεις, αλλά με όχι τόσο ισχυρό τρόπο όσο οι δείκτες τάσης. Τα υπόλοιπα τέσσερα χαρακτηριστικά bb_upper, low, open και sma_20 είναι χρήσιμα αλλά δευτερεύοντα.



Σχήμα 5.16: Ραβδόγραμμα σημαντικότητας μεταθέσεων

Τα υπόλοιπα χαρακτηριστικά είτε δεν βοηθούν ιδιαίτερα είτε προσθέτουν θόρυβο στο μοντέλο. Η ανακατάταξή τους δεν μειώνει την απόδοση σε κάποιες περιπτώσεις μπορεί να τη βελτιώνει ελαφρώς.

Στα αποτελέσματα των παραπάνω αναλύσεων ο όγκος (ημερήσιος αριθμός συναλλαγών), που θα περιμέναμε να παίζει σημαντικό ρόλο, συνεισφέρει ελάχιστα στις προβλέψεις του μοντέλου σε σύγκριση με άλλα χαρακτηριστικά. Αυτό μπορεί να συμβαίνει επειδή ο όγκος μπορεί έχει μεγάλες μεταβολές ανά μέρα λόγω διάφορων γεγονότων (ειδήσεις, νομοθετικές πράξεις κ.τ.λ). Αυτές τις μεταβολές το TTM τις αντιμετωπίζει απ'ό,τι φαίνεται ως θόρυβο. Τελικές επιλογές χαρακτηριστικών είναι οι open, high, low, wma_20, ema_20, tema_20, sma_20.

5.8 Αποτελέσματα βελτιστοποιημένου TTM

Σε αυτή την ενότητα αποτιμάται η απόδοση του τελικού μοντέλου TTM που προέκυψε μετά από την βελτιστοποίηση υπερπαραμέτρων και την ανάλυση σημαντικότητας χαρακτηριστικών. Οι συνθήκες εκπαίδευσης του τελικού μοντέλου είναι (i) Εκπαίδευση στο 42% του SPY, (ii) Learning Rate = 0,00225, (iii) Batch size = 64, (iv) Χαρακτηριστικά: open,

high, low, wma_20, ema_20, tema_20, sma_20.

Ο Πίνακας 5.8 παρουσιάζει τις μετρικές του τελικού μοντέλου στο σύνολο αξιολόγησης. Οι αμυντικές μετοχές (PG, JNJ, XOM) εμφανίζουν τα χαμηλότερα σφάλματα. Η AAPL παρουσιάζει ελαφρώς αυξημένες τιμές, ενώ τα υψηλότερα σφάλματα παρατηρούνται στην TSLA (MAE=12,63, RMSE=16,66, MAPE=7,26%) και, σε μικρότερο βαθμό, στην AMD. Όσον αφορά τις κατευθυντικές μετρικές, το μοντέλο εμφανίζει πολύ καλή συμπεριφορά, με Precision γύρω στο 0,50–0,54 και Recall μέχρι και 0,58. Οι τιμές του F1 συγκεντρώνονται μεταξύ 0,5–0,56, ενώ το Hit Rate κυμαίνεται περί το 0,47–0,50, με κορυφαία επίδοση στη JNJ (0.509).

Ο Πίνακας 5.9 ομαδοποιεί τα αποτελέσματα ανά καθεστώς μεταβλητότητας. Στο καθεστώς υψηλής μεταβλητότητας καταγράφεται η πιο αδύναμη επίδοση, με τιμές περίπου MAE=8,57, RMSE=11,4 και MAPE=6,01%. Οι απότομες, μη γραμμικές κινήσεις αυξάνουν τα σφάλματα και μειώνουν ελαφρώς την ποιότητα του σήματος πρόβλεψης (F1=0,508). Αντίθετα, στο καθεστώς χαμηλής μεταβλητότητας παρατηρείται η καλύτερη συμπεριφορά του μοντέλου. Στο καθεστώς αντιστροφής τάσης τα σφάλματα είναι λίγο παραπάνω από τη χαμηλή μεταβλητότητα (MAE=2,60, RMSE=3,36,) και το F1 κυμαίνεται στο 0,518. Τέλος, στο καθεστώς πλάγιας ή ακατάστατης κίνησης το F1 έχει την υψηλότερη τιμή (=0,554). Στα παράθυρα γεγονότων (Πίνακας 5.10) η πρόβλεψη κατεύθυνσης έχει ασταθή συμπεριφορά με πολύ υψηλές τιμές για κάποιες μετοχές (π.χ. Recall = 0,585 για AAPL και Recall = 0,425 για SPY). Οι μετρικές σφάλματος ακολουθούν το ίδιο μοτίβο με τα σύνολα αξιολόγησης.

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	3,11	4,09	2,41	0,477	0,513	0,554	0,533
TSLA	12,63	16,66	7,26	0,494	0,518	0,546	0,532
XOM	2,09	2,62	3,81	0,496	0,503	0,516	0,509
SPY	5,33	6,83	1,40	0,492	0,533	0,579	0,555
JNJ	1,91	2,42	1,37	0,509	0,524	0,539	0,531
AMD	4,51	6,14	4,76	0,479	0,479	0,529	0,502
PG	1,79	2,33	1,41	0,469	0,505	0,531	0,518

Πίνακας 5.8: Πίνακας μετρικών στο σύνολο αξιολόγησης - βελτιστοποιημένο TTM


Regime Type	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
High-Volatility	8,57	11,40	6,01	0,486	0,499	0,536	0,518
Low-Volatility	1,85	2,38	1,39	0,489	0,514	0,535	0,524
Post-Trend Reversal	2,60	3,36	3,11	0,486	0,508	0,535	0,521
Sideways/Chop	5,33	6,83	1,40	0,492	0,533	0,578	0,554

Πίνακας 5.9: Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - βελτιστοποιημένο TTM

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	2,16	2,70	3,24	0,451	0,500	0,585	0,539
TSLA	16,49	19,30	9,17	0,458	0,484	0,556	0,517
XOM	2,51	3,08	3,41	0,512	0,559	0,570	0,565
SPY	6,43	8,12	1,66	0,475	0,400	0,425	0,413
JNJ	1,70	2,14	1,49	0,451	0,510	0,515	0,513
AMD	1,28	1,73	5,99	0,444	0,479	0,507	0,493
PG	0,99	1,15	1,64	0,497	0,471	0,508	0,489

Πίνακας 5.10: Πίνακας μετρικών στα παράθυρα γεγονότων - βελτιστοποιημένο TTM

Η σχέση κυλιόμενης μεταβλητότητας/σφάλματος του βελτιστοποιημένου μοντέλου μετρήθηκε σε σύγκριση με το μοντέλο εκπαιδευμένο στο SPY χωρίς βελτιστοποίηση [4]. Τα σφάλματα του βελτιστοποιημένου μοντέλου είναι σαφώς μικρότερα σε όλες τις μετοχές και για οποιοδήποτε ποσοστό μεταβλητότητας. Το εύρημα αυτό δείχνει ότι το τελικό μοντέλο είναι πολύ ανθεκτικό σε πρόσφατες διακυμάνσεις. Αντίθετα, μη βελτιστοποιημένο μοντέλο παρουσιάζει μεγαλύτερη διασπορά σφαλμάτων και περισσότερες ακραίες τιμές. Παράδειγμα για την TSLA στο Σχήμα 5.17.



Σχήμα 5.17: Διάγραμμα κυλιόμενης μεταβλητότητας/σφάλματος για την TSLA - TTM-optimized [4]


Στο διάγραμμα του Σχήματος 5.18 παρουσιάζονται οι σωρευτικές αποδόσεις της επενδυτικής στρατηγικής, όπως αυτή περιγράφηκε στο κεφάλαιο 2. Για κάθε αυριανή μέρα κοιτάμε το μοντέλο για το αν προβλέπει άνοδο ή κάθοδο, και παίρνουμε αυτή τη θέση ως επενδυτές. Το κέδρος της μέρας μετράται ως η επί τοις εκατό αύξηση της απόδοσης, εφόσον η θέση που πήραμε είναι σωστή. Αυτή η διαδικασία τρέχει για μεγάλη χρονική περίοδο ώστε να φανεί το κατά πόσο το μοντέλο μπορεί να δώσει σταθερά κέρδη. Το μοντέλο επιτυγχάνει την καλύτερη επίδοση στην TSLA, η οποία όμως φαίνεται πως έχει υψηλό ρίσκο. Η σωρευτική απόδοση της κινείται για μεγάλο χρονικό διάστημα πάνω από το 100% και φτάνει σε επίπεδα της τάξης του 150–170%, αλλά υπάρχουν μεγάλες ενδιάμεσες πτώσεις οι οποίες δείχνουν ότι υπάρχει σε χρονικά διαστήματα μπορεί να χαθεί πολύ κέρδος. Οι SPY και XOM ακολουθούν θετική τροχιά της τάξης του 30–60%, στοιχείο που υποδηλώνει ικανοποιητική ικανότητα πρόβλεψης κατεύθυνσης τόσο στην ευρύτερη αγορά όσο και στον ενεργειακό κλάδο. Η AMD παρουσιάζει βαθύ Drawdown (πτώση) περίπου στο μέσο του δείγματος, το οποίο όμως ακολουθείται από ανάκαμψη, καταλήγοντας σε σωρευτική απόδοση περίπου 60–

80%. Η PG διαγράφει ηπιότερη αλλά σταθερότερη πορεία με τελικό αποτέλεσμα 20–40%, ενώ η JNJ κινείται οριακά γύρω από το μηδέν. Η AAPL, τέλος, καταλήγει σε αρνητικό αποτέλεσμα, δείχνοντας ότι το μοντέλο δυσκολεύτηκε να συλλάβει σωστά την κατεύθυνση της συγκεκριμένης μετοχής.


Η συνοπτική αποτύπωση της ίδιας στρατηγικής παρουσιάζεται μέσω του δείκτη Sharpe (Σχήμα 5.20), του Total Return (Σχήμα 5.19) και του Max Drawdown (Σχήμα 5.21). Η TSLA ξεχωρίζει με συνολικό κέρδος περίπου 120%, το οποίο όμως συνοδεύεται από εξαιρετικά υψηλό μέγιστο Drawdown της τάξης του 110%. Η AMD ακολουθεί με 59% συνολική απόδοση, επίσης με σημαντικά ενδιάμεσα τραβήγματα. Το SPY εμφανίζεται με συνολικό κέρδος περίπου 44%, το καλύτερο Sharpe ratio (σχέση απόδοσης/κινδύνου) και πολύ χαμηλότερο Drawdown. Η επένδυση σε αυτό το ETF δίνει σταθερές αποδόσεις με μικρό ρίσκο. Τα Sharpe ratio στις TSLA και AMD είναι επίσης μεγάλα αλλά λόγω των υψηλών αποδόσεων και όχι του μικρού κινδύνου. Η XOM και η PG αποδίδουν μεσαία αποτελέσματα (31% και 19% αντίστοιχα), με Sharpe ratio 0,01–0,02 και Drawdowns γύρω στο 0,70 και 0,30. Η JNJ κινείται οριακά θετικά (3%), με σχεδόν μηδενικό Sharpe, γεγονός που δείχνει περιορισμένη δυνατότητα αξιοποίησης της μετοχής. Αντίθετα, η AAPL αποτελεί την αρνητική εξαίρεση, με τελικό αποτέλεσμα -18% και αρνητικό Sharpe ratio, παρότι το Max Drawdown παραμένει υψηλό.

Η συνολική εικόνα των αποτελεσμάτων είναι τελείως διαφορετική από αυτή του μοντέλου μηδενικής προσαρμογής. Η χρήση συνόλου εκπαίδευσης, η βελτιστοποίηση των υπερ-παραμέτρων και η χρήση χαρακτηριστικών εισόδου έφερε το TTM σε μορφή που αποδίδει ικανοποιητικά στις προβλέψεις χρονοσειρών μετοχών, ακόμη και με χρήση πολύ μικρού συνόλου δεδομένων εκπαίδευσης. Η βελτιστοποιημένη απόδοση σε όλα τα καθεστώτα μεταβλητότητας και σε όλες τις κλίμακες δείχνει πως το μοντέλο μπορεί να ανταποκριθεί σε προβλέψεις σε ευρύ φάσμα της αγοράς. Εκτός της μακροπρόθεσμης μεταβλητότητας που αντιπροσωπεύεται από τα σύνολα αξιολόγησης, τα διαγράμματα κυλιόμενης μεταβλητότητας δείχνουν πως το μοντέλο αντιδρά καλά σε βραχυπρόθεσμα σκαμπανεβάσματα τιμών. Ακόμη και σε περιπτώσεις που τα σφάλματα είναι μεγάλα, οι αποδόσεις στην πρόβλεψη κατεύθυνσης είναι πολύ ενθαρρυντικές για την ικανότητα του μοντέλου. Στα παράθυρα γεγονότων υπάρχει ασυνεπής συμπεριφορά, αναδεικνύοντας πως ακόμα το TTM δεν είναι σε θέση να προβλέπει εξαιρετικές περιπτώσεις τις αγορές. Για σταθερά αποτελέσματα σε τέτοιες περιπτώσεις ίσως θα χρειαστεί οι επόμενες εκδόσεις του TTM να έχουν πιο βαθιά αρχιτεκτονική,


δηλαδή με περισσότερες παραμέτρους (βάρη).




Σχήμα 5.18: Διάγραμμα αποδόσεων επενδυτικής στρατηγικής - TTM



Σχήμα 5.19: Sharpe Ratio στρατηγικής ανά μετοχή - TTM



Σχήμα 5.20: Total Return στρατηγικής ανά μετοχή - TTM



Σχήμα 5.21: Max Drawdown στρατηγικής ανά μετοχή - TTM

Κεφάλαιο 6

Πρόβλεψη με χρήση στατιστικών μεθόδων και μοντέλων βαθιάς μάθησης

6.1 Εισαγωγή

Σε αυτό το κεφάλαιο γίνονται προβλέψεις με στατιστικές μεθόδους και με μοντέλα βαθιάς μάθησης. Οι μελέτες, ως προς τα αποτελέσματα που παράγονται, είναι ίδιες με τις μελέτες που έγιναν για το TTM, δηλαδή πίνακες μετρικών, μέτρηση κυλιόμενης μεταβλητότητας και απόδοση επενδυτικής στρατηγικής. Σε κάθε ενότητα γίνεται ένας σχολιασμός ως προς τη σύγκριση με το TTM. Συγκεντρωτικά συμπεράσματα εξηγούνται στο επόμενο κεφάλαιο. Στην πρώτη ενότητα γίνεται χρήση της κλασσικής στατιστικής μεθόδου ARIMA. Στην δεύτερη ενότητα εκπαιδεύεται ένα νευρωνικό δίκτυο LSTM δύο στρωμάτων και στην τρίτη χρησιμοποιείται ο iTransformer. Για όλα τα μοντέλα γίνεται αποτίμηση των αποτελεσμάτων και στις επτά μετοχές. Τα σύνολα αξιολόγησης είναι τα ίδια με το προηγούμενο κεφάλαιο. Η εκπαίδευση γίνεται στο 42% των δεδομένων, για να αξιολογηθούν οι προβλέψεις σε παρόμοιες συνθήκες με αυτές του TTM.

6.2 ARIMA

Σε αυτήν την ενότητα μελετάται το μοντέλο ARIMA. Αρχικά, γίνεται προσδιορισμός των καλύτερων παραμέτρων και στην συνέχεια αποτίμηση των αποτελεσμάτων. Το ARIMA αποτελεί είναι ένα μονοδιάστατο μοντέλο χρονοσειρών που προσαρμόζεται στις στατιστικές ιδιότητες μιας συγκεκριμένης χρονοσειράς πάνω στην οποία εκπαιδεύεται. Οι παράμετροι

του εκτιμώνται με στόχο να αποτυπώσουν την αυτοσυσχέτιση, την τάση και τη δομή του θορύβου αυτής της μεμονωμένης σειράς. Ένα μοντέλο που έχει προσαρμοστεί σε μία μετοχή δεν μπορεί γενικά να εφαρμοστεί σε μια άλλη χωρίς σημαντική απώλεια ακρίβειας. Για αυτό το λόγο σε αυτό το πείραμα κάθε χρονοσειρά μοντελοποιείται με ξεχωριστό μοντέλο ARIMA, σε αντίθεση με το TTM όπου υπήρχε η δυνατότητα να χρησιμοποιηθεί μόνο το SPY.

6.2.1 Προσδιορισμός παραμέτρων ARIMA

Πριν τη χρήση του μοντέλου ARIMA για την πρόβλεψη μετοχών, πρέπει να βρεθούν οι όροι AR, I και MA (ή παράμετροι (p, d, q) , βλ. κεφάλαιο 2). Αυτή η διαδικασία πρέπει να γίνει για όλες τις μετοχές. Παρακάτω θα παρουσιαστούν τα αποτελέσματα για την AAPL. Η διαδικασία είναι η ίδια και για τις υπόλοιπες. Στο τέλος την υποενότητας υπάρχουν σχόλια για τα αποτελέσματα των μελετών για όλες τις μετοχές.

Αρχικά, ελέγχεται το αν η χρονοσειρά είναι στάσιμη. Μια στάσιμη χρονοσειρά χαρακτηρίζεται από σταθερό μέσο όρο και διακύμανση στον χρόνο. Για τον έλεγχο χρησιμοποιείται το τεστ ADF, το οποίο εξετάζει τη μηδενική υπόθεση ότι η σειρά έχει μοναδιαία ρίζα, δηλαδή δεν είναι στάσιμη. Η απόφαση μπορεί να ληφθεί είτε μέσω της τιμής p είτε συγκρίνοντας το ADF statistic με τις κρίσιμες τιμές για επίπεδα σημαντικότητας 1%, 5% και 10%. Τιμή p μικρότερη του 0,05 οδηγεί σε απόρριψη της μηδενικής υπόθεσης. Αντίστοιχα, ADF statistic μικρότερο από την αντίστοιχη κρίσιμη τιμή συνεπάγεται το ίδιο συμπέρασμα. Όταν η σειρά δεν είναι στάσιμη, εφαρμόζεται διαφορική μετατροπή τάξης d , κατά την οποία κάθε παρατήρηση αντικαθίσταται από τη διαφορά της με την προηγούμενη. Το αποτέλεσμα του τεστ ADF για την AAPL φαίνεται στο Σχήμα 6.1.

Ο αρχικός έλεγχος έδωσε ADF statistic ίσο με 1,8718 και p -value 0,9985, τιμές που δεν επιτρέπουν την απόρριψη της μηδενικής υπόθεσης, συνεπώς η αρχική σειρά δεν είναι στάσιμη και απαιτείται διαφοροποίηση. Μετά από μία διαφορική μετατροπή ($d = 1$), το ADF statistic έγινε $-16,1243$ με p -value $4,86 \times 10^{-29}$, δηλαδή σημαντικά μικρότερο από όλες τις κρίσιμες τιμές. Η διαφοροποιημένη σειρά είναι στάσιμη μετά από $d = 1$.


Στη συνέχεια, εξετάζονται τα διαγράμματα ACF και PACF (Σχήμα 6.2) για τον προσδιορισμό των παραμέτρων p και q . Τα διαγράμματα διαβάζονται ως εξής. Αν για τις πρώτες τιμές (μικρά lags) υπάρχουν μεγάλες τιμές ACF/PACF, εκτός της ζώνης εμπιστοσύνης, σημαίνει ότι υπάρχει εξάρτηση της τωρινής τιμής (μηδενικό lag) από το παρελθόν, και χρειάζονται

```
ADF Test: Original
ADF stat: 1.8718 | p-value: 0.9985 | lags: 16 | nobs: 3875
Critical (1%): -3.4320
Critical (5%): -2.8623
Critical (10%): -2.5672
Not stationary

ADF Test: Differenced (d=1)
ADF stat: -16.1243 | p-value: 4.86e-29 | lags: 15 | nobs: 3875
Critical (1%): -3.4320
Critical (5%): -2.8623
Critical (10%): -2.5672
Stationary
```

Σχήμα 6.1: Αποτελέσματα τεστ ADF

τιμές p και q .



Σχήμα 6.2: Διαγράμματα ACF/PACF

Στα διαγράμματα της διαφοροποιημένης σειράς όλες οι ράβδοι του ACF (πλην του μηδενικού lag) βρίσκονται πολύ κοντά στο μηδέν και εντός της ζώνης εμπιστοσύνης. Αντίστοιχα, το PACF δεν παρουσιάζει σημαντικές αιχμές σε μικρά lags και οι εκτιμήσεις παραμένουν μικρές και εντός ζώνης. Το ζεύγος ACF/PACF συνεπώς δεν δείχνει ουσιαστική γραμμική εξάρτηση που να δικαιολογεί πρόσθετους όρους AR ή MA πέραν της διαφοροποίησης.


Το επόμενο βήμα είναι να εκτιμηθεί ως βασική προδιαγραφή το ARIMA(0,1,0) σε όλο το δείγμα, με στόχο να γίνει ένας αρχικός διαγνωστικός έλεγχος σφαλμάτων πριν την οριστική πρόβλεψη. Για την εκτίμηση χρησιμοποιούνται οι συναρτήσεις της python `.plot_diagnostics()`

(Σχήμα 6.3) και `.sarimax()` (Σχήμα 6.4) οι οποίες παράγουν: (i) Standardized residuals over time, η οποία είναι γραφική παράσταση των υπολοίπων στον χρόνο η οποία μας δείχνει αν υπάρχουν συστηματικά μοτίβα ή αλλαγές στη διακύμανση. Θέλουμε να δούμε τυχαία κατανομή γύρω από το 0 χωρίς ορατή δομή, (ii) Histogram & KDE plot, δηλαδή το ιστόγραμμα των υπολοίπων, με υπερτιθέμενη εκτίμηση πυκνότητας (KDE) και την καμπύλη κανονικής κατανομής $N(0,1)$. Δείχνει αν τα υπόλοιπα ακολουθούν κατά προσέγγιση κανονική κατανομή, (iii) Normal Q–Q plot, το οποίο συγκρίνει την κατανομή των υπολοίπων με την ιδανική κανονική κατανομή. Αν τα σημεία βρίσκονται πάνω στη διαγώνιο, η κατανομή είναι κοντά στην κανονική. Αποκλίσεις στις άκρες υποδεικνύουν βαριές ουρές. (iv) Correlogram (ACF των υπολοίπων), το οποίο δείχνει τις αυτοσυσχετίσεις των υπολοίπων για διάφορα lags. Πρέπει οι μπάρες να βρίσκονται μέσα στα μπλε όρια εμπιστοσύνης ως ένδειξη ότι δεν μένει σημαντική αυτοσυσχέτιση. (v) Ljung–Box τεστ, το οποίο ελέγχει αν τα υπόλοιπα έχουν αυτοσυσχέτιση (δηλαδή αν υπάρχει κάποια προβλέψιμη δομή που το μοντέλο δεν έχει πιάσει). Αν $p\text{-value} > 0,05$, τα υπόλοιπα είναι ασυσχέτιστα, (vi) Jarque–Bera τεστ το οποίο ελέγχει αν η κατανομή των υπολοίπων είναι κανονική (συμμετρική, χωρίς βαριές ουρές). Αν $p\text{-value} > 0,05$ τότε είναι περίπου κανονική. (vii) Heteroskedasticity τεστ, το οποίο ελέγχει αν η διακύμανση των υπολοίπων είναι σταθερή στον χρόνο. Αν $p\text{-value} > 0,05$ υπάρχει σταθερή μεταβλητότητα.

SARIMAX Results						
=====						
Dep. Variable:	close		No. Observations:	3892		
Model:	SARIMAX(0, 1, 0)		Log Likelihood	-7239.092		
Date:	Sat, 09 Aug 2025		AIC	14482.184		
Time:	21:52:22		BIC	14494.716		
Sample:	01-29-2010		HQIC	14486.633		
	- 12-30-2024					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

intercept	0.0633	0.025	2.534	0.011	0.014	0.112
sigma2	2.4206	0.022	112.202	0.000	2.378	2.463
=====						
Ljung-Box (L1) (Q):			1.59	Jarque-Bera (JB):	19478.90	
Prob(Q):			0.21	Prob(JB):	0.00	
Heteroskedasticity (H):			111.91	Skew:	0.12	
Prob(H) (two-sided):			0.00	Kurtosis:	13.96	
=====						

Σχήμα 6.4: Αποτελέσματα συνάρτησης `sarimax()`



Σχήμα 6.3: Αποτελέσματα συνάρτησης `plot_diagnostics()`

Για την AAPL τα διαγνωστικά τεστ παρέχουν συνεπή εικόνα ως προς την αυτοσυσχέτιση αλλά όχι ως προς την κανονικότητα και τη σταθερότητα της διακύμανσης: το Ljung–Box δεν απορρίπτει την υπόθεση μη ύπαρξης σειριακής συσχέτισης στα κατάλοιπα ($Q = 1, 59$, $p = 0, 21$), ενώ το Jarque–Bera απορρίπτει την κανονικότητα ($JB = 19478, 90$, $p < 0, 001$) και ο έλεγχος ετεροσκεδαστικότητας υποδηλώνει μεταβαλλόμενη διακύμανση ($111, 91$, $p < 0, 001$).

Τα διαγράμματα υπολοίπων επιβεβαιώνουν τα παραπάνω ευρήματα. Τα τυποποιημένα υπόλοιπα ταλαντώνονται γύρω από το μηδέν χωρίς συστηματικό περιοδικό μοτίβο, αλλά παρουσιάζουν σαφείς μεταβολές ως προς την ένταση μετά το 2020, ενισχύοντας την ένδειξη ετεροσκεδαστικότητας. Το ιστόγραμμα με την εκτιμώμενη πυκνότητα εμφανίζει εντονότερη κορυφή και βαρύτερες ουρές σε σχέση με την κανονική κατανομή, ενώ το διάγραμμα Normal Q–Q δείχνει αποκλίσεις στα άκρα, ιδίως στο άνω τεταρτημόριο. Τέλος, το Correlogram των υπολοίπων τοποθετεί όλες τις ράβδους εντός των ορίων εμπιστοσύνης, άρα δεν προκύπτει ένδειξη υπολειπόμενης γραμμικής εξάρτησης.

Συνολικά, το $ARIMA(0,1,0)$ περιγράφει ικανοποιητικά τη δυναμική της χρονοσειράς, αλλά ταυτόχρονα παραμένουν κάποια ζητήματα στη μορφή της διακύμανσης. Για καλύ-

τερα αποτελέσματα ως προς τη διακύμανση θα μπορούσαν να χρησιμοποιηθούν άλλα στατιστικά μοντέλα όπως το GARCH.

Η ίδια διαδικασία εφαρμόστηκε σε όλες τις μετοχές και τα αποτελέσματα παρουσίασαν παρόμοια χαρακτηριστικά. Από την ανάλυση των διαγραμμάτων ACF και PACF προέκυψε ότι οι ράβδοι, εκτός του μηδενικού lag, παραμένουν πολύ κοντά στο μηδέν και εντός των ορίων εμπιστοσύνης, χωρίς να εμφανίζονται σημαντικές αιχμές. Δεν εντοπίστηκε ένδειξη σταθερής αποσύνθεσης στο ACF ούτε απότομης αποκοπής στο PACF. Η εφαρμογή μίας μόνο διαφοροποίησης ($d = 1$) ήταν επαρκής για την αφαίρεση της αυτοσυσχέτισης, καθιστώντας τις σειρές στάσιμες, χωρίς να απαιτούνται όροι AR ή MA. Όσον αφορά την μελέτη των υπολοίπων με παρόμοιο τρόπο υπήρχε συνέπεια ως προς την αυτοσυσχέτιση, αλλά όχι ως προς τη διακύμανση.

Η υπεροχή του απλού ARIMA(0,1,0) έναντι πιο σύνθετων μοντελοποιήσεων εξηγείται από τη φύση των χρηματιστηριακών χρονοσειρών. Οι τιμές τείνουν να ακολουθούν μια διαδικασία τύπου random walk, όπου η καλύτερη πρόβλεψη της μελλοντικής τιμής είναι η τρέχουσα τιμή συν ένα τυχαίο σφάλμα. Στατιστικά, η συμπεριφορά αυτή οδηγεί σε έντονη μη στασιμότητα, η οποία αντιμετωπίζεται με μία διαφοροποίηση ($d = 1$). Η διαφοροποιημένη σειρά προσεγγίζει διαδικασία λευκού θορύβου, περιορίζοντας την ανάγκη για πρόσθετους όρους AR ή MA.

6.2.2 Αποτελέσματα προβλέψεων

Στο σύνολο αξιολόγησης (Πίνακας 6.1) το ARIMA(0,1,0) συμπεριφέρεται άνισα ανά μετοχή και καθεστώς αγοράς. Σε όλες τις μετοχές αποδίδει πολύ καλά ως προς τα σφάλματα, αλλά η πρόβλεψη κατεύθυνσης είναι προβληματική. Η XOM αποτελεί εξαίρεση, επιτυγχάνοντας τα υψηλότερα ποσοστά Hit Rate/Precision/Recall/F1. Το SPY εμφανίζει μικρό ποσοστιαίο σφάλμα παρόλο που τα RMSE και MAE είναι από τα υψηλότερα στον πίνακα. Ανά καθεστώς (Πίνακας 6.2), το μοτίβο είναι πιο σταθερό. Σε υψηλή μεταβλητότητα τα σφάλματα μεγαλώνουν και η κατεύθυνση πιέζεται, στη χαμηλή μεταβλητότητα τα σφάλματα συρρικνώνονται και οι κατευθυντικές μετρικές κατά μέσο όρο βελτιώνονται, ενώ μετά από αντιστροφή τάσης βλέπουμε μικρό κέρδος στην κατεύθυνση. Σε πλάγια/ακατάστατη κίνηση, τα απόλυτα σφάλματα αυξάνονται και το Hit Rate πέφτει κάτω από το 0,50. Στα παράθυρα γεγονότων (Πίνακας 6.3) το βελτιώνεται η πρόβλεψη κατεύθυνσης για αρκετές μετοχές, αλλά συνεχίζει να είναι χαμηλή. Σε γεγονότα που το καθεστώς τείνει προς μια πιο συνεπή βραχυπρόθεσμη

τάση, ανεξαρτήτως κατεύθυνσης, το ARIMA καταφέρνει να συνεχίσει στη φορά της κίνησης.

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	1,1081	1,7537	1,6868	0,421	0,462	0,457	0,459
TSLA	5,6888	7,8264	3,1606	0,442	0,467	0,471	0,469
XOM	1,1987	1,6114	1,6136	0,527	0,566	0,570	0,568
SPY	4,5348	5,8346	1,1638	0,510	0,413	0,417	0,415
JNJ	0,8636	1,4005	0,7583	0,510	0,540	0,543	0,541
AMD	0,6014	0,9063	2,9458	0,448	0,466	0,463	0,464
PG	0,4215	0,5837	0,6989	0,521	0,473	0,473	0,473

Πίνακας 6.1: Πίνακας μετρικών στο σύνολο αξιολόγησης - ARIMA

Regime Type	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
High-Volatility	3,6217	5,6038	2,5455	0,490	0,487	0,487	0,487
Low-Volatility	1,0630	1,5538	0,8008	0,513	0,522	0,523	0,522
Post-Trend Reversal	1,3065	1,8480	1,3529	0,503	0,509	0,511	0,510
Sideways/Chop	2,9227	4,2097	0,7957	0,496	0,528	0,529	0,529


Πίνακας 6.2: Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - ARIMA

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	1,6830	2,4108	1,3100	0,488	0,510	0,510	0,510
TSLA	5,1559	8,0718	2,7930	0,495	0,507	0,507	0,507
XOM	0,9300	1,2852	1,3960	0,517	0,507	0,512	0,509
SPY	2,9227	4,2097	0,7957	0,496	0,528	0,529	0,529
JNJ	1,0956	1,5934	0,7832	0,533	0,528	0,529	0,528
AMD	2,0876	3,1357	2,2980	0,484	0,467	0,467	0,467
PG	1,0304	1,5141	0,8184	0,493	0,516	0,517	0,516

Πίνακας 6.3: Πίνακας μετρικών στα παράθυρα γεγονότων - ARIMA

Η σχέση βραχυπρόθεσμης μεταβλητότητας/σφάλματος για το ARIMA υπολογίστηκε σε σύγκριση με το τελικό βελτιστοποιημένο μοντέλο TTM [4] . Σε όλες σχεδόν τις μετοχές, όσο

αυξάνεται η βραχυπρόθεσμη μεταβλητότητα, τόσο αυξάνει και το μέγεθος του σφάλματος. Υπάρχει συστηματική υπεροχή του τελικού μοντέλου TTM, καθώς τα σημεία του βρίσκονται χαμηλότερα και είναι πιο συμπαγή από τα αντίστοιχα του ARIMA. Δηλαδή, το τελικό μοντέλο δίνει μικρότερα και πιο σταθερά σφάλματα, ειδικά όταν η μεταβλητότητα ανεβαίνει. Σε υψηλές τιμές μεταβλητότητας, το ARIMA εμφανίζει συχνότερες ακραίες τιμές. Ενδεικτικά τα αποτελέσματα για την AMD φαίνονται στο Σχήμα 6.5)




Σχήμα 6.5: Διάγραμμα κυλιόμενης μεταβλητότητας/σφάλματος για την AMD - ARIMA [4]


Στο διάγραμμα της επενδυτικής στρατηγικής (Σχήμα 6.6) υπάρχουν σημαντικές διαφοροποιήσεις σε σχέση με το τελικό μοντέλο TTM. Υπενθυμίζοντας, σε αυτό το πείραμα κοιτάμε το μοντέλο για το αν προβλέπει άνοδο ή κάθοδο για κάθε επόμενη μέρα, και παίρνουμε αυτή τη θέση ως επενδυτές. Το κέδρος της μέρας μετράται ως η επί τοις εκατό αύξηση της απόδοσης, εφόσον η θέση που πήραμε είναι σωστή. Το ARIMA οδηγεί σε πολύ ισχυρή τελική επίδοση στην AMD, που πλησιάζει ή ξεπερνά το 100%, αλλά έχει πολύ μεγάλα σκαμπανεβάσματα στις αποδόσεις. Η TSLA παραμένει ως μετοχή μεγάλων σωρευτικών αποδόσεων αλλά με έντονα Drawdowns. Η AAPL παραμένει κοντά στο μηδέν ή οριακά αρνητική, και η JNJ καταλήγει χαμηλά θετική.

Στα διαγράμματα για τα Sharpe Ratio (Σχήμα 6.7) , Total Return (Σχήμα 6.8) και Max Drawdown (Σχήμα 6.9) η TSLA και πάλι ηγείται με Total Return = 109% και Sharpe ratio = 0,02, αλλά με ακόμη μεγαλύτερο Max Drawdown = 1,42. Η AMD είναι πολύ δυνατή στο ARIMA, με 113% τελικό κέρδος, Sharpe Ratio = 0,02 και Max Drawdown = 1,30, αλλά αυτοί οι δείκτες δεν δείχνουν τις μεγάλες ασυνέπειες που αναδείχθηκαν στο διάγραμμα. Το SPY εμφανίζει ισορροπημένες επιστροφές με περίπου 72% στο Total Return, το υψηλότερο Sharpe ratio (0,04) και σχετικά χαμηλό Max Drawdown (0.39). Η PG και η XOM δίνουν μικρομεσαίες αποδόσεις (22% και 10%) με χαμηλά έως μεσαία Drawdowns, ενώ η JNJ μένει χαμηλά (6% απόδοση). Η AAPL παραμένει αρνητική (-4%) με Max Drawdown πάνω από 1.0.


Συνολικά τα αποτελέσματα της στρατηγικής είναι σύμφωνα με τα αποτελέσματα στους πίνακες και στα διαγράμματα κυλιόμενης μεταβλητότητας. Το ARIMA είναι καλύτερο στις μετρικές σφάλματος. Άρα, όταν προβλέπει σωστά την κατεύθυνση τα επί τοις εκατό κέρδη θα είναι περισσότερα. Όμως, είναι χειρότερο στις προβλέψεις κατεύθυνσης, που σημαίνει πως υπάρχουν πιο συχνά απώλειες και οι γραμμές στο διάγραμμα απόδοσης φαίνονται με πολύ περισσότερα σκαμπανεβάσματα σε σχέση με το TTM. Μπορεί μακροπρόθεσμα, και σε περιόδους μεγάλων ανόδων, να δίνει πιο πολλά κέρδη, αλλά έχει πιο ασταθή συμπεριφορά βραχυπρόθεσμα.




Σχήμα 6.6: Διάγραμμα αποδόσεων επενδυτικής στρατηγικής - ARIMA



Σχήμα 6.7: Sharpe Ratio στρατηγικής ανά μετοχή - ARIMA



Σχήμα 6.8: Total Return στρατηγικής ανά μετοχή - ARIMA



Σχήμα 6.9: Max Drawdown στρατηγικής ανά μετοχή - ARIMA

6.3 LSTM

Σε αυτή την ενότητα γίνεται η εκπαίδευση και αξιολόγηση με χρήση του μοντέλου LSTM. Αρχικά, περιγράφεται η δομή του μοντέλου και στην συνέχεια αποτιμάται η απόδοση του στην πρόβλεψη όλων των μετοχών. Η εκπαίδευση του έγινε αποκλειστικά στο SPY, καθώς τα νευρωνικά δίκτυα, λόγω του αριθμού των βαρών τους, έχουν ικανότητα να προβλέπουν άγνωστα δεδομένα, εφόσον αυτά είναι στην ίδια μορφή με το σύνολο εκπαίδευσης.

6.3.1 Δομή LSTM

Η εκπαίδευση και οι προβλέψεις για το LSTM πρέπει να γίνουν σε στάσιμη χρονοσειρά. Για αυτό το λόγο το μοντέλο προβλέπει τον ημερήσιο λογαριθμικό δείκτη απόδοσης (log-return) της τιμής κλεισίματος:

$$r_t = \log(P_t) - \log(P_{t-1})$$

όπου r_t ο δείκτης απόδοσης και P_t στην περίπτωση μας η τιμή κλεισίματος. Η πρόβλεψη γίνεται σε επίπεδο απόδοσης και όχι πραγματικής τιμής κλεισίματος, ενώ στη συνέχεια οι αποδόσεις μετατρέπονται σε τιμές, εξασφαλίζοντας έναν βαθμό στασιμότητας. Ως είσοδοι χρησιμοποιούνται τα open, high, low, καθώς και οι τεχνικοί δείκτες sma_20, ema_20, wma_20, tema_20, bb_upper και bb_lower. Η προεπεξεργασία περιλαμβάνει τον υπολογισμό των λογαριθμικών αποδόσεων από την τιμή κλεισίματος μέσω της συνάρτησης `numpy.diff()`, με εισαγωγή $r_0 = 0$. Το σύνολο χωρίζεται σε σύνολο εκπαίδευσης και σύνολο αξιολόγησης με το 42% των παρατηρήσεων να χρησιμοποιείται για εκπαίδευση, ώστε να υπάρχει άμεση σύγκριση με το TTM. Η κλιμάκωση των εισόδων γίνεται με `MinMaxScaler`, ο οποίος εφαρμόζεται σε όλα τα χαρακτηριστικά εισόδου του συνόλου εκπαίδευσης, ενώ για τον στόχο εφαρμόζεται `StandardScaler`, ώστε το μοντέλο να μάθει πάνω σε κανονικοποιημένες αποδόσεις.

Η δημιουργία δειγμάτων γίνεται με παράθυρο σταθερού μήκους `LOOKBACK = 512` ημερών. Για κάθε χρονικό δείκτη i στην εκπαίδευση, η είσοδος X_i είναι ένας πίνακας $512 \times F$, δηλαδή η ακολουθία $[x_{i-512}, \dots, x_{i-1}]$, όπου F είναι ο αριθμός χαρακτηριστικών. Ο στόχος για το ίδιο δείγμα είναι το r_i . Για να υπάρχει διαθέσιμο το P_{t-1} στον υπολογισμό της απόδοσης, οι έγκυροι χρονικοί δείκτες ξεκινούν από `LOOKBACK + 1`. Η αρχιτεκτονική του LSTM είναι σειριακή και υλοποιείται με την `Keras Sequential`. Περιλαμβάνει δύο στοιβαγμένα στρώματα LSTM και ένα γραμμικό στρώμα για την έξοδο. Συγκεκριμένα, το δίκτυο

δέχεται είσοδο με σχήμα $(512, F)$, ακολουθεί ένα LSTM 128 στοιχείων, στη συνέχεια ένα LSTM 64 στοιχείων και τέλος ένα στρώμα που προβλέπει την κανονικοποιημένη απόδοση της επόμενης ημέρας. Η εκπαίδευση γίνεται με συνάρτηση κόστους το MSE και βελτιστοποιητή τον Adam. Η εκπαίδευση γίνεται σε 40 εποχές.

6.3.2 Αποτελέσματα προβλέψεων

Οι μετρικές στα σύνολα αξιολόγησης για το LSTM (Πίνακας 6.4), ως προς τα σφάλματα είναι παρόμοιες με αυτές του ARIMA, με χαμηλά ποσοστά σε RMSE, MAE και MAPE για όλες τις μετοχές, αλλά παρουσιάζεται μεγαλύτερη συνέπεια στην πρόβλεψη κατεύθυνσης. Αυτό επιβεβαιώνεται και από και από τα αποτελέσματα ανά καθεστώς μεταβλητότητας (Πίνακας 6.4). Η εικόνα είναι αντίθετη στα παράθυρα γεγονότων (Πίνακας 6.4), όπου το LSTM παρουσιάζει μεγαλύτερη ασυνέπεια στην κατεύθυνση, ενώ το ARIMA είχε πιο σταθερή απόδοση σε αυτά τα δύσκολα περιβάλλοντα. Σε σχέση με το TTM έχει σαφώς καλύτερη απόδοση στα σφάλματα, αλλά πάλι χειρότερες και στα παράθυρα γεγονότων πολύ χειρότερες επιδόσεις στην πρόβλεψη της κατεύθυνσης.

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	1,8344	2,5443	1,4084	0,483	0,505	0,520	0,513
TSLA	5,3074	8,1808	2,8496	0,496	0,508	0,521	0,514
XOM	0,9543	1,3045	1,4211	0,513	0,503	0,516	0,509
SPY	3,716	4,8984	0,971	0,496	0,528	0,540	0,534
JNJ	1,1067	1,5985	0,791	0,532	0,528	0,542	0,534
AMD	2,2590	3,3088	2,450	0,482	0,467	0,486	0,476
PG	1,1267	1,5779	0,889	0,487	0,511	0,524	0,517

Πίνακας 6.4: Πίνακας μετρικών στο σύνολο αξιολόγησης - LSTM


Regime Type	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
High-Volatility	3,7832	5,7448	2,6496	0,489	0,487	0,504	0,495
Low-Volatility	1,1167	1,5882	0,8393	0,510	0,519	0,533	0,526
Post-Trend Reversal	1,3944	1,9244	1,4147	0,498	0,504	0,518	0,511
Sideways/Chop	3,716	4,8984	0,971	0,496	0,528	0,540	0,534

Πίνακας 6.5: Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - LSTM

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	1,1720	1,7882	1,7814	0,426	0,467	0,467	0,467
TSLA	5,8203	7,9328	3,2248	0,446	0,471	0,485	0,478
XOM	1,2128	1,6170	1,631	0,519	0,558	0,577	0,567
SPY	4,6639	5,9926	1,190	0,498	0,404	0,426	0,414
JNJ	0,8760	1,4020	0,768	0,513	0,542	0,556	0,549
AMD	0,6192	0,9305	3,035	0,463	0,482	0,507	0,495
PG	0,4184	0,5810	0,694	0,518	0,470	0,488	0,479


Πίνακας 6.6: Πίνακας μετρικών στα παράθυρα γεγονότων - LSTM

Στη σχέση βραχυπρόθεσμης μεταβλητότητας/σφάλματος, το μοτίβο είναι πως όσο αυξάνεται η βραχυπρόθεσμη μεταβλητότητα, τόσο διευρύνεται η κατανομή των σφαλμάτων [4]. Ωστόσο, το τελικό μοντέλο σχηματίζει συστηματικά πυκνότερη συγκέντρωση κοντά στο 0 και με μικρότερη ουρά σε σχέση με το LSTM. Στις AAPL (Σχήμα 6.10) και XOM υπάρχει ήπια θετική κλίση σφάλματος-μεταβλητότητας. Το LSTM εμφανίζει συχνότερες ακραίες τιμές (>5), ενώ το τελικό μοντέλο παραμένει συμπαγές σε χαμηλά σφάλματα. Ο όγκος των σφαλμάτων του τελικού μοντέλου μετατοπίζεται χαμηλότερα, αν και παραμένουν να υπάρχουν ακραίες τιμές. Στις SPY, JNJ και PG υπάρχει παρόμοια επίδοση με λίγο μεγαλύτερα σφάλματα για το LSTM.



Σχήμα 6.10: Διάγραμμα κυλιόμενης μεταβλητότητας/σφάλματος για την AAPL - LSTM [4]

Στην επενδυτική στρατηγική (Σχήμα 6.11) τα αποτελέσματα είναι σχεδόν πανομοιότυπα με το ARIMA, αλλά με λίγο υψηλότερα μέγιστα. Η TSLA έπειτα από μια αρχική αστάθεια, μπαίνει σε παρατεταμένη ανοδική φάση με επαναλαμβανόμενες κορυφές $>100\%$ και κλείσιμο γύρω στο $+110\text{--}120\%$. Η AMD παρουσιάζει παρόμοια συμπεριφορά, με μεγάλα ράλλυ και εξίσου μεγάλες διορθώσεις, αλλά τερματίζει επίσης ψηλά ($+110\text{--}120\%$). Το SPY ανεβαίνει σταθερά, χωρίς ακραίες ταλαντώσεις, και καταλήγει κοντά στο $+60\text{--}70\%$. Η JNJ σκαρφαλώνει μέχρι περίπου $+60\text{--}70\%$ αλλά υποχωρεί προς το τέλος σε $+30\text{--}40\%$, ενώ η PG κινείται με μικρές κλίσεις και κλείνει γύρω στο $+15\text{--}25\%$. Η XOM μετά από ράλλυ στο μέσο της περιόδου ακολουθεί παρατεταμένη αποδυνάμωση και μόλις στο τέλος ανακάμπτει κοντά στο μηδέν έως $+10\%$.




Σχήμα 6.11: Διάγραμμα αποδόσεων επενδυτικής στρατηγικής - LSTM


Στο Sharpe Ratio (Σχήμα 6.13) το LSTM αναδεικνύει καθαρό νικητή το SPY (0,04), άρα η στρατηγική παράγει την υψηλότερη απόδοση ανά μονάδα κινδύνου όταν εφαρμόζεται στον ευρύ δείκτη αγοράς. Οι TSLA και AMD ακολουθούν (0,02), υποδεικνύοντας ελκυστική, αλλά όχι κορυφαία σχέση ρίσκου-απόδοσης. Οι PG (0,01) και XOM/JNJ (0,00) κινούνται οριακά πάνω από το μηδέν, με AAPL να εμφανίζει ελαφρά αρνητική τιμή. Η εικόνα στα Total Returns (Σχήμα 6.12) αναδεικνύει τις ελαφρώς μεγαλύτερες κορυφές σε σχέση με το ARIMA. Οι TSLA και AMD γράφουν τριμήφια κέρδη (112,7% και 110,8% αντίστοιχα), το SPY ακολουθεί με 71,0%, ενώ οι PG και XOM αποδίδουν μέτρια (21,7% και 10,7%). Η JNJ κινείται οριακά θετικά (6,0%) και η AAPL καταγράφει μικρή αρνητική επίδοση (-3,2%). Στο Max Drawdown (Σχήμα 6.14) για TSLA και AMD οι μέγιστες υποχωρήσεις είναι εξαιρετικά μεγάλες (141% και 130%). Το SPY παρουσιάζει τον μικρότερο κραδασμό (39%) μεταξύ των υψηλών αποδόσεων, ενώ οι PG και JNJ έχουν επίσης σχετικά περιορισμένα Drawdowns (34% και 69%). Η AAPL εμφανίζει μεγάλο Drawdown (106%), στοιχείο συμβατό με τη μειονεκτική συνολική απόδοση της.

Τα αποτελέσματα των παραπάνω πειραμάτων δείχνουν μια σαφή εικόνα. Η αρχιτεκτονική βαθιάς μάθησης του LSTM μπορεί μακροπρόθεσμα να δίνει καλή πρόβλεψη κατεύθυνσης, αλλά σε δύσκολα περιβάλλοντα αντιμετωπίζει προβλήματα. Έτσι, τελικά στην επενδυτική στρατηγική τα αποτελέσματα είναι πανομοιότυπα με το ARIMA. Νευρωνικά δίκτυα, όπως το LSTM, χρειάζονται πολύ περισσότερα δεδομένα για να αναδειχθεί η προβλεπτική τους ικανότητα. Με λίγα δεδομένα όπως στο πείραμα αυτό παράγουν ίδια, και σε μερικές


περιπτώσεις χειρότερα, αποτελέσματα με κλασσικές στατιστικές μεθόδους. Σε τέτοιες συνθήκες το πλεονέκτημα ενός θεμελιώδους μοντέλου όπως το TTM γίνεται εμφανές.



Σχήμα 6.12: Sharpe Ratio στρατηγικής ανά μετοχή - LSTM



Σχήμα 6.13: Total Return στρατηγικής ανά μετοχή - LSTM



Σχήμα 6.14: Max Drawdown στρατηγικής ανά μετοχή - LSTM

6.4 iTransformer

Σε αυτή την ενότητα γίνεται η εκπαίδευση και αξιολόγηση με χρήση του μοντέλου iTransformer. Περιγράφεται η δομή του μοντέλου και στην συνέχεια αποτιμάται η απόδοση του στην πρόβλεψη όλων των μετοχών. Η εκπαίδευση του έγινε, όπως και για το LSTM, αποκλειστικά στο SPY με συνθήκες εκπαίδευσης παρόμοιες με εκείνες του TTM.

6.4.1 Δομή iTransformer

Το μοντέλο προβλέπει τον επόμενης ημέρας λογαριθμικό ημερήσιο δείκτη απόδοσης της τιμής κλεισίματος και η μάθηση γίνεται στο χώρο των αποδόσεων και όχι των τιμών. Η χρονοσειρά φορτώνεται με τιμές open, high, low, close, sma_20, ema_20, wma_20, tema_20, bb_upper και bb_lower. Ο στόχος του μοντέλου είναι ο υπολογισμός του r_t όπως για το LSTM. Ο υπολογισμός των αποδόσεων γίνεται από τη στήλη κλεισίματος με `np.diff()` και εισαγωγή $r_0 = 0$. Ο χρονικός διαχωρισμός με μήκος σειράς N περιλαμβάνει τα πρώτα 42% δείγματα. Η κλιμάκωση χαρακτηριστικών εισόδου γίνεται με `MinMaxScaler` που εφαρμόζεται με `.fit` μόνο στα χαρακτηριστικά εισόδου, ενώ η κλιμάκωση στόχου γίνεται με `StandardScaler`. Τα δείγματα δημιουργούνται με sliding windows σταθερού μήκους (`LOOKBACK = 512`) ημερών, όπου για χρόνο i η είσοδο X_i περιλαμβάνει τα προηγούμενα 512 βήματα και στόχος είναι το r_i .

Η αρχιτεκτονική υλοποιείται με PyTorch και χρησιμοποιεί έναν encoder-only Transformer για μονή πρόβλεψη. Αρχικά εφαρμόζεται γραμμική προβολή που χαρτογραφεί τα χαρακτηριστικά εισόδου στον κρυφό χώρο, έπειτα γίνεται αλλαγή διαστάσεων σε σχήμα $(seq, batch, d_model)$ και εισάγεται ημιτονοειδής positional encoding. Ο encoder αποτελείται από δύο στρώματα `TransformerEncoderLayer` με `d_model = 128`, `nhead = 8`, `dim_forward = 512`, `dropout = 0.1`, ενεργοποίηση `GELU` και `norm_first = True`. Η συγκέντρωση γίνεται από την αναπαράσταση του τελευταίου χρονικού βήματος και η έξοδος περνά από `LayerNorm` και `Linear(d_model → 1)`, ώστε να δοθεί μία τιμή που αντιστοιχεί στην απόδοση $\hat{r}_t$. Η είσοδος στο forward έχει σχήμα $(batch, seq = 512, features = F)$ και η έξοδος έχει διαστάσεις $(batch,)$ με τις προβλεπόμενες κανονικοποιημένες αποδόσεις.

Από τους κλιμακωμένους αυτούς πίνακες δημιουργούνται PyTorch tensors για εκπαίδευση και επικύρωση. Έτσι ορίζονται X_{tm} με σχήμα $(n_train_samples, 512, F)$, y_{tm} με σχήμα $(n_train_samples,)$ και validation split που κρατά το τελευταίο 10% των παραθύρων εκπαί-

δευσης ως σύνολο επικύρωσης. Δημιουργούνται `DataLoaders` για εκπαίδευση και επικύρωση με `batch size` ίσο με το $\min(64, n_{\text{train}})$ και `drop_last = False`.

Η εκπαίδευση γίνεται με συνάρτηση κόστους το MSE πάνω στις κανονικοποιημένες αποδόσεις, βελτιστοποιητή τον Adam με ρυθμό μάθησης $1e-3$, και με `gradient clipping` στη νόρμα 1.0 για σταθερότητα. Ο αριθμός εποχών είναι 30 με `early stopping` που παρακολουθεί την τιμή επικύρωσης MSE, αποθηκεύει το καλύτερο μοντέλο όταν το σφάλμα επικύρωσης βελτιώνεται περισσότερο από 10^{-6} , και σταματά όταν δεν υπάρχει βελτίωση για 6 συνεχόμενες εποχές. Μετά το τέλος της διαδικασίας φορτώνονται τα καλύτερα βάρη για περαιτέρω χρήση. Γίνεται αυτόματη επιλογή συσκευής `cuda` όπου αυτή είναι διαθέσιμη, διαφορετικά επιλέγεται η `cpu`, ενώ υπάρχει έλεγχος ώστε να διασφαλίζεται ότι το διαθέσιμο σύνολο εκπαίδευσης επαρκεί για το `LOOKBACK`, διαφορετικά προκαλείται `RuntimeError`.

6.4.2 Αποτελέσματα προβλέψεων

Η συνολική εικόνα του `iTransformer` στο σύνολο αξιολόγησης (Πίνακας 6.7) είναι σχετικά καλή σε όλες τις μετοχές. Στις μετρικές κατεύθυνσης, η επίδοση είναι υψηλή, με μικρές διαφοροποιήσεις μεταξύ ακρίβειας και ανάκλησης, με εξαίρεση την πρόβλεψη στην AMD. Ανά καθεστώς μεταβλητότητας (Πίνακας 6.8), η χαμηλή μεταβλητότητα συνδέεται με τις καλύτερες τιμές σφάλματος και την υψηλότερη κατεύθυνση. Στο αντίθετο άκρο, η υψηλή μεταβλητότητα επιδεινώνει τόσο τα σφάλματα όσο και την κατεύθυνση, ενώ μετά από αντιστροφές τάσης το μοντέλο διατηρεί καλά σφάλματα αλλά χρειάζεται χρόνο για να προσαρμοστεί ως προς τη φορά. Σε πλάγια κίνηση, το ποσοστιαίο σφάλμα παραμένει χαμηλό, αν και τα απόλυτα σφάλματα αυξάνονται λόγω κλίμακας. Στα παράθυρα γεγονότων (Πίνακας 6.9), ο `iTransformer` αποδίδει καλύτερα όταν αναδεικνύεται καθαρή βραχυπρόθεσμη τάση, αλλά γενικώς έχει χαμηλές επιδόσεις, προσομοιάζοντας τα αποτελέσματα του LSTM.

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	1,722	2,440	1,341	0,491	0,513	0,526	0,519
TSLA	6,234	9,179	3,209	0,486	0,499	0,512	0,505
XOM	0,934	1,286	1,403	0,519	0,509	0,522	0,516
SPY	2,926	4,212	0,797	0,491	0,523	0,543	0,533
JNJ	1,097	1,594	0,785	0,533	0,528	0,543	0,535
AMD	2,164	3,202	2,375	0,479	0,464	0,482	0,473
PG	1,066	1,533	0,843	0,490	0,513	0,526	0,520

Πίνακας 6.7: Πίνακας μετρικών στο σύνολο αξιολόγησης - iTransformer

Regime Type	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
High-Volatility	4,199	6,190	2,793	0,483	0,481	0,497	0,489
Low-Volatility	1,082	1,563	0,814	0,512	0,520	0,535	0,527
Post-Trend Reversal	1,328	1,863	1,373	0,505	0,511	0,524	0,517
Sideways/Chop	2,926	4,212	0,797	0,491	0,523	0,543	0,533


Πίνακας 6.8: Πίνακας μετρικών ανά καθεστώς μεταβλητότητας - iTransformer

Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
AAPL	1,139	1,771	1,732	0,426	0,467	0,467	0,467
TSLA	6,399	8,530	3,477	0,431	0,457	0,463	0,460
XOM	1,197	1,609	1,610	0,527	0,565	0,585	0,574
SPY	4,574	5,855	1,174	0,502	0,405	0,426	0,411
JNJ	0,863	1,401	0,758	0,513	0,542	0,562	0,552
AMD	0,609	0,911	2,987	0,448	0,467	0,478	0,472
PG	0,423	0,584	0,701	0,514	0,467	0,488	0,477

Πίνακας 6.9: Πίνακας μετρικών στα παράθυρα γεγονότων - iTransformer

Στη σχέση κυλιόμενης μεταβλητότητας/σφάλματος το νέφος του iTransformer πλαταίνει και αυτό πιο έντονα από αυτό του τελικού μοντέλου, ιδίως στα ανώτερα ποσοστά μεταβλητότητας [4]. Σε χαμηλή μεταβλητότητα τα δύο μοντέλα συγκλίνουν. Ανά μετοχή, η εικόνα είναι

συνεκτική. Στην AAPL η σχέση βραχυπρόθεσμης μεταβλητότητας/σφάλματος είναι εμφανώς ανοδική, με τον iTransformer να παράγει περισσότερα μεγάλα λάθη για ποσά $>0,05$, ενώ το TTM παραμένει συμπαγές. Η TSLA παρουσιάζει το ισχυρότερο φαινόμενο. Στην υψηλή μεταβλητότητα συσσωρεύονται ακραίες τιμές σε επίπεδα σφάλματος 20–50. Στις XOM και στον SPY το πρότυπο είναι ηπιότερο αλλά ίδιο, δηλαδή ήπια κλίση σε χαμηλή μεταβλητότητα και αισθητή διεύρυνση των λαθών του iTransformer καθώς η μεταβλητότητα κινείται προς 0,04–0,08. Η JNJ και η PG έχουν συνολικά μικρότερες διασπορές και σχετικά αδύναμη κλίση. Η AMD (Σχήμα 6.15) προσομοιάζει την TSLA.




Σχήμα 6.15: Διάγραμμα κυλιόμενης μεταβλητότητας/σφάλματος για την AMD - iTransformer [4]


Στο διάγραμμα απόδοσης επενδυτικής στρατηγικής (Σχήμα 6.16) η TSLA έχει μεγάλα ανοδικά σκέλη και έντονες πτώσεις, αλλά κλείνει υψηλά (110–130%). Η AMD παρουσιάζει επίσης ισχυρές εκρηκτικές φάσεις (κορύφωση $>100\%$) με ενδιάμεσες πτώσεις. Το SPY ακολουθεί ηπιότερη, πιο ομαλή ανιούσα τροχιά που τελικά σταθεροποιείται γύρω στο 60–70%. Η PG κινείται σταθερά με μικρά εύρη και μέτριο τελικό κέρδος (20–30%), ενώ η JNJ και η XOM καταγράφουν αρχικά αξιοπρόσεκτα κέρδη που αμβλύνονται στο δεύτερο μισό της

περιόδου. Η AAPL είναι η πιο αδύναμη καμπύλη, με παρατεταμένες φάσεις υποχώρησης και αρνητικό κλείσιμο. Στο Sharpe ratio (Σχήμα 6.17) η καλύτερη αναλογία απόδοσης/κινδύνου εμφανίζεται για το SPY (0,04). Ακολουθούν AMD και TSLA (0,02–0,025), έπειτα PG (0,01), ενώ XOM και JNJ κινούνται οριακά θετικά. Η AAPL είναι ουσιαστικά μηδενική/ελαφρά αρνητική. Στα Total Returns (Σχήμα 6.18) οι υψηλότερες σωρευτικές αποδόσεις προκύπτουν σε TSLA (112%) και AMD (111%), ακολουθεί το SPY (71%). PG (22%) και XOM (11%) δίνουν μέτριες αποδόσεις, το JNJ χαμηλή (6%), ενώ η AAPL είναι αρνητική (–3%). Το μοτίβο υποδεικνύει ότι ο iTransformer κεφαλαιοποιεί καλά τις παρατεταμένες τάσεις σε high-beta μετοχές και στον ευρύτερο δείκτη, αλλά δυσκολεύεται σε πιο αμυντικά περιβάλλοντα. Στο Max Drawdown (Σχήμα 6.19) το κόστος ρίσκου είναι έντονο σε TSLA και AMD, αυξημένο και στην XOM, πιο ήπιο στο SPY (η μικρότερη μπάρα μεταξύ των υψηλών αποδόσεων), χαμηλό στην PG και μέτριο στην JNJ.


Το συμπέρασμα που βγαίνει για τον iTransformer είναι το ίδιο με αυτό για το LSTM. Αυτά τα μοντέλα χρειάζονται πολύ περισσότερα δεδομένα για να αναδειχθούν οι ικανότητές τους, αλλιώς προσομοιάζουν τις ικανότητες κλασσικών στατιστικών μεθόδων. Μια συνολική αποτίμηση των αποτελεσμάτων γίνεται στο επόμενο κεφάλαιο.




Σχήμα 6.16: Διάγραμμα αποδόσεων επενδυτικής στρατηγικής - iTransformer



Σχήμα 6.17: Sharpe Ratio στρατηγικής ανά μετοχή - iTransformer



Σχήμα 6.18: Total Return στρατηγικής ανά μετοχή - iTransformer



Σχήμα 6.19: Max Drawdown στρατηγικής ανά μετοχή - iTransformer

Κεφάλαιο 7

Συμπεράσματα

Σε αυτό το κεφάλαιο γίνεται μια ολική αποτίμηση των συμπερασμάτων που προέκυψαν από τα προηγούμενα πειράματα.

7.1 Σύνοψη και συμπεράσματα

Στους παρακάτω πίνακες φαίνονται ομαδοποιημένα τα αποτελέσματα των μετρικών για τα τέσσερα μοντέλα. Ο Πίνακας 7.1 αφορά τις μετρικές στα σύνολα αξιολόγησης. Το βελτιστοποιημένο TTM (TTM-opt) ενώ δεν εμφανίζει την χαμηλότερη τιμή σε καμία μετρική σφάλματος, είναι πολύ κοντά στα άλλα μοντέλα. Το ενδιαφέρον εύρημα είναι πως στις περισσότερες περιπτώσεις έχει τις υψηλότερες τιμές σε Precision, Recall και F1. Αυτό αναδείχθηκε και από τα διαγράμματα κυλιόμενης μεταβλητότητας/σφάλματος [4]. Ενώ μακροπρόθεσμα τα ARIMA, LSTM και iTransformer έχουν χαμηλότερα σφάλματα, βραχυπρόθεσμα το TTM είχε πιο συμπυκνωμένα σφάλματα γύρω από το μηδέν. Επειδή σε αυτά τα γραφήματα δεν υπολογίζεται το απόλυτο σφάλμα, αλλά η απλή αφαίρεση πραγματικής/προβλεπόμενης τιμής, χαμηλά σφάλματα δείχνουν πως η πρόβλεψη πήγαινε προς τη σωστή κατεύθυνση. Για τα Hit Rate έχουμε, πλην ελάχιστων εξαιρέσεων, χαμηλές τιμές, αναδεικνύοντας πως αυτή η μετρική είναι πολύ δύσκολο να βελτιστοποιηθεί σε προβλέψεις μετοχών. Στα παράθυρα γεγονότων (Πίνακας 7.2) στις περισσότερες περιπτώσεις ο iTransformer και το LSTM κυριαρχούν με εξαίρεση την πρόβλεψη στην TSLA όπου το ARIMA πέτυχε πολύ καλές προβλέψεις. Στην ομαδοποίηση των προβλέψεων ανά καθεστώς μεταβλητότητας (Πίνακας 7.3) οι διαφορές ARIMA, LSTM και iTransformer φαίνεται πως είναι αμελητέες. Αυτό φάνηκε και από το ότι έδωσαν πολύ παρόμοια αποτελέσματα στις επενδυτικές στρατηγικές.

Model	Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
TTM-opt	AAPL	3,11	4,09	2,41	0,477	0,513	0,554	0,533
ARIMA	AAPL	1,1081	1,7537	1,6868	0,421	0,462	0,457	0,459
LSTM	AAPL	1,8344	2,5443	1,4084	0,483	0,505	0,520	0,513
iTransformer	AAPL	1,722	2,440	1,341	0,491	0,513	0,526	0,519
TTM-opt	TSLA	12,63	16,66	7,26	0,494	0,518	0,546	0,532
ARIMA	TSLA	5,6888	7,8264	3,1606	0,442	0,467	0,471	0,469
LSTM	TSLA	5,3074	8,1808	2,8496	0,496	0,508	0,521	0,514
iTransformer	TSLA	6,234	9,179	3,209	0,486	0,499	0,512	0,505
TTM-opt	XOM	2,09	2,62	3,81	0,496	0,503	0,516	0,509
ARIMA	XOM	1,1987	1,6114	1,6136	0,527	0,566	0,570	0,568
LSTM	XOM	0,9543	1,3045	1,4211	0,513	0,503	0,516	0,509
iTransformer	XOM	0,934	1,286	1,403	0,519	0,509	0,522	0,516
TTM-opt	SPY	5,33	6,83	1,40	0,492	0,533	0,579	0,555
ARIMA	SPY	4,5348	5,8346	1,1638	0,510	0,413	0,417	0,415
LSTM	SPY	3,716	4,8984	0,971	0,496	0,528	0,540	0,534
iTransformer	SPY	2,926	4,212	0,797	0,491	0,523	0,543	0,533
TTM-opt	JNJ	1,91	2,42	1,37	0,509	0,524	0,539	0,531
ARIMA	JNJ	0,8636	1,4005	0,7583	0,510	0,540	0,543	0,541
LSTM	JNJ	1,1067	1,5985	0,791	0,532	0,528	0,542	0,534
iTransformer	JNJ	1,097	1,594	0,785	0,533	0,528	0,543	0,535
TTM-opt	AMD	4,51	6,14	4,76	0,479	0,479	0,529	0,502
ARIMA	AMD	0,6014	0,9063	2,9458	0,448	0,466	0,463	0,464
LSTM	AMD	2,2590	3,3088	2,450	0,482	0,467	0,486	0,476
iTransformer	AMD	2,164	3,202	2,375	0,479	0,464	0,482	0,473
TTM-opt	PG	1,79	2,33	1,41	0,469	0,505	0,531	0,518
ARIMA	PG	0,4215	0,5837	0,6989	0,521	0,473	0,473	0,473
LSTM	PG	1,1267	1,5779	0,889	0,487	0,511	0,524	0,517
iTransformer	PG	1,066	1,533	0,843	0,490	0,513	0,526	0,520

Πίνακας 7.1: Ενοποιημένος πίνακας μετρικών στα σύνολα αξιολόγησης για τα 4 μοντέλα

Model	Ticker	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
TTM-opt	AAPL	2,16	2,70	3,24	0,451	0,500	0,585	0,539
ARIMA	AAPL	1,6830	2,4108	1,3100	0,488	0,510	0,510	0,510
LSTM	AAPL	1,1720	1,7882	1,7814	0,426	0,467	0,467	0,467
iTransformer	AAPL	1,139	1,771	1,732	0,426	0,467	0,467	0,467
TTM-opt	TSLA	16,49	19,30	9,17	0,458	0,484	0,556	0,517
ARIMA	TSLA	5,1559	8,0718	2,7930	0,495	0,507	0,507	0,507
LSTM	TSLA	5,8203	7,9328	3,2248	0,446	0,471	0,485	0,478
iTransformer	TSLA	6,399	8,530	3,477	0,431	0,457	0,463	0,460
TTM-opt	XOM	2,51	3,08	3,41	0,512	0,559	0,570	0,565
ARIMA	XOM	0,9300	1,2852	1,3960	0,517	0,507	0,512	0,509
LSTM	XOM	1,2128	1,6170	1,6310	0,519	0,558	0,577	0,567
iTransformer	XOM	1,197	1,609	1,610	0,527	0,565	0,585	0,574
TTM-opt	SPY	6,43	8,12	1,66	0,475	0,400	0,425	0,413
ARIMA	SPY	2,9227	4,2097	0,7957	0,496	0,528	0,529	0,529
LSTM	SPY	4,6639	5,9926	1,1900	0,498	0,404	0,426	0,414
iTransformer	SPY	4,574	5,855	1,174	0,502	0,405	0,426	0,411
TTM-opt	JNJ	1,70	2,14	1,49	0,451	0,510	0,515	0,513
ARIMA	JNJ	1,0956	1,5934	0,7832	0,533	0,528	0,529	0,528
LSTM	JNJ	0,8760	1,4020	0,7680	0,513	0,542	0,556	0,549
iTransformer	JNJ	0,863	1,401	0,758	0,513	0,542	0,562	0,552
TTM-opt	AMD	1,28	1,73	5,99	0,444	0,479	0,507	0,493
ARIMA	AMD	2,0876	3,1357	2,2980	0,484	0,467	0,467	0,467
LSTM	AMD	0,6192	0,9305	3,0350	0,463	0,482	0,507	0,495
iTransformer	AMD	0,609	0,911	2,987	0,448	0,467	0,478	0,472
TTM-opt	PG	0,99	1,15	1,64	0,497	0,471	0,508	0,489
ARIMA	PG	1,0304	1,5141	0,8184	0,493	0,516	0,517	0,516
LSTM	PG	0,4184	0,5810	0,6940	0,518	0,470	0,488	0,479
iTransformer	PG	0,423	0,584	0,701	0,514	0,467	0,488	0,477

Πίνακας 7.2: Ενοποιημένος πίνακας μετρικών στα παράθυρα γεγονότων για τα 4 μοντέλα

Model	Regime Type	MAE	RMSE	MAPE	Hit Rate	Precision	Recall	F1
TTM-opt	High-Volatility	8,57	11,40	6,01	0,4860	0,4990	0,5360	0,5180
ARIMA	High-Volatility	3,6217	5,6038	2,5455	0,4900	0,4870	0,4870	0,4870
LSTM	High-Volatility	3,7832	5,7448	2,6496	0,4890	0,4870	0,5040	0,4950
iTransformer	High-Volatility	4,1990	6,1900	2,7930	0,4830	0,4810	0,4970	0,4890
TTM-opt	Low-Volatility	1,85	2,38	1,39	0,4890	0,5140	0,5350	0,5240
ARIMA	Low-Volatility	1,0630	1,5538	0,8008	0,5130	0,5220	0,5230	0,5220
LSTM	Low-Volatility	1,1167	1,5882	0,8393	0,5100	0,5190	0,5330	0,5260
iTransformer	Low-Volatility	1,0820	1,5630	0,8140	0,5120	0,5200	0,5350	0,5270
TTM-opt	Post-Trend Reversal	2,60	3,36	3,11	0,4860	0,5080	0,5350	0,5210
ARIMA	Post-Trend Reversal	1,3065	1,8480	1,3529	0,5030	0,5090	0,5110	0,5100
LSTM	Post-Trend Reversal	1,3944	1,9244	1,4147	0,4980	0,5040	0,5180	0,5110
iTransformer	Post-Trend Reversal	1,3280	1,8630	1,3730	0,5050	0,5110	0,5240	0,5170
TTM-opt	Sideways/Chop	5,33	6,83	1,40	0,4920	0,5330	0,5780	0,5540
ARIMA	Sideways/Chop	2,9227	4,2097	0,7957	0,4960	0,5280	0,5290	0,5290
LSTM	Sideways/Chop	3,7160	4,8984	0,9710	0,4960	0,5280	0,5400	0,5340
iTransformer	Sideways/Chop	2,9260	4,2120	0,7970	0,4910	0,5230	0,5430	0,5330

Πίνακας 7.3: Ενοποιημένος πίνακας μετρικών ανά καθεστώς μεταβλητότητας για τα 5 μοντέλα

Στα Σχήματα 7.1 - 7.8 παρουσιάζονται τα γραφήματα των προβλέψεων για την τιμή κλεισίματος, σε σύνολο αξιολόγησης και στο παράθυρο «Πάγωμα υψηλού βήτα» για την TSLA, η οποία ήταν η πιο δύσκολη στην πρόβλεψη μετοχή. Η διαφορά στην πρόβλεψη του πλάτους είναι εμφανής στα διαγράμματα του συνόλου αξιολόγησης, όπου ARIMA, LSTM και iTransformer έχουν σαφώς καλύτερες επιδόσεις. Παρ' όλα αυτά όμως, όπως είδαμε το TTM είχε καλύτερη πρόβλεψη στην κατεύθυνση, που δεν μπορεί να φανεί στα σύνολα αξιολόγησης λόγω του όγκου των δεδομένων στο γράφημα. Στα παράθυρα γεγονότων αυτό γίνεται πιο διακριτό, καθώς ARIMA και νευρωνικά δίκτυα σε πολλές περιπτώσεις έχουν καθυστερήσεις πολλών ημερών μέχρι να αλλάξουν κατεύθυνση και σε φάσεις όπου υπάρχει σαφής ανοδική πορεία, για μερικές μέρες προβλέπουν μηδενική αλλαγή κατεύθυνσης.

Ως γενικό συμπέρασμα αυτής της εργασίας, ένα θεμελιώδες μοντέλο, όπως το TTM, που δεν έχει το μειονέκτημα άλλων θεμελιωδών μοντέλων ως προς τους πόρους που απαιτεί, είναι αντάξιο σε προβλέψεις χρονοσειρών μετοχών με κλασσικές στατιστικές μεθόδους και σύγχρονα νευρωνικά δίκτυα. Η εσωτερική του δομή του δίνει το πλεονέκτημα με πολύ λίγα δεδομένα να πετυχαίνει συγκρίσιμες προβλέψεις με αυτές τις μεθόδους, οι οποίες τουλάχιστον

χιστον στην περίπτωση των νευρωνικών δικτύων χρειάζονται περισσότερα δεδομένα για να αναδειχθεί η ικανότητα τους. Σε πιο γενικό πλαίσιο, οι χρονοσειρές μετοχών είναι από τις δυσκολότερες κατηγορίες χρονοσειρών για πρόβλεψη. Συγκρίσιμα αποτελέσματα για το TTM με στατιστικές μεθόδους και μεθόδους βαθιάς μάθησης σε αυτόν τον τομέα, σημαίνει πως σε χρονοσειρές άλλων τομέων, που απαιτούνε πιο απλή ανάλυση το TTM θα μπορούσε να παράγει πολύ καλά αποτελέσματα.




Σχήμα 7.1: Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - σύνολο αξιολόγησης - TTM




Σχήμα 7.2: Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - σύνολο αξιολόγησης - ARIMA




Σχήμα 7.3: Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - σύνολο αξιολόγησης - LSTM



Σχήμα 7.4: Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - σύνολο αξιολόγησης - iTransformer




Σχήμα 7.5: Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - Πάγωμα υψηλού βήτα - TTM



Σχήμα 7.6: Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - Πάγωμα υψηλού βήτα - ARIMA



Σχήμα 7.7: Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - Πάγωμα υψηλού βήτα - LSTM



Σχήμα 7.8: Διάγραμμα προβλέψεων τιμών κλεισίματος TSLA - Πάγωμα υψηλού βήτα - iTransformer

7.2 Μελλοντικές επεκτάσεις

Μια μελλοντική επέκταση της εργασίας αυτής, θα μπορούσε να είναι η εκπαίδευση του μοντέλου σε πληθώρα διαφορετικών τεχνικών δεικτών και η αξιολόγηση σε επιδόσεις ανά καθεστώς μεταβλητότητας. Επίσης, σε μια άλλη επέκταση της εργασίας θα μπορούσε, η μεγαλύτερη ενσωμάτωση χρονοσειρών μετοχών να γίνει στην προεκπαίδευση του μοντέλου και όχι στην μετ'εκπαίδευση όπως έγινε σε αυτή την εργασία. Αυτό θα μπορούσε να γίνει αφαιρώντας κάποια από τα υπόλοιπα σύνολα δεδομένων που έχουν χρησιμοποιηθεί για προεκπαίδευση, για να διατηρηθεί η λιτότητα του μοντέλου. Τέλος, το μοντέλο εκπαιδευμένο σε χρονοσειρές μετοχών θα μπορούσε να χρησιμοποιηθεί για την πρόβλεψη άλλων οικονομικών χρονοσειρών, όπως για παράδειγμα το ακαθάριστο εγχώριο προϊόν.

Βιβλιογραφία

- [1] Rodney Kizito, Phillip Scruggs, Xueping Li, Michael Devinney, Joseph Jansen, and Reid Kress. Long short-term memory networks for facility infrastructure failure and remaining useful life prediction. *IEEE Access*, PP:1–1, 05 2021.
- [2] Yong Liu, Tengge Hu, Haoran Zhang, Haixu Wu, Shiyu Wang, Lintao Ma, and Mingsheng Long. iTransformer: Inverted transformers are effective for time series forecasting. In *The Twelfth International Conference on Learning Representations*, 2024.
- [3] Vijay Ekambaram, Arindam Jati, Pankaj Dayama, Sumanta Mukherjee, Nam H. Nguyen, Wesley M. Gifford, Chandra Reddy, and Jayant Kalagnanam. Tiny time mixers (ttms): Fast pre-trained models for enhanced zero/few-shot forecasting of multivariate time series. In A. Globerson, L. Mackey, D. Belgrave, A. Fan, U. Paquet, J. Tomczak, and C. Zhang, editors, *Advances in Neural Information Processing Systems*, volume 37, pages 74147–74181. Curran Associates, Inc., 2024.
- [4] https://github.com/SpyrosAnagnosto/Thesis_Anagnosto. GitHub repository.
- [5] Abhimanyu Das, Weihao Kong, Rajat Sen, and Yichen Zhou. A decoder-only foundation model for time-series forecasting. In *Forty-first International Conference on Machine Learning*, 2024.
- [6] Abdul Fatir Ansari, Lorenzo Stella, Ali Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Huibin Shen, Oleksandr Shchur, Syama Sundar Rangapuram, Sebastian Pineda Arango, Shubham Kapoor, Jasper Zschiegner, Danielle C. Maddix, Hao Wang, Michael W. Mahoney, Kari Torkkola, Andrew Gordon Wilson, Michael Bohlke-Schneider, and Bernie Wang. Chronos: Learning the language of time series. *Transactions on Machine Learning Research*, 2024. Expert Certification.

- [7] S. Tiwary. Time-series forecasting of stock prices using arima. In *Proceedings of the IEOM Society International Conference (India)*. IEOM Society International, 2022.
- [8] Dariusz Kobiela, Dawid Krefta, Weronika Król, and Paweł Weichbroth. Arima vs lstm on nasdaq stock exchange data. *Procedia Computer Science*, 207:3836–3845, 2022.
- [9] Adil Moghar and Mhamed Hamiche. Stock market prediction using LSTM recurrent neural network. *Procedia Computer Science*, 170:1168–1173, 2020.
- [10] Phuoc Tran, Thi Kim Anh Pham, Huy Tam Phan, and Chien V. Nguyen. Applying machine learning algorithms to predict the stock price trend in the stock market – the case of vietnam. *Humanities and Social Sciences Communications*, 11(1), 2024.
- [11] Tian Li and et al. MASTER: Market-guided stock transformer for stock price forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2024.
- [12] Xinghong Fu, Masanori Hirano, and Kentaro Imajo. Financial fine-tuning a large time series model, December 2024.
- [13] Ben A. Marconi. Time series foundation models for multivariate financial time series forecasting, July 2025.